

Segmentación clásica del tumor realzante (ET) en T1c sobre BraTS 2024 GLI: alcances y límites de los métodos sin aprendizaje profundo

Abel Albuez, Victoria Acero y Santiago Gil
Maestría en Ingeniería de Sistemas y Computación
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Procesamiento de Imágenes Médicas 2026

Repositorio: <https://github.com/AbelAlbuez/medical-image-processing>

Resumen—Se aborda la segmentación automática del tumor realzante (*enhancing tumor*, ET; etiqueta 3 de BraTS) sobre la modalidad T1 con contraste (T1c) empleando exclusivamente métodos clásicos de SIMPLEITK, sin aprendizaje profundo. Un análisis exploratorio sobre 100 casos de *BraTS 2024 GLI Post-Treatment* (78 con ET presente) muestra que T1c es la modalidad más separable para el realce (razón discriminante de Fisher mediana de 1,32 frente a 0,47 en T2-FLAIR). Tras una limpieza de T1c (Wiener $\rightarrow$ N4 $\rightarrow$ normalización por percentiles) se evalúan cuatro métodos —Otsu multinivel, crecimiento de regiones, *watershed* por marcadores y mezcla de gaussianas multimodal— sobre nueve casos. El hallazgo central es que los métodos clásicos por intensidad son insuficientes para el ET: ningún método supera un Dice medio de 0,50, y el mejor —crecimiento de regiones, con Dice medio de 0,320— es apenas “el menos malo”. La mezcla de gaussianas multimodal *sobre-segmenta* (sensibilidad 0,63 pero Dice 0,094), evidenciando que añadir modalidades no compensó la falta de un modelo de forma. Complementariamente, un registro rígido por información mutua de Mattes recupera una perturbación conocida con un error de registro objetivo (TRE) medio de 0,007 mm, y una reconstrucción 3D por *marching cubes* valida la escala física de las mallas.

Index Terms—BraTS 2024 GLI, tumor realzante, T1c, segmentación clásica, SimpleITK, información mutua de Mattes, *marching cubes*.

I. INTRODUCCIÓN Y OBJETIVOS

Los gliomas son los tumores cerebrales primarios más frecuentes y su seguimiento por resonancia magnética (RM) es central en la práctica clínica. En el escenario *post-tratamiento*, el tumor realzante (ET) —tejido que capta contraste en T1c— es un marcador de actividad tumoral residual o recurrente, y por ello un objetivo de interés clínico directo. El reto BraTS 2024 GLI [1] introduce explícitamente la cavidad de resección como una clase adicional, lo que altera las hipótesis de intensidad sobre las que descansan los métodos clásicos.

Este trabajo se restringe deliberadamente a **métodos clásicos** (sin aprendizaje profundo) implementados sobre ITK/SIMPLEITK [2], con el objetivo de caracterizar honestamente sus *alcances y límites* para el ET. Los objetivos concretos son: (i) un análisis exploratorio (EDA) que justifique la modalidad objetivo; (ii) una limpieza de T1c; (iii) un registro rígido demostrativo por información mutua; (iv) la segmentación del ET con cuatro métodos clásicos; y (v) una

reconstrucción 3D de las máscaras para inspección visual. La canalización completa se organiza en seis módulos reproducibles y se ejecuta leyendo los datos directamente desde los archivos comprimidos del reto.

II. MATERIALES Y DATASET

Se emplea el subconjunto *BraTS 2024 GLI Post-Treatment*. Cada caso aporta cuatro modalidades co-registradas (T1n, T1c, T2w, T2-FLAIR) y una segmentación experta *seg* con cuatro etiquetas: 1=NETC (núcleo no realzante), 2=SNFH (edema/FLAIR hiperintenso), 3=ET (realce) y 4=RC (cavidad de resección). **El objetivo de este trabajo es la etiqueta 3 (ET)**. Los volúmenes se leen directamente desde los .zip del reto, extrayendo puntualmente cada par caso/modalidad sin descomprimir el archivo completo. Se procesa un subconjunto de 100 casos del conjunto de entrenamiento (el que posee *seg*); de ellos, **78 contienen ET**.

La Tabla I resume la geometría, homogénea en todo el subconjunto (verificada por el EDA).

Cuadro I
GEOMETRÍA DEL SUBCONJUNTO (UNIFORME EN LOS 100 CASOS).

Propiedad	Valor
Dimensiones (vóxeles)	$182 \times 218 \times 182$
Espaciado	$1,0 \times 1,0 \times 1,0$ mm (isotrópico)
Casos procesados	100
Casos con ET (<i>seg</i> ==3)	78

II-A. Separabilidad del ET por modalidad

Para justificar la modalidad objetivo se midió la separabilidad entre los vóxeles de ET y el tejido cerebral sano por modalidad, mediante la razón discriminante de Fisher (FDR) y la distancia de Bhattacharyya (Tabla II, Fig. 1). **T1c es claramente la modalidad más separable para el ET** (FDR mediano 1,32, casi el triple que T2-FLAIR), lo que confirma la elección de T1c como soporte de la segmentación.

Cuadro II
SEPARABILIDAD ET VS. TEJIDO SANO POR MODALIDAD (MEDIANA Y MEDIA SOBRE LOS 78 CASOS CON ET).

Modalidad	FDR mediana	FDR media	Bhatt. med.	Bhatt. media
T1c	1,317	1,461	0,375	0,403
T2-FLAIR	0,472	0,818	0,153	0,238
T2w	0,341	0,667	0,178	0,250
T1n	0,099	0,227	0,126	0,177




Figura 1. Separabilidad ET vs. tejido sano por modalidad (FDR y Bhattacharyya medianos). T1c domina, justificando su uso para ET.

II-B. Umbral de Otsu y casos demostrativos

El umbral alto de Otsu ($n=3$) sobre T1c en escala cruda tiene una mediana de 3120 y un rango de 352 a 6435 entre casos (Fig. 2), lo que evidencia una fuerte variabilidad inter-caso de la intensidad y motiva la normalización del módulo siguiente. El volumen de ET tiene una mediana de 4814 mm³ (rango 66–87 993 mm³). A partir de esta distribución se seleccionaron automáticamente casos demostrativos que cubren el rango de tamaño de ET más un caso *sin* ET (Tabla III, Fig. 3).

Cuadro III
CASOS DEMOSTRATIVOS SELECCIONADOS POR EL EDA.

Categoría	Caso	Volumen ET (mm ³)
Pequeño	BraTS-GLI-00529-100	501
Mediano	BraTS-GLI-02063-102	4 812
Grande	BraTS-GLI-02060-100	19 975
Sin ET	BraTS-GLI-00005-100	0

III. PREPROCESAMIENTO (T1c)

Sobre T1c se aplica, en este orden: (1) reducción de ruido con filtro de Wiener adaptativo (ventana 3); (2) corrección del campo de sesgo con N4 [4] (*shrink* 4); y (3) normalización por percentiles [0,5, 99,5] a [0,1] dentro del cerebro. El denoise precede a N4 para evitar que el ruido se modele como estructura, y la normalización al final fija la escala entre casos (Tabla I mostró que la geometría es homogénea, por lo que no se requiere remuestreo).

La Tabla IV resume, para los nueve casos de la segmentación, la intensidad antes (escala cruda) y después de la limpieza; todos los volúmenes quedan en [0,1], lo que homogeneiza la escala dispar de partida (medias crudas de 335 a 3096). La Fig. 4 ilustra el efecto.




Figura 2. Distribución del umbral alto de Otsu ($n=3$) en T1c por caso (escala cruda); la dispersión justifica normalizar.




Figura 3. Casos demostrativos: T1c con el ET (contorno rojo) en el corte del centroide. El caso sin ET no presenta realce.

IV. REGISTRO RÍGIDO DEMOSTRATIVO

Se incluye una demostración cuantitativa de registro rígido por información mutua de Mattes [5] con transformación Euler3D y esquema multi-resolución. Tomando T1c como volumen fijo, se le aplica una perturbación rígida *conocida* (rotación (6, 4, -5)°, traslación (5, -4, 3) mm) para generar un volumen desalineado, y se registra para recuperarla. La métrica se configura con 50 *bins*, muestreo aleatorio del 10 % (semilla 42), inicialización por geometría (*CenteredTransformInitializer*), optimizador *gradient descent line search*, factores de reducción [4, 2] y sigmas [2, 1].

Como la perturbación es conocida, el error de registro objetivo (TRE) mide directamente la calidad: en los cuatro casos es *sub-vóxel* ($\approx 0,007$ mm), y el Dice del cerebro mejora de 0,906 a 0,963 (Tabla V, Fig. 5). El registro recupera con precisión la transformación impuesta; es el único bloque del trabajo con un resultado cuantitativamente sólido, en contraste con la segmentación.

V. SEGMENTACIÓN CLÁSICA DEL ET

Sobre T1c limpio se evaluaron cuatro métodos clásicos, con el ET ($seg==3$) como referencia: **Otsu** multinivel ($n=3$ [3], clase más brillante); **crecimiento de regiones**; **watershed** por marcadores [6]; y **mezcla de gaussianas** (GMM [7]) *multimodal* (T1c+T2w+T2-FLAIR), incluida como comparación. Se usaron nueve casos: ocho con ET (cubriendo el rango de volumen) y uno sin ET (robustez).

Cuadro IV

ESTADÍSTICAS DE INTENSIDAD DENTRO DEL CEREBRO ANTES Y DESPUÉS DE LA LIMPIEZA (9 CASOS DE SEGMENTACIÓN).

Caso	ET	media _{orig}	p99 _{orig}	media _{limp}	std _{limp}
02063-106	sí	359,2	669,0	0,350	0,117
00529-100	sí	1973,7	3299,2	0,507	0,131
02062-100	sí	385,9	683,0	0,384	0,108
02063-102	sí	334,7	616,2	0,365	0,112
00498-100	sí	1651,9	2986,4	0,451	0,114
00463-101	sí	2133,1	4300,3	0,305	0,124
02060-100	sí	690,8	1358,0	0,340	0,128
00046-101	sí	3096,0	7022,2	0,280	0,128
00005-100	no	2081,6	4334,2	0,374	0,103




Figura 4. Limpieza de T1c (caso 02060-100): original, resultado (Wiener→N4→normalización) e histograma cerebral.

V-A. Hallazgo: la semilla del crecimiento de regiones

El comportamiento del crecimiento de regiones reveló un problema específico del escenario post-tratamiento que merece destacarse. La semilla natural —el centroide del ET— **cae dentro de la cavidad de resección** (label 4), que es *oscura* en T1c, porque el ET forma típicamente un *anillo* alrededor de dicha cavidad. Sembrado ahí, el crecimiento por intensidad parte de tejido oscuro y se “fuga” hacia el resto del cerebro, produciendo máscaras degeneradas (Dice ≈ 0). La solución adoptada es sembrar en el **vóxel de ET más brillante** y crecer por una *ventana brillante* [$\alpha I_{\text{semilla}}$; máx] con $\alpha = 0,65$ (calibrado por barrido, Tabla VIII). La etiqueta experta solo aporta la *ubicación* de la semilla (inicialización semi-automática); la máscara final surge del crecimiento sobre T1c, no de la copia del *ground truth*.

V-B. Resultados agregados

La Tabla VI promedia las métricas sobre los ocho casos con ET. El crecimiento de regiones obtiene el mejor Dice medio, pero **este valor (0,320) debe leerse como “el menos malo”, no como un éxito**: ningún método alcanza siquiera 0,50 de Dice. La GMM multimodal exhibe la mayor sensibilidad (0,63) pero el peor Dice (0,094), porque etiqueta como tumor un cúmulo amplio (edema, vasos) y *sobre-segmenta*; su especificidad (0,965) es la más baja de las cuatro. La Fig. 6 resume el orden y la Fig. 7 contrasta visualmente el mejor método con la sobre-segmentación de la GMM.

V-C. Resultados por caso

La Tabla VII muestra el Dice por caso (semáforo: verde $\geq 0,80$, amarillo 0,50–0,80, rojo $< 0,50$). El predominio del




Figura 5. Arriba: fija, desalineada y recuperada (caso 02060-100). Abajo: convergencia de la información mutua de Mattes; la métrica desciende y se estabiliza.




Figura 6. Dice medio por método. RegionGrowing es el mejor, pero todos quedan muy por debajo de un Dice útil.

rojo es, en sí mismo, el resultado: la inmensa mayoría de las combinaciones caso/método quedan por debajo de 0,50. Además, la **dispersión es alta y no hay un ganador estable**: aunque RegionGrowing gana en promedio, Watershed supera al resto en 02063-106 y 00463-101 (único valor amarillo, 0,618), y Otsu es competitivo en los casos de ET grande. El caso sin ET (00005-100) no admite Dice (N/A), pero los cuatro métodos producen máscaras no vacías (falsos positivos), lo que ilustra que ningún método clásico “se abstiene” ante la ausencia de realce.

V-D. Calibración del crecimiento de regiones

La Tabla VIII reporta el barrido (*itertools.product*) del umbral relativo α y el radio del cierre morfológico. El óptimo medio se alcanza en ($\alpha = 0,65$, cierre = 3) con Dice 0,341; la configuración por defecto usa cierre 1 (0,320). La mejora por ajuste es marginal, coherente con el límite de fondo del método.

Cuadro V
REGISTRO RÍGIDO DEMOSTRATIVO (PERTURBACIÓN CONOCIDA → RECUPERACIÓN). TRE SUB-VÓXEL Y MEJORA DEL DICE DE CEREBRO EN LOS CUATRO CASOS.

Caso	TRE (mm)	Dice cerebro antes	Dice cerebro después	MSE antes	MSE después	MI final	Tiempo (s)
00529-100	0,0064	0,9076	0,9633	205 707	3 109	−1,029	8,1
02063-102	0,0095	0,9110	0,9646	5 635	188	−1,000	6,7
02060-100	0,0082	0,9196	0,9621	27 553	1 106	−0,982	7,2
00005-100	0,0054	0,8865	0,9607	242 177	3 676	−0,765	7,0
Promedio	0,0074	0,9062	0,9627	120 268	2 020	−0,944	7,25

Cuadro VI
RESUMEN POR MÉTODO (DICE MEDIO SOBRE 8 CASOS CON ET). NINGÚN MÉTODO SUPERA 0,50.

Método	Multim.	Dice	Jaccard	Sensib.	Especif.
RegionGrowing	no	0,320	0,196	0,362	0,999
Watershed	no	0,213	0,132	0,133	0,999
Otsu	no	0,164	0,097	0,516	0,995
GMM multimodal	sí	0,094	0,052	0,630	0,965

Cuadro VII
DICE POR CASO Y MÉTODO. SEMÁFORO: VERDE $\geq 0,80$, AMARILLO 0,50–0,80, ROJO $< 0,50$.

Caso	Otsu	RegionGrow.	Watershed	GMM mult.
02063-106	0,007	0,257	0,344	0,003
00529-100	0,009	0,407	0,155	0,000
02062-100	0,023	0,217	0,088	0,026
02063-102	0,170	0,283	0,255	0,000
00498-100	0,136	0,157	0,096	0,094
00463-101	0,207	0,280	0,618	0,146
02060-100	0,368	0,451	0,110	0,265
00046-101	0,395	0,509	0,035	0,217
00005-100 (sin ET)	N/A	N/A	N/A	N/A

Cuadro VIII
BARRIDO DEL CRECIMIENTO DE REGIONES (DICE MEDIO SOBRE LOS CASOS CON ET).

α	cierre	Dice	α	cierre	Dice
0,55	1	0,266	0,65	3	0,341
0,55	2	0,269	0,75	1	0,287
0,55	3	0,269	0,75	2	0,306
0,65	1	0,320	0,75	3	0,322
0,65	2	0,331			




Figura 7. Caso 02060-100. Arriba: crecimiento de regiones (predicción roja, GT cian). Abajo: GMM multimodal, que sobre-segmenta ampliamente.

VI. RECONSTRUCCIÓN 3D

Para inspección visual se generaron mallas por *marching cubes* [8] del ET predicho (crecimiento de regiones) y del *ground truth*, con el espaciado físico aplicado y suavizado de Taubin, exportadas en OBJ y GLB; un visor web autocontenido (Three.js local) permite superponerlas en la exposición. La Tabla IX reúne las métricas.

Dos lecturas. Primero, la **validación de escala es correcta**: el volumen de la malla GT reproduce el volumen de ET del EDA en el mismo orden de magnitud (p. ej. caso 02060-100, 19 266 vs. 19 975 mm³; caso 00046-101, 25 685 vs. 25 306 mm³), lo que confirma una geometría física consistente. Segundo, la **distancia media superficie-superficie entre predicción y GT (2,6 a 42,7 mm) no valida la predicción**; al contrario, cuantifica cuánto se *aleja* la malla predicha del GT en los casos difíciles (p. ej. 00498-100, donde la predicción

multiplica por seis el volumen del GT y la distancia asciende a 42,7 mm). La reconstrucción 3D es, por tanto, una herramienta de inspección y de validación de escala, no una medida de acierto.




Figura 8. Mallas ET predicho (naranja) vs. GT (verde). Izquierda: 02060-100 (solape razonable). Derecha: 00498-100, donde la predicción sobre-segmenta y se aleja del GT.

Cuadro IX

MÉTRICAS 3D POR CASO. LA VALIDACIÓN DE ESCALA (VOL. MALLA GT VS. EDA) ES CORRECTA; LA DISTANCIA SUPERFICIE-SUPERFICIE MIDE EL *alejamiento* PRED $\leftrightarrow$ GT, NO ACIERTO.

Caso	Dice	Vért. pred	Vért. GT	Vol. pred (mm ³)	Vol. GT (mm ³)	Vol. GT EDA (mm ³)	Dist. media (mm)
02063-106	0,257	724	450	254,6	192,1	254,0	4,79
00529-100	0,407	298	722	112,4	424,9	501,0	2,13
02062-100	0,217	633	1 704	187,8	908,4	1 062,0	3,72
02063-102	0,283	824	3 898	747,9	4 706,2	4 812,0	10,09
00498-100	0,157	48 963	5 906	29 113,1	4 535,9	4 816,0	42,74
00463-101	0,280	49 983	8 044	27 308,6	11 258,8	11 312,0	37,45
02060-100	0,451	33 392	18 583	19 489,3	19 266,1	19 975,0	14,13
00046-101	0,509	15 095	18 109	11 269,1	25 685,0	25 306,0	2,64




Figura 9. Mosaico de 3 vistas (axial/coronal/sagital) del caso 02060-100: original con GT y las cuatro segmentaciones.

VII. DISCUSIÓN Y LIMITACIONES

Por qué fallan los métodos clásicos en el ET. El ET no es un objeto “brillante y compacto” separable por intensidad: es un anillo delgado, heterogéneo y, en el escenario post-tratamiento, rodea una cavidad oscura. Esto rompe las hipótesis de cada método. *Otsu* supone un histograma con un modo brillante claro, pero T1c es *unimodal* (coeficiente de bimodalidad $< 5/9$ en los casos analizados), de modo que el umbral de la clase alta cae en un punto arbitrario y mezcla realce con tejido sano brillante. *Crecimiento de regiones* y *watershed* dependen de una semilla/marcador fiable; aun corregida la semilla (Sec. V-A), la heterogeneidad del realce limita el crecimiento. *GMM multimodal* ilustra que **añadir modalidades no ayudó**: al agrupar T1c+T2w+T2-FLAIR captura un cúmulo amplio dominado por el edema, con alta sensibilidad pero Dice ínfimo (Fig. 10).

Limitaciones del registro demostrativo. El registro es rígido y se evaluó frente a una perturbación rígida conocida; por construcción no compensa deformaciones no rígidas (efecto de masa, cambios post-quirúrgicos) y su excelente TRE no debe extrapolarse a un escenario inter-sujeto o longitudinal real.

Alcance experimental. La segmentación se evaluó sobre nueve casos y el registro/3D sobre cuatro y ocho respectivamente; las cifras son indicativas, no un *benchmark* a gran escala.




Figura 10. Sobre-segmentación de la GMM multimodal (caso 00529-100): predicción roja muy superior al GT cian.

VIII. REPRODUCIBILIDAD

La canalización completa (seis módulos en Python 3.11 con SIMPLEITK) es reproducible y lee los datos directamente desde los .zip. La Tabla X resume los parámetros clave.

Cuadro X
PARÁMETROS DEL PIPELINE.

Etapas	Configuración
Objetivo	ET ($seg==3$) sobre T1c
Limpieza	Wiener (3) $\rightarrow$ N4 (<i>shrink</i> 4) $\rightarrow$ percentil [0,5, 99,5] $\rightarrow$ [0, 1]
Otsu	multinivel $n=3$, clase alta
Region growing	semilla en ET más brillante, ventana $[\alpha I, \text{máx}]$, $\alpha = 0,65$
Watershed	marcador en ET brillante, gradiente de Sobel
GMM	4 componentes, T1c+T2w+T2-FLAIR
Registro	Mattes MI (50 bins), Euler3D, <i>shrink</i> [4, 2], sigmas [2, 1], 150 iter
Semilla aleatoria	42
Datos	lectura directa desde .zip (BraTS 2024 GLI)

IX. CONCLUSIONES Y TRABAJO FUTURO

El hallazgo central es claro y honesto: **los métodos clásicos basados en intensidad son insuficientes para segmentar el tumor realzante en T1c** en BraTS 2024 GLI post-tratamiento. Ningún método supera un Dice medio de 0,50; el mejor —crecimiento de regiones, 0,320— es apenas “el menos malo”, y la multimodalidad mediante GMM no ayudó (sobre-segmentación). El escenario post-tratamiento, con su cavidad de resección oscura, agrava el problema y obligó a corregir la estrategia de siembra. En contraste, el registro rígido por información mutua sí resuelve con precisión su tarea (TRE

sub-vóxel), y la reconstrucción 3D valida la escala física de las máscaras.

Como trabajo futuro, estos límites motivan: (i) modelos con *prior* de forma (*level sets* con regularización, contornos activos) que no dependan solo de intensidad; (ii) una combinación multimodal más informada que la GMM ingenua; (iii) registro deformable para escenarios longitudinales; y (iv), naturalmente, el aprendizaje profundo, cuya necesidad este estudio cuantifica por contraste.

REFERENCIAS

- [1] U. Baid *et al.*, “The RSNA-ASNR-MICCAI BraTS 2021 benchmark on brain tumor segmentation and radiogenomic classification,” *arXiv:2107.02314*, 2021.
- [2] B. C. Lowekamp, D. T. Chen, L. Ibáñez and D. Blezek, “The design of SimpleITK,” *Frontiers in Neuroinformatics*, vol. 7, p. 45, 2013.
- [3] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [4] N. J. Tustison *et al.*, “N4ITK: Improved N3 bias correction,” *IEEE Trans. Med. Imag.*, vol. 29, no. 6, pp. 1310–1320, 2010.
- [5] D. Mattes, D. R. Haynor, H. Vesselle, T. K. Lewellyn and W. Eubank, “PET-CT image registration in the chest using free-form deformations,” *IEEE Trans. Med. Imag.*, vol. 22, no. 1, pp. 120–128, 2003.
- [6] L. Vincent and P. Soille, “Watersheds in digital spaces: an efficient algorithm based on immersion simulations,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 6, pp. 583–598, 1991.
- [7] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [8] W. E. Lorensen and H. E. Cline, “Marching cubes: A high resolution 3D surface construction algorithm,” *ACM SIGGRAPH Computer Graphics*, vol. 21, no. 4, pp. 163–169, 1987.