

Segmentación clásica de gliomas en BraTS 2024 (GLI) y registro rígido por información mutua: un estudio de las limitaciones de los métodos sin aprendizaje profundo

Abel Albuez, Victoria Acero y Santiago Gil
Maestría en Ingeniería de Sistemas y Computación
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Procesamiento de Imágenes Médicas 2026

Repositorio: <https://github.com/AbelAlbuez/medical-image-processing>

Resumen—Se presenta un proyecto de procesamiento de imágenes médicas sobre el dataset *BraTS 2024 Adult Glioma* (GLI), estructurado en tres bloques: (i) un análisis exploratorio (EDA) de 25 casos multimodales (T1n, T1c, T2w, T2-FLAIR); (ii) un pipeline de segmentación automática del tumor cerebral *completo* ($seg > 0$) en la modalidad FLAIR mediante métodos clásicos basados en intensidad —Otsu multinivel, modelos de mezcla Gaussiana (GMM), crecimiento de regiones sembrado en el centroide del *ground truth* y watershed por marcadores— sin recurrir a aprendizaje profundo; y (iii) una demostración cuantitativa de registro rígido por información mutua de Mattes con transformación Euler3D y esquema multi-resolución, sobre tres casos representativos. El hallazgo central del bloque de segmentación es que los métodos puramente basados en intensidad son insuficientes para el tumor completo en casos post-tratamiento (Dice medio 0,33 con Otsu, el mejor método; 0,18 con crecimiento de regiones), principalmente porque la cavidad de resección es hipointensa en FLAIR y rompe la hipótesis de un único modo brillante. El registro, en cambio, recupera la perturbación rígida impuesta con un *Target Registration Error* (TRE) residual sub-vóxel (media 0,004 mm), confirmando la robustez del motor MattesMI + Euler3D incluso cuando las modalidades del dataset ya están coregistradas de fábrica.

Index Terms—BraTS 2024, gliomas, segmentación clásica, Otsu, GMM, crecimiento de regiones, watershed, registro rígido, información mutua, ITK, SimpleITK.

I. INTRODUCCIÓN Y OBJETIVOS

Los gliomas adultos son los tumores cerebrales primarios más frecuentes y presentan una alta heterogeneidad morfológica e intensitaria que dificulta su delineación automática en resonancia magnética (RM). La iniciativa BraTS (*Brain Tumor Segmentation Challenge*) provee anualmente un dataset multimodal con segmentaciones expertas que se ha convertido en el estándar de facto para evaluar algoritmos de segmentación de gliomas [1]. La edición 2024 (track GLI) amplía la cohorte y reorganiza las etiquetas para distinguir entre *Necrotic Tumor Core* (NETC), *Surrounding Non-enhancing FLAIR Hyperintensity* (SNFH), *Enhancing Tumor* (ET) y *Resection Cavity* (RC).

El presente proyecto se enmarca en el curso de Procesamiento de Imágenes Médicas de la Maestría en Ingeniería

de Sistemas y Computación de la Pontificia Universidad Javeriana, cuyo requisito explícito es resolver tareas de análisis de imagen **sin recurrir a aprendizaje profundo**. Bajo esa restricción, los objetivos son:

1. Caracterizar mediante un EDA cuantitativo el dataset BraTS 2024 GLI y derivar parámetros operativos (modalidad fija para registro, métrica recomendada, semillas).
2. Implementar un pipeline reproducible de **segmentación automática del tumor completo** ($seg > 0$) sobre la modalidad T2-FLAIR usando cuatro familias clásicas (Otsu, GMM, crecimiento de regiones, watershed) y cuantificar sus límites contra *ground truth*.
3. Demostrar cuantitativamente, sobre tres casos, un motor de **registro rígido por información mutua** (MattesMI + Euler3D multi-resolución) recuperando una perturbación conocida.

La hipótesis de trabajo es que, aun con una cuidadosa cadena de preprocesamiento (Wiener + N4 + normalización por percentiles), los métodos clásicos basados solamente en intensidad serán insuficientes para casos con cavidad de resección, justificando empíricamente la necesidad de información de forma, atlas o aprendizaje en pipelines clínicos modernos.

II. MATERIALES Y DATASET

Se trabajó sobre una muestra de **25 casos** del subconjunto público BraTS 2024 GLI. Cada caso contiene cuatro volúmenes multimodales 3D —T1 nativo (T1n), T1 con contraste (T1c), T2 ponderado (T2w) y T2 FLAIR (T2f)— y una segmentación experta (seg) con las etiquetas NETC, SNFH, ET y RC. Como muestra la Tabla I, los 25 volúmenes comparten geometría exactamente: forma $182 \times 218 \times 182$, espaciado isotrópico de 1 mm y orientación LAS, lo que descarta la necesidad de remuestreo o reorientación previas.

Cuadro I
GEOMETRÍA DE LOS 25 CASOS ANALIZADOS (HOMOGÉNEA EN TODO EL SUBSET).

Propiedad	Valor
Forma del volumen (vóxeles)	$182 \times 218 \times 182$
Espaciado (mm)	$1,00 \times 1,00 \times 1,00$
Orientación	LAS
Casos isotrópicos a 1 mm	100 %

II-A. Distribución de intensidades por modalidad

La Figura 1 resume la distribución de intensidades por modalidad sobre los 25 casos. Las cuatro modalidades difieren tanto en rango dinámico como en forma del histograma, motivando la normalización por percentiles que se describe en la Sección III.




Figura 1. Distribuciones de intensidad por modalidad sobre los 25 casos (T1n, T1c, T2w, T2-FLAIR).

II-B. Separabilidad sub-región vs. tejido sano

Para anticipar el desempeño esperado de una segmentación por umbral, se calcularon dos métricas de separabilidad entre cada sub-región y el tejido sano: el *Fisher Discriminant Ratio* (FDR; mayor = más separable) y la distancia de Bhattacharyya (mayor = más separable). Los valores se reportan en la Tabla II.

Cuadro II
SEPARABILIDAD DE CADA SUB-REGIÓN RESPECTO A TEJIDO SANO, POR MODALIDAD. *FDR*: FISHER DISCRIMINANT RATIO (↑ MEJOR). *Bhatt.*: DISTANCIA DE BHATTACHARYYA (↑ MEJOR).

Métrica	Sub-región	T1n	T1c	T2w	T2-FLAIR
FDR	NETC	0.611	0.672	0.551	0.550
	SNFH	0.851	0.858	0.740	0.604
	ET	0.663	0.731	0.710	0.670
	RC	0.639	0.638	0.564	0.659
Bhatt.	NETC	0.145	0.079	0.204	0.211
	SNFH	0.026	0.018	0.057	0.163
	ET	0.089	0.070	0.069	0.089
	RC	0.134	0.134	0.188	0.082

La SNFH (edema/infiltración no-realzante, principal componente del *tumor completo*) es claramente más separable en

T2-FLAIR ($Bhatt. = 0,163$ frente a $\leq 0,06$ en las otras modalidades). Este resultado justifica empíricamente la elección de FLAIR como modalidad de trabajo para la segmentación del objetivo $seg > 0$.




Figura 2. Separabilidad sub-región vs. tejido sano: heatmaps de FDR y Bhattacharyya por modalidad y sub-región.

II-C. Umbrales Otsu y grado de bimodalidad

Se estimaron umbrales Otsu multinivel (dos cortes) sobre cada modalidad y se cuantificó el grado de bimodalidad del histograma (razón inter/intra-clase). Como referencia global, la Tabla III reporta los valores medianos.

Cuadro III
UMBRALES OTSU MULTINIVEL MEDIANOS Y BIMODALIDAD POR MODALIDAD (SOBRE 25 CASOS).

Modalidad	Otsu bajo	Otsu alto	Bimodalidad
T1c	759.17	1710.55	0.229
T1n	505.17	822.55	0.533
T2-FLAIR	393.97	698.63	0.369
T2w	791.70	1332.09	0.587




Figura 3. Umbrales Otsu (líneas verticales) sobre el histograma agregado y grado de bimodalidad por modalidad.

II-D. Variabilidad inter-caso y casos demostrativos

Existe una alta varianza inter-caso del volumen tumoral total (de $\sim 4,5$ k vóxeles en el caso más pequeño hasta ~ 195 k en el más grande), así como del p99 de intensidad. La Figura 4

ilustra esa dispersión. Para los bloques de segmentación y registro se eligieron cinco casos representativos cubriendo distintas situaciones clínicas, listados en la Tabla IV.




Figura 4. Variabilidad inter-caso de las medias y p99 de intensidad por modalidad.

Cuadro IV
CINCO CASOS DEMOSTRATIVOS SELECCIONADOS PARA LOS EXPERIMENTOS. VOLÚMENES EN VÓXELES (GROUND TRUTH).

Caso	Motivo	Total	NETC	SNFH	ET	RC
02827-100	Típico (mediana)	57050	0	13208	0	43842
02119-101	Tumor grande ($\sim p_{95}$)	195115	2701	174405	2409	15600
02923-101	Tumor pequeño ($\sim p_5$)	10036	0	4798	0	5238
02514-102	Post-resección ($RC > 0$)	156341	0	62326	5185	88850
02859-100	Sólo edema (sin ET)	64735	0	62422	0	23850

Nótese que en cuatro de los cinco casos la sub-región *Resection Cavity* (RC) es significativa, y en tres de ellos es la sub-región dominante. Esto será determinante para entender las limitaciones reportadas en la Sección VI.

II-E. Semilla automática para crecimiento de regiones

Como insumo del método de crecimiento de regiones se identificó, por caso, un punto candidato a semilla preferentemente dentro de ET (o, en su defecto, dentro del tumor completo) con su intensidad T1c asociada. La Figura 5 muestra el solapamiento de las intensidades de semilla con la distribución de tejido sano, anticipando que la semilla por sí sola no es discriminante.




Figura 5. Intensidades T1c en el voxel semilla (por caso) frente a la distribución global de T1c en tejido sano.

II-F. Parámetros derivados para el bloque de registro

A partir del EDA (archivo `parametros_registro.json`) se fijaron los parámetros operativos del registro: modalidad fija recomendada **T1n**, métrica **Información Mutua de Mattes** (apropiada para escenarios multimodales), transformación **rígida Euler3D** y un **100 %** de casos isotrópicos a 1 mm. Crucialmente, el EDA verifica que las cuatro modalidades por caso ya están coregistradas, por lo que el registro intra-sujeto es *redundante* y se plantea como un ejercicio **demostrativo** (perturbación rígida conocida $\rightarrow$ recuperación).

III. PREPROCESAMIENTO

Antes de toda segmentación se aplica un pipeline de limpieza de intensidades común a todos los métodos, encadenado en el orden:

1. **Filtro de Wiener** con kernel de tamaño 3 para atenuar ruido gaussiano sin penalizar bordes.
2. **Corrección de campo de sesgo N4** (Tustison *et al.* [4]) con factor de *shrink* = 4 para eliminar el sesgo lento de intensidad típico de RM.
3. **Normalización por percentiles**: recorte al intervalo $[p_0, p_{99.5}]$ y reescalado lineal a $[0, 1]$ por volumen, descartando los extremos sin eliminar señal anatómica relevante.

El volumen normalizado se almacena en `limpieza/<caso>/<caso>-t2f_limpio.npy` y constituye la entrada única para los cuatro métodos de segmentación de la Sección IV. La razón de aplicar la limpieza a FLAIR (t2f) es la conclusión del EDA: FLAIR es la modalidad con mayor separabilidad para el SNFH/tumor-completo.

IV. SEGMENTACIÓN CLÁSICA DEL TUMOR COMPLETO

Se implementaron cuatro familias clásicas de segmentación, todas operando sobre el mismo volumen FLAIR preprocesado y con el mismo objetivo: producir una máscara binaria del **tumor completo** (unión de NETC, SNFH, ET y RC, es decir, $\text{seg} > 0$).

IV-A. Métodos

Multi-binarización por Otsu con dos cortes y selección de la clase de mayor intensidad (*foreground* = tumor candidato).

Ajuste de una Gaussiana (GMM) sobre los vóxeles del cerebro enmascarado; la clase con mayor media se toma como candidata a tumor.

Creación de regiones automáticamente en el centro de ET. Se toma el *ground truth* del tumor completo y propagado a vecinos dentro de una banda de intensidad calibrada en torno a la intensidad de semilla.

Watershed sobre la magnitud del gradiente del volumen FLAIR, con marcadores derivados de mínimos regionales y de la propia máscara Otsu como restricción de *foreground*.

IV-B. Métricas y configuración experimental

La evaluación se realizó sobre los cinco casos demostrativos de la Tabla IV. Como verdad terreno se usó $seg > 0$ (tumor completo). Se reportan Dice, Jaccard y sensibilidad ($TP/(TP + FN)$) por método y caso.

IV-C. Resultados agregados

La Tabla V resume las métricas promediadas sobre los cinco casos. Otsu obtiene el mejor Dice agregado pero con un valor bajo (0,325); el crecimiento de regiones **falla completamente** (Dice $\approx 0,18$, sensibilidad 0,16). La Figura 6 ilustra el ranking de métodos.

Cuadro V

MÉTRICAS PROMEDIO SOBRE LOS 5 CASOS DEMOSTRATIVOS (OBJETIVO: TUMOR COMPLETO, MODALIDAD FLAIR).

Método	Dice	Jaccard	Sensibilidad
Otsu	0.325	0.255	0.583
Watershed	0.239	0.196	0.638
GMM	0.208	0.184	0.400
Crecimiento	0.179	0.162	0.163




Figura 6. Comparativa visual de métricas (Dice, Jaccard, sensibilidad) por método clásico sobre los 5 casos.

IV-D. Resultados por caso

El detalle por caso (Tabla VI) revela un patrón muy informativo: *los cuatro métodos rinden bien únicamente en el caso de tumor grande sin cavidad dominante* (02119-101, Dice $\geq 0,89$ para Otsu, GMM y crecimiento), y todos colapsan en presencia de cavidad de resección o ausencia total de ET.

Cuadro VI

DICE POR CASO Y MÉTODO (OBJETIVO TUMOR COMPLETO, FLAIR). CODIFICACIÓN: verde $DICE \geq 0,80$; amarillo 0,50–0,80; rojo $< 0,50$.

Caso	Otsu	GMM	Crecim.	Watershed
02827-100 (típico, RC dom.)	0.027	0.025	0.000	0.023
02119-101 (tumor grande)	0.896	0.924	0.896	0.905
02923-101 (tumor pequeño)	0.014	0.013	0.000	0.010
02514-102 (post-resección)	0.508	0.057	0.000	0.141
02859-100 (solo edema)	0.182	0.023	0.000	0.115

Las figuras 7–9 muestran mosaicos 2D del corte axial central con *ground truth* superpuesto y las cuatro segmentaciones lado a lado para tres de los cinco casos.




Figura 7. Caso BraTS-GLI-02119-101 (tumor grande): comparativa GT vs. Otsu, GMM, crecimiento de regiones y watershed sobre el volumen FLAIR preprocesado. Es el único caso donde los cuatro métodos producen Dice $> 0,89$.

BraTS-GLI-02827-100 — tumor completo (FLAIR) · GT vs métodos




Figura 8. Caso BraTS-GLI-02827-100 (típico, dominado por cavidad de resección): la hipointensidad de la RC en FLAIR rompe la hipótesis de un único modo brillante y todos los métodos fracasan.

BraTS-GLI-02923-101 — tumor completo (FLAIR) · GT vs métodos




Figura 9. Caso BraTS-GLI-02923-101 (tumor pequeño): la fracción tumor/encéfalo es tan baja que los métodos globales saturan en falsos positivos y el crecimiento sembrado en el centroide del GT no logra propagarse.

V. REGISTRO RÍGIDO DEMOSTRATIVO

El bloque de registro implementa un motor clásico de alineamiento volumen-volumen basado en **Información Mutua de Mattes** con una transformación **rígida Euler3D** (3 rotaciones + 3 traslaciones, 6 d.o.f.) y un esquema piramidal multi-resolución, todo sobre SimpleITK. Como el EDA estableció que las modalidades de BraTS ya están coregistradas, el experimento es **demostrativo**: se toma el volumen T1n original como *moving*, se le aplica una transformación rígida conocida y se mide la capacidad del motor para recuperarla.

V-A. Configuración

Los hiperparámetros se cargaron desde `parametros_usados.json` y se resumen en la Tabla VII.

Cuadro VII
PARÁMETROS DEL REGISTRO MATTES MI + EULER3D
MULTI-RESOLUCIÓN.

Parámetro	Valor
Modalidad fija/móvil	T1n
Métrica	Mattes Mutual Information
Bins del histograma (MI)	50
Fracción de muestreo	0.1 (seed=42)
Iteraciones máx. por nivel	150
Pirámide — <i>shrink</i>	[4, 2]
Pirámide — σ	[2, 1]
Optimizador	Gradient Descent Line Search
Inicialización	CenteredTransformInitializer (geom.)
Rotación perturbada (°)	(6,0, 4,0, -5,0)
Traslación perturbada (mm)	(5,0, -4,0, 3,0)

V-B. Métricas por caso

La Tabla VIII reporta las métricas de los tres casos registrados. **TRE** (*Target Registration Error*) se calcula sobre puntos de control distribuidos en el volumen y es la métrica más fiable; **Dice de cerebro** se calcula entre las máscaras del encéfalo de fijo y móvil antes/después del registro; **MSE** es el error cuadrático medio de intensidades; **MI final** es el valor de la métrica de Mattes al converger (más negativo = mejor).

Cuadro VIII
MÉTRICAS DE REGISTRO POR CASO (3 CASOS). SUB-VÓXEL EN TODOS LOS TRE.

Caso	TRE (mm)	Dice antes	Dice desp.	MSE antes	MSE desp.	MI final	Tiempo (s)
02827-100	0.0021	0.907	0.963	15731.86	110.81	-1.196	107.0
02119-101	0.0029	0.913	0.963	1793.01	35.69	-1.141	90.5
02923-101	0.0058	0.915	0.965	215758.45	4325.13	-1.263	88.7
Promedio	0.0036	0.912	0.964	—	—	-1.200	95.4

V-C. Visualización

Las Figuras 10–12 muestran, para cada caso, los tres volúmenes —fijo (referencia), móvil desalineado y móvil recuperado— en una vista axial central. La Figura 13 muestra las curvas de convergencia de la métrica Mattes por iteración y por nivel piramidal en los tres casos.




Figura 10. Caso BraTS-GLI-02119-101: *fija* (izq.), *desalineado* (centro) y *recuperado* (der.) tras el registro rígido. TRE residual = 0,0029 mm.



Figura 11. Caso BraTS-GLI-02827-100: TRE residual = 0,0021 mm, el mejor de los tres.




Figura 12. Caso BraTS-GLI-02923-101: TRE residual = 0,0058 mm, todavía sub-vóxel.




Figura 13. Curvas de convergencia de la métrica de Mattes (negativa de la información mutua) por iteración y por nivel piramidal, para los tres casos.

VI. DISCUSIÓN Y LIMITACIONES

VI-A. Por qué fallan los métodos clásicos en el tumor completo

La Tabla VI expone un patrón inequívoco: los cuatro métodos basados únicamente en intensidad sólo rinden bien en el caso 02119-101, donde la sub-región dominante es la SNFH (~ 174 k vóxeles, hiperintensa en FLAIR). En los otros cuatro casos hay siempre un componente sustancial de RC —por ejemplo 43,8 k vóxeles de RC frente a 13,2 k de SNFH en 02827-100, o 88,8 k frente a 62,3 k en 02514-102— y la RC es **hipointensa** en FLAIR, indistinguible del ventrículo o del líquido cefalorraquídeo.

En consecuencia, el objetivo $seg > 0$ contiene simultáneamente vóxeles brillantes (SNFH/ET) y vóxeles oscuros (RC) que no pueden separarse con un único umbral global —ni con

una mezcla Gaussiana de pocos componentes que asigne la RC a la misma clase que SNFH—. El crecimiento de regiones, sembrado en el centroide del GT, queda atrapado en una sola sub-región: si la semilla cae en RC, no propaga a SNFH y viceversa. La sensibilidad media de 0,163 de este método refleja esta fragmentación.

El watershed obtiene la mayor sensibilidad media (0,638) pero su precisión es la peor a igualdad de Dice, evidenciando sobre-segmentación. La conclusión práctica es robusta: **los métodos clásicos basados en intensidad son insuficientes para segmentar el tumor completo post-tratamiento** en BraTS 2024 GLI. Resolver este problema requiere o bien información de forma (atlas, modelos estadísticos), multi-modalidad explícita (combinar FLAIR + T1c) o aprendizaje supervisado, ninguna de las cuales pertenece al alcance del presente proyecto.

VI-B. Limitaciones del registro demostrativo

El registro alcanza un TRE residual sub-vóxel ($\leq 0,006$ mm) en los tres casos y eleva el Dice de cerebro de 0,91 a 0,96, lo que confirma la corrección del motor. No obstante, caben dos matices:

1. La validación es *intra-sujeto* y *sintética*: la transformación recuperada es la misma que se aplicó artificialmente, lo que sobreestima el desempeño frente a un escenario clínico real con diferencias inter-sujeto.
2. La transformación es *rígida* y no compensa deformaciones locales (desplazamiento de masa, atrofia, cavidad de resección). Para esos escenarios se requeriría un registro deformable (B-spline, Demons, SyN).

VII. REPRODUCIBILIDAD

- **Modalidad de segmentación:** T2-FLAIR (t_{2f}).
- **Objetivo:** tumor completo ($seg > 0$).
- **Pipeline de limpieza:** Wiener (size=3) $\rightarrow$ N4 (shrink=4) $\rightarrow$ normalización por percentiles ($p_{0,5}, p_{99,5}$).
- **Métodos clásicos:** Otsu multinivel (2 cortes), GMM (3 componentes), ConnectedThreshold (semilla en el centroide del GT), watershed por marcadores sobre magnitud del gradiente.
- **Modalidad de registro:** T1n.
- **Métrica/transformación:** Mattes MI (50 bins, muestreo 0,1) + Euler3D, multi-resolución shrink [4, 2] / σ [2, 1], máximo 150 iteraciones por nivel, inicialización CenteredTransformInitializer (geometría).
- **Perturbación:** rotación $(6,4, -5)^\circ$ y traslación $(5, -4, 3)$ mm.
- **Casos demostrativos:** 02119-101, 02827-100, 02923-101, 02514-102, 02859-100 (segmentación) y 02119-101, 02827-100, 02923-101 (registro).
- **Código y artefactos:** <https://github.com/AbelAlbuez/medical-image-processing>.

VIII. CONCLUSIONES Y TRABAJO FUTURO

El proyecto cubre las tres tareas requeridas —EDA, segmentación y registro— sobre BraTS 2024 GLI sin recurrir a aprendizaje profundo. El EDA cuantitativo justifica

la elección de FLAIR para segmentar el tumor completo (mayor separabilidad de SNFH frente a tejido sano) y fija parámetros operativos para el registro. La segmentación clásica obtiene resultados aceptables **únicamente cuando la sub-región dominante es la SNFH hiperintensa**; en presencia de cavidad de resección o tumor pequeño, todos los métodos colapsan, con un Dice agregado máximo de 0,33 (Otsu). Este resultado es el hallazgo central del proyecto y constituye una motivación empírica clara para el uso de métodos basados en aprendizaje en contextos clínicos reales. El bloque de registro, en cambio, recupera con precisión sub-vóxel una perturbación rígida conocida en los tres casos, validando la implementación del motor Mattes MI + Euler3D multi-resolución.

Trabajo futuro: (i) extender la segmentación a estrategias multi-modalidad (combinaciones FLAIR + T1c) y a operadores morfológicos para imponer compacidad; (ii) reemplazar el crecimiento de regiones por un *level-set* con término de forma; (iii) probar un registro deformable (Demons o B-spline) para los casos con masa significativa; y (iv) ampliar la cohorte de evaluación a la totalidad del subset GLI.

REFERENCIAS

- [1] U. Baid *et al.*, “The RSNA-ASNR-MICCAI BraTS 2021 benchmark on brain tumor segmentation and radiogenomic classification,” *arXiv:2107.02314*, 2021.
- [2] B. C. Lowekamp, D. T. Chen, L. Ibáñez and D. Blezek, “The design of SimpleITK,” *Frontiers in Neuroinformatics*, vol. 7, p. 45, 2013.
- [3] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [4] N. J. Tustison *et al.*, “N4ITK: Improved N3 bias correction,” *IEEE Trans. Med. Imag.*, vol. 29, no. 6, pp. 1310–1320, 2010.
- [5] D. Mattes, D. R. Haynor, H. Vesselle, T. K. Lewellyn and W. Eubank, “PET-CT image registration in the chest using free-form deformations,” *IEEE Trans. Med. Imag.*, vol. 22, no. 1, pp. 120–128, 2003.
- [6] L. Vincent and P. Soille, “Watersheds in digital spaces: an efficient algorithm based on immersion simulations,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 6, pp. 583–598, 1991.