

Segmentación clásica del tumor realzante (ET) en T1c sobre BraTS 2024 GLI: alcances y límites de los métodos sin aprendizaje profundo

Abel Albuez, Victoria Acero y Santiago Gil

Maestría en Ingeniería de Sistemas y Computación

Pontificia Universidad Javeriana, Bogotá D.C., Colombia

Procesamiento de Imágenes Médicas 2026

Repositorio: <https://github.com/AbelAlbuez/medical-image-processing>

Resumen—Se aborda la segmentación automática del *tumor realzante* (*enhancing tumor*, ET; etiqueta 3 de BraTS) sobre la modalidad T1 con contraste (T1c) empleando exclusivamente métodos clásicos de SIMPLEITK, sin aprendizaje profundo. Un análisis exploratorio sobre 100 casos de *BraTS 2024 GLI Post-Treatment* (78 con ET presente) muestra que T1c es la modalidad más separable para el realce (razón discriminante de Fisher mediana de 1,32 frente a 0,47 en T2-FLAIR). Tras una limpieza de T1c (Wiener $\rightarrow$ N4 $\rightarrow$ normalización por percentiles) se evalúan cuatro métodos —Otsu multinivel, crecimiento de regiones, *watershed* por marcadores y mezcla de gaussianas multimodal— sobre nueve casos. El hallazgo central es que los métodos clásicos por intensidad son insuficientes para el ET: ningún método supera un Dice medio de 0,50, y el mejor —crecimiento de regiones, con Dice medio de 0,320— es apenas “el menos malo”. La mezcla de gaussianas multimodal *sobre-segmenta* (sensibilidad 0,63 pero Dice 0,094), evidenciando que añadir modalidades no compensó la falta de un modelo de forma. Complementariamente, un registro rígido por información mutua de Mattes recupera una perturbación conocida con un error de registro objetivo (TRE) medio de 0,007 mm, y una reconstrucción 3D por *marching cubes* valida la escala física de las mallas.

Index Terms—BraTS 2024 GLI, tumor realzante, T1c, segmentación clásica, SimpleITK, información mutua de Mattes, *marching cubes*.

I. PROBLEMA, JUSTIFICACIÓN Y OBJETIVOS

Los gliomas son los tumores cerebrales primarios más frecuentes en adultos y su seguimiento por resonancia magnética (RM) es central en la práctica clínica [14], [15]. En el escenario *post-tratamiento*, el *tumor realzante* (ET) —tejido que capta contraste en T1c— es el marcador imagenológico de actividad tumoral residual o recurrente y un sustituto habitual de la respuesta a la terapia [16]. Delimitarlo manualmente es costoso y poco reproducible: la variabilidad inter- e intra-observador de la segmentación experta es alta incluso entre radiólogos especializados [13], lo que justifica el interés por métodos automáticos.

El reto BraTS 2024 GLI Post-Treatment [1], [9] introduce por primera vez la *cavidad de resección* (RC) como clase explícita, alterando las hipótesis de intensidad sobre las que descansan los métodos clásicos: el ET, lejos de ser un objeto brillante y compacto, suele aparecer como un *anillo* delgado y heterogéneo alrededor de una cavidad oscura. Este escenario es

un banco de pruebas natural para preguntar hasta dónde llegan los métodos clásicos sin el apoyo del aprendizaje profundo.

Este trabajo se restringe deliberadamente a **métodos clásicos** (sin aprendizaje profundo) implementados sobre ITK/SIMPLEITK [2], con el objetivo de caracterizar honestamente sus *alcances* y *límites* para el ET. Los objetivos concretos son: (i) un análisis exploratorio (EDA) que justifique la modalidad objetivo; (ii) una limpieza de T1c; (iii) un registro rígido demostrativo por información mutua; (iv) la segmentación del ET con cuatro métodos clásicos; y (v) una reconstrucción 3D de las máscaras para inspección visual. La canalización completa se organiza en seis módulos reproducibles y se ejecuta leyendo los datos directamente desde los archivos comprimidos del reto.

II. ESTADO DEL ARTE

La literatura reciente sobre segmentación de gliomas en BraTS está dominada por el aprendizaje profundo, en particular por la familia NNU-NET; el contexto clásico-híbrido es minoritario pero existe. A continuación se resumen tres trabajos representativos que enmarcan este estudio.

Györfi et al. (2021) [12]. Proponen una canalización *clásico-híbrida* para BraTS basada en normalización de histogramas, un atlas que codifica la *desviación de la normalidad* y un ensamble de árboles (125 árboles en bosques aleatorios) sobre características multimodales por vóxel. El trabajo reporta un Dice global cercano al 86 % con un registro afín previo en aproximadamente 58 s de CPU, posicionando los métodos basados en intensidad y atlas como una alternativa competitiva en hardware modesto. No obstante, su evaluación es anterior a la introducción de la cavidad de resección y se centra en el tumor completo, no en el realzante por sí solo.

Baig et al. (2024) [10]. Estudian explícitamente el escenario *post-tratamiento* con NNU-NET 3D sobre BraTS 2023/2024, con cuatro modalidades (T1n, T1c, T2w, T2-FLAIR) y cinco etiquetas (incluyendo RC). Comparan tres entrenamientos —redes pre-tratamiento, post-tratamiento y combinada— y reportan Dice por sub-región entre 0,82 y 0,94. Su hallazgo más relevante es que la red *combinada* reduce los falsos positivos

sobre la cavidad de resección, evidenciando que el caso postquirúrgico exige información de contexto que no está en una sola modalidad.

Luque et al. (2024) [11]. Aplican NNU-NET con *Cross Pseudo Supervision* (semi-supervisado) para estimar la *extensión de la resección* (EOR) en gliomas. Reportan un Dice externo de 0,52 sobre imágenes no vistas y, al usar la segmentación para clasificar el grado de resección, alcanzan precisión 0,90 y sensibilidad 0,87. El trabajo confirma que la tarea *anatómica* es difícil incluso para redes profundas modernas, pero que los mapas resultantes ya son útiles para la decisión clínica.

Hueco que llena este trabajo. El estado del arte está dominado por aprendizaje profundo y, en el escenario post-tratamiento, ningún trabajo conocido por los autores cuantifica el *techo* de los métodos puramente clásicos basados en intensidad para el ET. Este informe no compete con NNU-NET: caracteriza su *línea de base* sin aprendizaje profundo, incluyendo post-proceso, ensambles y un *ablation* del preprocesamiento, y muestra que el límite es estructural (forma del realce) y no de umbral.

III. DESCRIPCIÓN DE LA BASE DE DATOS

Se emplea el subconjunto *BraTS 2024 GLI Post-Treatment* [9]. Es la *primera* edición del reto BraTS centrada explícitamente en el escenario post-tratamiento; su novedad principal frente a ediciones previas es la inclusión de la *cavidad de resección* (RC) como clase distinta. La cohorte completa abarca del orden de ~ 2200 pacientes adultos provenientes de siete instituciones, con volúmenes en formato NIFTI (.nii.gz), cuatro modalidades de resonancia magnética por caso ya *co-registradas* a un espacio común y *esqueletizadas* (*skull-stripping* aplicado), y una segmentación experta consensuada por radiólogos. Las modalidades son T1n (T1 nativo), T1c (T1 con contraste de gadolinio), T2w y T2-FLAIR; las cuatro etiquetas anatómicas son 1=NETC (núcleo no realzante), 2=SNFH (edema/FLAIR hiperintenso), 3=ET (realce) y 4=RC (cavidad de resección). **El objetivo de este trabajo es la etiqueta 3 (ET).** Los volúmenes se leen directamente desde los .zip del reto, extrayendo puntualmente cada par caso/modalidad sin descomprimir el archivo completo. Se procesa un subconjunto de 100 casos del conjunto de entrenamiento (el que posee *seg*); de ellos, **78 contienen ET**.

La Tabla I resume la geometría, homogénea en todo el subconjunto (verificada por el EDA).

Cuadro I
GEOMETRÍA DEL SUBCONJUNTO (UNIFORME EN LOS 100 CASOS).

Propiedad	Valor
Dimensiones (vóxeles)	$182 \times 218 \times 182$
Espaciado	$1,0 \times 1,0 \times 1,0$ mm (isotrópico)
Casos procesados	100
Casos con ET (<i>seg</i> =3)	78

III-A. Separabilidad del ET por modalidad

Para justificar la modalidad objetivo se midió la separabilidad entre los vóxeles de ET y el tejido cerebral sano por modalidad, mediante la razón discriminante de Fisher (FDR) y la distancia de Bhattacharyya (Tabla II, Fig. 1). **T1c es claramente la modalidad más separable para el ET** (FDR mediano 1,32, casi el triple que T2-FLAIR), lo que confirma la elección de T1c como soporte de la segmentación.

Cuadro II
SEPARABILIDAD ET VS. TEJIDO SANO POR MODALIDAD (MEDIANA Y MEDIA SOBRE LOS 78 CASOS CON ET).

Modalidad	FDR mediana	FDR media	Bhatt. med.	Bhatt. media
T1c	1,317	1,461	0,375	0,403
T2-FLAIR	0,472	0,818	0,153	0,238
T2w	0,341	0,667	0,178	0,250
T1n	0,099	0,227	0,126	0,177




Figura 1. Separabilidad ET vs. tejido sano por modalidad (FDR y Bhattacharyya medianos). T1c domina, justificando su uso para ET.

III-B. Umbral de Otsu y casos demostrativos

El umbral alto de Otsu ($n=3$) sobre T1c en escala cruda tiene una mediana de 3120 y un rango de 352 a 6435 entre casos (Fig. 2), lo que evidencia una fuerte variabilidad inter-caso de la intensidad y motiva la normalización del módulo siguiente. El volumen de ET tiene una mediana de 4814 mm^3 (rango $66\text{--}87\,993 \text{ mm}^3$). A partir de esta distribución se seleccionaron automáticamente casos demostrativos que cubren el rango de tamaño de ET más un caso *sin* ET (Tabla III, Fig. 3).

Cuadro III
CASOS DEMOSTRATIVOS SELECCIONADOS POR EL EDA.

Categoría	Caso	Volumen ET (mm^3)
Pequeño	BraTS-GLI-00529-100	501
Mediano	BraTS-GLI-02063-102	4 812
Grande	BraTS-GLI-02060-100	19 975
Sin ET	BraTS-GLI-00005-100	0

IV. DESCRIPCIÓN DE LA LÍNEA DE PROCESAMIENTO

La canalización está organizada en **seis módulos numerados**, cada uno con su propio reporte HTML, sus figuras y sus archivos de salida (CSV/JSON), y todos reproducibles desde PYTHON 3.11 con SIMPLEITK [2]:




Figura 2. Distribución del umbral alto de Otsu ($n=3$) en T1c por caso (escala cruda); la dispersión justifica normalizar.




Figura 3. Casos demostrativos: T1c con el ET (contorno rojo) en el corte del centroide. El caso sin ET no presenta realce.

1. **EDA.** Caracterización de geometría, intensidades y separabilidad por modalidad sobre 100 casos; selecciona T1c como modalidad objetivo y los casos demostrativos (Sec. III).
2. **Limpieza T1c.** Reducción de ruido con filtro de Wiener, corrección del campo de sesgo con N4 [4] y normalización por percentiles (Sec. V).
3. **Registro rígido.** Recuperación demostrativa de una perturbación rígida conocida con información mutua de Mattes [5] sobre transformación Euler3D multi-resolución (Sec. VI).
4. **Segmentación clásica del ET.** Otsu multinivel, crecimiento de regiones, *watershed* por marcadores y mezcla de gaussianas multimodal (Sec. VII), incluyendo el hallazgo sobre la semilla (cavidad de resección → ET más brillante, $\alpha = 0,65$) y el ensamble por unión con post-proceso.
5. **Reconstrucción 3D.** Mallas por *marching cubes* [8] de la predicción y el *ground truth* para validación de escala (Sec. VIII).
6. **Visualización.** Mosaicos 2D (axial/coronal/sagital) y un visor 3D web autocontenido para inspección visual.

Las tres reglas transversales que se respetan a lo largo de la canalización son: (i) *el ground truth solo ubica la semilla y evalúa, nunca construye la máscara*; (ii) los hiperparámetros (umbral relativo α , radio de cierre, etc.) son *globales*, ajustados sobre el promedio de los casos y no por caso; (iii) la lectura es directa desde .zip, sin copiar el dataset al disco.

V. PREPROCESAMIENTO (T1C)

Sobre T1c se aplica, en este orden: (1) reducción de ruido con filtro de Wiener adaptativo (ventana 3); (2) corrección del campo de sesgo con N4 [4] (*shrink* 4); y (3) normalización por percentiles [0,5, 99,5] a [0,1] dentro del cerebro. El denoise precede a N4 para evitar que el ruido se modele como estructura, y la normalización al final fija la escala entre casos (Tabla I mostró que la geometría es homogénea, por lo que no se requiere remuestreo).

La Tabla IV resume, para los nueve casos de la segmentación, la intensidad antes (escala cruda) y después de la limpieza; todos los volúmenes quedan en [0,1], lo que homogeneiza la escala dispar de partida (medias crudas de 335 a 3096). La Fig. 4 ilustra el efecto.

Cuadro IV
ESTADÍSTICAS DE INTENSIDAD DENTRO DEL CEREBRO ANTES Y DESPUÉS DE LA LIMPIEZA (9 CASOS DE SEGMENTACIÓN).

Caso	ET	media _{orig}	p99 _{orig}	media _{limp}	std _{limp}
02063-106	sí	359,2	669,0	0,350	0,117
00529-100	sí	1973,7	3299,2	0,507	0,131
02062-100	sí	385,9	683,0	0,384	0,108
02063-102	sí	334,7	616,2	0,365	0,112
00498-100	sí	1651,9	2986,4	0,451	0,114
00463-101	sí	2133,1	4300,3	0,305	0,124
02060-100	sí	690,8	1358,0	0,340	0,128
00046-101	sí	3096,0	7022,2	0,280	0,128
00005-100	no	2081,6	4334,2	0,374	0,103




Figura 4. Limpieza de T1c (caso 02060-100): original, resultado (Wiener→N4→normalización) e histograma cerebral.

VI. REGISTRO RÍGIDO DEMOSTRATIVO

Se incluye una demostración cuantitativa de registro rígido por información mutua de Mattes [5] con transformación Euler3D y esquema multi-resolución. Tomando T1c como volumen fijo, se le aplica una perturbación rígida conocida (rotación (6, 4, -5)°, traslación (5, -4, 3) mm) para generar un volumen desalineado, y se registra para recuperarla. La métrica se configura con 50 *bins*, muestreo aleatorio del 10 % (semilla 42), inicialización por geometría (*CenteredTransformInitializer*), optimizador *gradient descent line search*, factores de reducción [4, 2] y sigmas [2, 1].

Como la perturbación es conocida, el error de registro objetivo (TRE) mide directamente la calidad: en los cuatro casos es *sub-vóxel* ($\approx 0,007$ mm), y el Dice del cerebro mejora de 0,906 a 0,963 (Tabla V, Fig. 5). El registro recupera con

precisión la transformación impuesta; es el único bloque del trabajo con un resultado cuantitativamente sólido, en contraste con la segmentación.




Figura 5. Arriba: fija, desalineada y recuperada (caso 02060-100). Abajo: convergencia de la información mutua de Mattes; la métrica descende y se estabiliza.

VII. SEGMENTACIÓN CLÁSICA DEL ET

Sobre T1c limpio se evaluaron cuatro métodos clásicos, con el ET ($seg==3$) como referencia: **Otsu** multinivel ($n=3$ [3], clase más brillante); **crecimiento de regiones**; **watershed** por marcadores [6]; y **mezcla de gaussianas** (GMM [7]) *multimodal* (T1c+T2w+T2-FLAIR), incluida como comparación. Se usaron nueve casos: ocho con ET (cubriendo el rango de volumen) y uno sin ET (robustez).

VII-A. Hallazgo: la semilla del crecimiento de regiones

El comportamiento del crecimiento de regiones reveló un problema específico del escenario post-tratamiento que merece destacarse. La semilla natural —el centroide del ET— **cae dentro de la cavidad de resección** (label 4), que es *oscura* en T1c, porque el ET forma típicamente un *anillo* alrededor de dicha cavidad. Sembrado ahí, el crecimiento por intensidad parte de tejido oscuro y se “fuga” hacia el resto del cerebro, produciendo máscaras degeneradas (Dice ≈ 0). La solución adoptada es sembrar en el **vóxel de ET más brillante** y crecer por una *ventana brillante* $[\alpha I_{semilla}, máx]$ con $\alpha = 0,65$ (calibrado por barrido, Tabla VIII). La etiqueta experta solo aporta la *ubicación* de la semilla (inicialización semi-automática); la máscara final surge del crecimiento sobre T1c, no de la copia del *ground truth*.

VII-B. Resultados agregados

La Tabla VI promedia las métricas sobre los ocho casos con ET. El crecimiento de regiones obtiene el mejor Dice medio, pero **este valor (0,320) debe leerse como “el menos malo”, no como un éxito**: ningún método alcanza siquiera

0,50 de Dice. La GMM multimodal exhibe la mayor sensibilidad (0,63) pero el peor Dice (0,094), porque etiqueta como tumor un cúmulo amplio (edema, vasos) y *sobre-segmenta*; su especificidad (0,965) es la más baja de las cuatro. La Fig. 6 resume el orden y la Fig. 7 contrasta visualmente el mejor método con la sobre-segmentación de la GMM.




Figura 6. Dice medio por método. RegionGrowing es el mejor, pero todos quedan muy por debajo de un Dice útil.




Figura 7. Caso 02060-100. Arriba: crecimiento de regiones (predicción roja, GT cian). Abajo: GMM multimodal, que sobre-segmenta ampliamente.

VII-C. Resultados por caso

La Tabla VII muestra el Dice por caso (semáforo: verde $\geq 0,80$, amarillo $0,50-0,80$, rojo $< 0,50$). El predominio del rojo es, en sí mismo, el resultado: la inmensa mayoría de las combinaciones caso/método quedan por debajo de 0,50. Además, la **dispersión es alta y no hay un ganador estable**: aunque RegionGrowing gana en promedio, Watershed supera al resto en 02063-106 y 00463-101 (único valor amarillo, 0,618), y Otsu es competitivo en los casos de ET grande. El caso sin ET (00005-100) no admite Dice (N/A), pero los cuatro métodos producen máscaras no vacías (falsos positivos), lo que ilustra que ningún método clásico “se abstiene” ante la ausencia de realce.

Cuadro V
REGISTRO RÍGIDO DEMOSTRATIVO (PERTURBACIÓN CONOCIDA → RECUPERACIÓN). TRE SUB-VÓXEL Y MEJORA DEL DICE DE CEREBRO EN LOS CUATRO CASOS.

Caso	TRE (mm)	Dice cerebro antes	Dice cerebro después	MSE antes	MSE después	MI final	Tiempo (s)
00529-100	0,0064	0,9076	0,9633	205 707	3 109	−1,029	8,1
02063-102	0,0095	0,9110	0,9646	5 635	188	−1,000	6,7
02060-100	0,0082	0,9196	0,9621	27 553	1 106	−0,982	7,2
00005-100	0,0054	0,8865	0,9607	242 177	3 676	−0,765	7,0
Promedio	0,0074	0,9062	0,9627	120 268	2 020	−0,944	7,25

Cuadro VI
RESUMEN POR MÉTODO (DICE MEDIO SOBRE 8 CASOS CON ET). NINGÚN MÉTODO SUPERA 0,50.

Método	Multim.	Dice	Jaccard	Sensib.	Especif.
RegionGrowing	no	0,320	0,196	0,362	0,999
Watershed	no	0,213	0,132	0,133	0,999
Otsu	no	0,164	0,097	0,516	0,995
GMM multimodal	sí	0,094	0,052	0,630	0,965

Cuadro VII
DICE POR CASO Y MÉTODO. SEMÁFORO: VERDE $\geq 0,80$, AMARILLO 0,50–0,80, ROJO $< 0,50$.

Caso	Otsu	RegionGrow.	Watershed	GMM mult.
02063-106	0,007	0,257	0,344	0,003
00529-100	0,009	0,407	0,155	0,000
02062-100	0,023	0,217	0,088	0,026
02063-102	0,170	0,283	0,255	0,000
00498-100	0,136	0,157	0,096	0,094
00463-101	0,207	0,280	0,618	0,146
02060-100	0,368	0,451	0,110	0,265
00046-101	0,395	0,509	0,035	0,217
00005-100 (sin ET)	N/A	N/A	N/A	N/A

VII-D. Calibración del crecimiento de regiones

La Tabla VIII reporta el barrido (*itertools.product*) del umbral relativo α y el radio del cierre morfológico. El óptimo medio se alcanza en ($\alpha = 0,65$, cierre = 3) con Dice 0,341; la configuración por defecto usa cierre 1 (0,320). La mejora por ajuste es marginal, coherente con el límite de fondo del método.

Cuadro VIII
BARRIDO DEL CRECIMIENTO DE REGIONES (DICE MEDIO SOBRE LOS CASOS CON ET).

α	cierre	Dice	α	cierre	Dice
0,55	1	0,266	0,65	3	0,341
0,55	2	0,269	0,75	1	0,287
0,55	3	0,269	0,75	2	0,306
0,65	1	0,320	0,75	3	0,322
0,65	2	0,331			

VII-E. Estrategias de mejora y análisis de robustez

Se exploró si técnicas clásicas de post-proceso elevan el Dice del ET, manteniendo la regla anti-fuga: el GT solo ubica la semilla y evalúa, nunca construye la máscara ni ajusta

parámetros por caso (el radio de cierre y α son globales, por barrido sobre el promedio). Se evaluaron cuatro variantes por método: *base*, *+morfolología* (cierre + selección de componente conexo), *+sustracción* (método sobre $S = \text{clip}(T1c - T1n, 0)$, con *histogram matching* de T1n a T1c) y la combinación de ambas. Tres hallazgos:

(a) **Sin apertura morfológica.** La apertura destruía el ET pequeño (lo dejaba en Dice 0,000); eliminarla y conservar solo *cierre + componente conexo* evita ese colapso.

(b) **Componente anclado a la semilla.** Quedarse con el componente conexo *más grande* falla cuando el método no aísla el ET: en Otsu, el blob dominante es tejido sano y el solape con el ET es nulo (Dice 0,000 en cuatro casos). Anclar el componente al vóxel de ET más brillante *rescata* esos casos (Tabla X). El anclaje solo afecta a Otsu: el crecimiento de regiones y el *watershed* ya producen un único componente sembrado en el ET, y la GMM produce un único blob (su semilla a veces cae fuera, con *fallback* al mayor).

(c) **La sustracción T1c–T1n no mejoró** (resultado honesto, en contra de la intuición): rebaja el Dice medio de todos los métodos respecto a su base.

La Tabla IX resume el Dice medio por método y variante con el componente anclado, y la Fig. 8 lo ilustra.

Cuadro IX
DICE MEDIO POR MÉTODO Y VARIANTE (POST-PROCESO CON COMPONENTE ANCLADO A LA SEMILLA). NINGÚN MÉTODO ALCANZA 0,50.

Método	base	+morf.	+sust.	+sust+morf.
Otsu	0,164	0,353	0,117	0,326
RegionGrowing	0,320	0,342	0,243	0,267
Watershed	0,213	0,223	0,187	0,197
GMM multimodal	0,094	0,080	—	—

Cuadro X
RESCATE DE OTSU (+MORFOLOGÍA) AL ANCLAR EL COMPONENTE A LA SEMILLA: LOS CUATRO CASOS QUE EL COMPONENTE *mayor* DEJABA EN 0,000.

Caso	componente mayor	componente anclado
02063-106	0,000	0,181
00529-100	0,000	0,322
02062-100	0,000	0,413
02063-102	0,000	0,638




Figura 8. Arriba: Dice por método y variante (línea roja = 0,5). Abajo: Otsu en 02062-100 — base, componente mayor (selecciona tejido sano, Dice 0,000) y componente anclado a la semilla (verde), que recupera el realce.

VII-E0a. Ensemble de métodos: Como las predicciones ancladas de Otsu, crecimiento de regiones y *watershed* fallan en casos distintos, se combinaron por unión, voto de mayoría e intersección, aplicando el mismo post-proceso anclado a la máscara fusionada (*union_post*). La unión con post-proceso es la mejor estrategia global (Tabla XI): **Dice 0,370** (sensibilidad media 0,63, especificidad 0,997), por encima del mejor individual (0,353). El voto y la intersección sacrifican sensibilidad y bajan el Dice.

Cuadro XI

ENSAMBLE DE LOS MÉTODOS ANCLADOS (DICE MEDIO). LA UNIÓN CON POST-PROCESO ANCLADO SUPERA AL MEJOR MÉTODO INDIVIDUAL; NINGÚN ENSAMBLE ALCANZA 0,50.

Estrategia	Dice medio
Unión + post-proceso	0,370
Unión (sin post)	0,369
Otsu anclado (individual)	0,353
RegionGrowing anclado (indiv.)	0,342
Voto de mayoría	0,334
Intersección	0,204

VII-E0b. Histéresis y Otsu de dos clases (no mejoran): Se probó un umbral doble por histéresis (semilla alta, crecimiento hasta un nivel bajo) y un Otsu de dos clases. La histéresis eleva la sensibilidad media a 0,75 pero el Dice *cae* a 0,209 por fugas hacia tejido sano; el Otsu de dos clases se fuga masivamente en 7 de 9 casos (especificidad $\approx 0,80$, >1 M de vóxeles predichos) y colapsa a 0,084. Ninguna supera al ensemble; confirman que el límite no es de *umbral* sino estructural.

VII-E0c. Análisis de robustez: ablation de la limpieza: Para descartar que el preprocesamiento (filtro de Wiener, N4,

normalización) atenuara el realce fino y limitara el Dice, se repitió la segmentación variando solo la entrada: **E1** crudo, **E2** solo N4, **E3** N4 + normalización (sin Wiener) y **E4** pipeline completo. Para cada entrada se midió el Dice (estrategias Otsu anclado y unión+post) y la separabilidad ET frente a tejido sano mediante la razón discriminante de Fisher (FDR) y la distancia de Bhattacharyya (Tabla XII, Fig. 9).

Cuadro XII

ABLATION DE LA LIMPIEZA. EL DICE Y LA SEPARABILIDAD (FDR, BHATTACHARYYA) DEL ET *crecen* DE LA ENTRADA CRUDA (E1) A LA LIMPIA COMPLETA (E4): LA LIMPIEZA AYUDA.

Entrada	Otsu anc.	Unión+post	FDR	Bhatt.
E1 crudo	0,264	0,278	1,21	0,328
E2 N4	0,333	0,339	1,56	0,448
E3 N4+norm (sin Wiener)	0,311	0,314	1,72	0,496
E4 completo	0,353	0,370	1,80	0,498




Figura 9. Arriba: Dice por estrategia de ensemble (línea roja = 0,5). Abajo: ablation de la limpieza — el Dice (izq.) y la separabilidad FDR/Bhattacharyya (der.) suben monótonamente de E1 (crudo) a E4 (completo).

El ablation arroja dos conclusiones nítidas. (i) *La limpieza ayuda, no daña*: el Dice sube +0,092 de E1 a E4 y la separabilidad crece de forma monótona (FDR 1,21 $\rightarrow$ 1,80), siendo N4 el paso de mayor salto; el filtro de Wiener no atenúa el realce ($E4 > E3$) y la normalización tampoco ($E4 > E1$). (ii) *El techo es estructural*: aun con la entrada más separable posible (E4, FDR 1,80), el Dice se estanca en 0,370 $\ll$ 0,50. El límite lo impone la *forma* del ET —anillo delgado, heterogéneo, post-resección— no el preprocesamiento, que queda así validado.

VII-E0d. Evolución del mejor Dice y lectura honesta:

El recorrido completo (Tabla XIII) muestra que cada estrategia de post-proceso aporta ganancias marginales: de 0,320 (base) a 0,370 (ensemble), +0,050 **tras un post-proceso exhaustivo**, con un solo caso de ocho cruzando 0,50. La histéresis no mejora y el ablation confirma que la limpieza es beneficiosa y el techo es estructural. La conclusión se refuerza: para el ET,

los métodos clásicos son insuficientes y el problema exige información de *forma* o aprendizaje.

Cuadro XIII
EVOLUCIÓN DEL MEJOR DICE MEDIO A LO LARGO DE LAS ESTRATEGIAS DE MEJORA. NINGUNA CRUZA 0,50.

Estrategia	Mejor Dice	Nota
Base (RegionGrowing)	0,320	punto de partida
+Morfología (sin apertura)	0,342	la apertura destruía el ET pequeño
+Componente anclado	0,353	rescata Otsu (4 casos de 0,000 a 0,18–0,64)
Ensamble unión+post	0,370	mejor global (sens. 0,63)
Histéresis / Otsu 2-clases	—	no mejora (fugas)

VIII. RECONSTRUCCIÓN 3D

Para inspección visual se generaron mallas por *marching cubes* [8] del ET predicho (crecimiento de regiones) y del *ground truth*, con el espaciado físico aplicado y suavizado de Taubin, exportadas en OBJ y GLB; un visor web autocontenido (Three.js local) permite superponerlas en la exposición. La Tabla XIV reúne las métricas.

Dos lecturas. Primero, la **validación de escala es correcta**: el volumen de la malla GT reproduce el volumen de ET del EDA en el mismo orden de magnitud (p. ej. caso 02060-100, 19 266 vs. 19 975 mm³; caso 00046-101, 25 685 vs. 25 306 mm³), lo que confirma una geometría física consistente. Segundo, la **distancia media superficie-superficie entre predicción y GT (2,6 a 42,7 mm) no valida la predicción**; al contrario, cuantifica cuánto se *aleja* la malla predicha del GT en los casos difíciles (p. ej. 00498-100, donde la predicción multiplica por seis el volumen del GT y la distancia asciende a 42,7 mm). La reconstrucción 3D es, por tanto, una herramienta de inspección y de validación de escala, no una medida de acierto.




Figura 10. Mallas ET predicho (naranja) vs. GT (verde). Izquierda: 02060-100 (solape razonable). Derecha: 00498-100, donde la predicción sobre-segmenta y se aleja del GT.

IX. DISCUSIÓN Y LIMITACIONES

Por qué fallan los métodos clásicos en el ET. El ET no es un objeto “brillante y compacto” separable por intensidad: es un anillo delgado, heterogéneo y, en el escenario




Figura 11. Mosaico de 3 vistas (axial/coronal/sagital) del caso 02060-100: original con GT y las cuatro segmentaciones.

post-tratamiento, rodea una cavidad oscura. Esto rompe las hipótesis de cada método. *Otsu* supone un histograma con un modo brillante claro, pero T1c es *unimodal* (coeficiente de bimodalidad $< 5/9$ en los casos analizados), de modo que el umbral de la clase alta cae en un punto arbitrario y mezcla realce con tejido sano brillante. *Crecimiento de regiones* y *watershed* dependen de una semilla/marcador fiable; aun corregida la semilla (Sec. V-A), la heterogeneidad del realce limita el crecimiento. *GMM multimodal* ilustra que **añadir modalidades no ayudó**: al agrupar T1c+T2w+T2-FLAIR captura un cúmulo amplio dominado por el edema, con alta sensibilidad pero Dice ínfimo (Fig. 12).




Figura 12. Sobre-segmentación de la GMM multimodal (caso 00529-100): predicción roja muy superior al GT cian.

Limitaciones del registro demostrativo. El registro es rígido y se evaluó frente a una perturbación rígida conocida; por construcción no compensa deformaciones no rígidas (efecto de masa, cambios post-quirúrgicos) y su excelente TRE no debe extrapolarse a un escenario inter-sujeto o longitudinal real.

Alcance experimental. La segmentación se evaluó sobre nueve casos y el registro/3D sobre cuatro y ocho respectivamente; las cifras son indicativas, no un *benchmark* a gran escala.

X. REPRODUCIBILIDAD

La canalización completa (seis módulos en Python 3.11 con SIMPLEITK) es reproducible y lee los datos directamente desde los .zip. La Tabla XV resume los parámetros clave.

Cuadro XIV

MÉTRICAS 3D POR CASO. LA VALIDACIÓN DE ESCALA (VOL. MALLA GT VS. EDA) ES CORRECTA; LA DISTANCIA SUPERFICIE-SUPERFICIE MIDE EL alejamiento $PRED \leftrightarrow GT$, NO ACIERTO.

Caso	Dice	Vért. pred	Vért. GT	Vol. pred (mm ³)	Vol. GT (mm ³)	Vol. GT EDA (mm ³)	Dist. media (mm)
02063-106	0,257	724	450	254,6	192,1	254,0	4,79
00529-100	0,407	298	722	112,4	424,9	501,0	2,13
02062-100	0,217	633	1 704	187,8	908,4	1 062,0	3,72
02063-102	0,283	824	3 898	747,9	4 706,2	4 812,0	10,09
00498-100	0,157	48 963	5 906	29 113,1	4 535,9	4 816,0	42,74
00463-101	0,280	49 983	8 044	27 308,6	11 258,8	11 312,0	37,45
02060-100	0,451	33 392	18 583	19 489,3	19 266,1	19 975,0	14,13
00046-101	0,509	15 095	18 109	11 269,1	25 685,0	25 306,0	2,64

Cuadro XV
PARÁMETROS DEL PIPELINE.

Etapas	Configuración
Objetivo	ET (seg==3) sobre T1c
Limpieza	Wiener (3) $\rightarrow$ N4 (<i>shrink</i> 4) $\rightarrow$ percentil [0,5,99,5] $\rightarrow$ [0, 1]
Otsu	multinivel n=3, clase alta
Region growing	semilla en ET más brillante, ventana $[\alpha I, \text{máx}]$, $\alpha = 0,65$
Watershed	marcador en ET brillante, gradiente de Sobel
GMM	4 componentes, T1c+T2w+T2-FLAIR
Registro	Mattes MI (50 bins), Euler3D, <i>shrink</i> [4, 2], sigmas [2, 1], 150 iter
Semilla aleatoria	42
Datos	lectura directa desde .zip (BraTS 2024 GLI)

XI. CONCLUSIONES Y TRABAJO FUTURO

El hallazgo central es claro y honesto: **los métodos clásicos basados en intensidad son insuficientes para segmentar el tumor realzante en T1c** en BraTS 2024 GLI post-tratamiento. Ningún método supera un Dice medio de 0,50; el mejor base —crecimiento de regiones, 0,320— es apenas “el menos malo”, y la multimodalidad mediante GMM no ayudó (sobresegmentación). Ni siquiera el post-proceso clásico exhaustivo cambia la conclusión: tras explorar morfología, anclaje del componente a la semilla, ensamble de métodos e histéresis, el mejor valor —ensamble por unión con post-proceso anclado— alcanza solo 0,370 (+0,050 sobre la base), con un único caso de ocho cruzando 0,50. Un análisis de robustez por *ablation* de la limpieza descarta además que el preprocesamiento sea el culpable: la limpieza *mejora* el Dice y la separabilidad del realce (+0,092 de la entrada cruda a la completa), de modo que el techo es estructural, propio de la forma del ET. El escenario post-tratamiento, con su cavidad de resección oscura, agrava el problema y obligó a corregir la estrategia de siembra. En contraste, el registro rígido por información mutua sí resuelve con precisión su tarea (TRE sub-vóxel), y la reconstrucción 3D valida la escala física de las máscaras.

Como trabajo futuro, estos límites motivan: (i) modelos con *prior* de forma (*level sets* con regularización, contornos activos) que no dependan solo de intensidad; (ii) una combinación multimodal más informada que la GMM ingenua; (iii) registro deformable para escenarios longitudinales; y (iv),

naturalmente, el aprendizaje profundo, cuya necesidad este estudio cuantifica por contraste.

REFERENCIAS

- [1] U. Baid *et al.*, “The RSNA-ASNR-MICCAI BraTS 2021 benchmark on brain tumor segmentation and radiogenomic classification,” *arXiv:2107.02314*, 2021.
- [2] B. C. Lowekamp, D. T. Chen, L. Ibáñez and D. Blezek, “The design of SimpleITK,” *Frontiers in Neuroinformatics*, vol. 7, p. 45, 2013.
- [3] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [4] N. J. Tustison *et al.*, “N4ITK: Improved N3 bias correction,” *IEEE Trans. Med. Imag.*, vol. 29, no. 6, pp. 1310–1320, 2010.
- [5] D. Mattes, D. R. Haynor, H. Vesselle, T. K. Lewellyn and W. Eubank, “PET-CT image registration in the chest using free-form deformations,” *IEEE Trans. Med. Imag.*, vol. 22, no. 1, pp. 120–128, 2003.
- [6] L. Vincent and P. Soille, “Watersheds in digital spaces: an efficient algorithm based on immersion simulations,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 6, pp. 583–598, 1991.
- [7] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [8] W. E. Lorensen and H. E. Cline, “Marching cubes: A high resolution 3D surface construction algorithm,” *ACM SIGGRAPH Computer Graphics*, vol. 21, no. 4, pp. 163–169, 1987.
- [9] M. Correia de Verdier *et al.*, “The 2024 Brain Tumor Segmentation (BraTS) Challenge: Glioma Segmentation on Post-treatment MRI,” *arXiv:2405.18368*, 2024.
- [10] M. M. Baig *et al.*, “Adapting nnU-Net for the BraTS 2024 post-treatment glioma segmentation challenge,” *Neuro-Oncology Advances*, vol. 6, no. 1, art. vdae140, 2024.
- [11] L. Luque *et al.*, “Standardized evaluation of the extent of resection in adult gliomas using semi-supervised deep learning,” *Frontiers in Radiology*, vol. 4, art. 1357341, 2024.
- [12] Á. Györfi, L. Szilágyi and L. Kovács, “A fully automatic and efficient brain tumor segmentation framework based on ensemble learning and atlas-based normality deviation,” *Applied Sciences*, vol. 11, no. 2, art. 564, 2021.
- [13] M. Visser *et al.*, “Inter-rater agreement in glioma segmentations on longitudinal MRI,” *NeuroImage: Clinical*, vol. 22, art. 101727, 2019.
- [14] D. N. Louis *et al.*, “The 2021 WHO Classification of Tumors of the Central Nervous System: a summary,” *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021.
- [15] F. B. Mesfin and M. A. Al-Dhahir, “Gliomas,” in *StatPearls*, Treasure Island, FL, USA: StatPearls Publishing, 2024.
- [16] D. Bhattacharya *et al.*, “Imaging assessment of post-treatment gliomas: a review,” *Clinical Radiology*, vol. 79, no. 3, pp. e376–e392, 2024.