

Segmentación clásica del tumor realzante (ET) en BraTS 2024 GLI: del límite de los métodos por intensidad a los contornos deformables, con interpolación de contornos y reconstrucción 3D

Abel Albuez, Victoria Acero y Santiago Gil
Maestría en Ingeniería de Sistemas y Computación
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Procesamiento de Imágenes Médicas 2026

Repositorio: <https://github.com/AbelAlbuez/medical-image-processing>

Resumen—Se aborda la segmentación automática del *tumor realzante* (*enhancing tumor*, ET; etiqueta 3 de BraTS) sobre la modalidad T1 con contraste (T1c) empleando exclusivamente métodos clásicos (sin aprendizaje profundo). Un análisis exploratorio sobre 100 casos de *BraTS 2024 GLI Post-Treatment* (78 con ET presente) muestra que T1c es la modalidad más separable para el realce (razón discriminante de Fisher mediana de 1,32 frente a 0,47 en T2-FLAIR). Tras una limpieza de T1c (Wiener $\rightarrow$ N4 $\rightarrow$ normalización por percentiles) el estudio recorre dos familias clásicas. Primero, cuatro métodos *por intensidad* —Otsu multinivel, crecimiento de regiones, *watershed* por marcadores y mezcla de gaussianas multimodal— cuyo hallazgo central es que son insuficientes para el ET: ningún método base supera un Dice medio de 0,50 (el mejor, crecimiento de regiones, 0,320), y ni el post-proceso exhaustivo (morfología, anclaje a la semilla, ensamble, histéresis) ni un *ablation* de la limpieza cambian la conclusión: el techo es *estructural* (la forma del realce), no de umbral. Segundo, y como respuesta directa a ese límite, se añade un *prior* de forma mediante cuatro modelos clásicos de contorno deformable —level set geodésico, level set variacional de Chan–Vese, B-spline y *snake* paramétrico— inicializados con una semilla híbrida automática (GMM sobre T1c). Estos modelos elevan el Dice medio del ET hasta 0,505 (Chan–Vese; máximo 0,86) y, sobre todo, son robustos; pero *se estancan en torno a 0,50*, lo que confirma el límite estructural anticipado. Complementariamente, un registro rígido por información mutua de Mattes recupera una perturbación conocida con un error de registro objetivo (TRE) medio de 0,007 mm; un módulo de interpolación lineal de contornos entre cortes alcanza un Dice de 0,855 contra el corte real intermedio y densifica la pila de contornos; y una reconstrucción 3D por *marching cubes* y Poisson valida la escala física y permite la inspección visual interactiva de las mallas (ground-truth vs. predicción).

Index Terms—BraTS 2024 GLI, tumor realzante, T1c, segmentación clásica, contornos deformables, level set, Chan–Vese, SimpleITK, información mutua de Mattes, interpolación de contornos, *marching cubes*, reconstrucción de Poisson.

I. PROBLEMA, JUSTIFICACIÓN Y OBJETIVOS

Los gliomas son los tumores cerebrales primarios más frecuentes en adultos y su seguimiento por resonancia magnética (RM) es central en la práctica clínica [?], [?]. En el escenario *post-tratamiento*, el *tumor realzante* (ET) —tejido que capta contraste en T1c— es el marcador imagenológico de actividad

tumoral residual o recurrente y un sustituto habitual de la respuesta a la terapia [?]. Delimitarlo manualmente es costoso y poco reproducible: la variabilidad inter- e intra-observador de la segmentación experta es alta incluso entre radiólogos especializados [?], lo que justifica el interés por métodos automáticos.

El reto BraTS 2024 GLI Post-Treatment [?], [?] introduce por primera vez la *cavidad de resección* (RC) como clase explícita, alterando las hipótesis de intensidad sobre las que descansan los métodos clásicos: el ET, lejos de ser un objeto brillante y compacto, suele aparecer como un *anillo* delgado y heterogéneo alrededor de una cavidad oscura. Este escenario es un banco de pruebas natural para preguntar hasta dónde llegan los métodos clásicos sin el apoyo del aprendizaje profundo.

Este trabajo se restringe deliberadamente a **métodos clásicos** (sin aprendizaje profundo) implementados sobre ITK/SimpleITK [?], con el objetivo de caracterizar honestamente sus *alcances* y *límites* para el ET y de mostrar, sobre los mismos datos, qué aporta pasar de métodos por intensidad a métodos con *prior* de forma. Los objetivos concretos son: (i) un análisis exploratorio (EDA) que justifique la modalidad objetivo; (ii) una limpieza de T1c; (iii) un registro rígido demostrativo por información mutua; (iv) la segmentación del ET con cuatro métodos clásicos *por intensidad*; (v) un segundo bloque de segmentación con cuatro modelos clásicos de *contorno deformable* (spline / level set) que incorporan un *prior* de forma; (vi) la interpolación de contornos entre cortes para densificar la representación 3D; y (vii) una reconstrucción 3D de las máscaras (*marching cubes* y Poisson) para validación de escala e inspección visual. La canalización completa se organiza en módulos reproducibles y se ejecuta leyendo los datos directamente desde los archivos comprimidos del reto.

II. ESTADO DEL ARTE

La literatura reciente sobre segmentación de gliomas en BraTS está dominada por el aprendizaje profundo, en particular por la familia NNU-NET; el contexto clásico-híbrido

es minoritario pero existe. A continuación se resumen tres trabajos representativos que enmarcan este estudio.

Györfi et al. (2021) [?]. Proponen una canalización *clásico-híbrida* para BraTS basada en normalización de histogramas, un atlas que codifica la *desviación de la normalidad* y un ensamble de árboles (125 árboles en bosques aleatorios) sobre características multimodales por vóxel. El trabajo reporta un Dice global cercano al 86 % con un registro afín previo en aproximadamente 58 s de CPU, posicionando los métodos basados en intensidad y atlas como una alternativa competitiva en hardware modesto. No obstante, su evaluación es anterior a la introducción de la cavidad de resección y se centra en el tumor completo, no en el realzante por sí solo.

Baig et al. (2024) [?]. Estudian explícitamente el escenario *post-tratamiento* con NNU-NET 3D sobre BraTS 2023/2024, con cuatro modalidades (T1n, T1c, T2w, T2-FLAIR) y cinco etiquetas (incluyendo RC). Comparan tres entrenamientos —redes pre-tratamiento, post-tratamiento y combinada— y reportan Dice por sub-región entre 0,82 y 0,94. Su hallazgo más relevante es que la red *combinada* reduce los falsos positivos sobre la cavidad de resección, evidenciando que el caso post-quirúrgico exige información de contexto que no está en una sola modalidad.

Luque et al. (2024) [?]. Aplican NNU-NET con *Cross Pseudo Supervision* (semi-supervisado) para estimar la *extensión de la resección* (EOR) en gliomas. Reportan un Dice externo de 0,52 sobre imágenes no vistas y, al usar la segmentación para clasificar el grado de resección, alcanzan precisión 0,90 y sensibilidad 0,87. El trabajo confirma que la tarea *anatómica* es difícil incluso para redes profundas modernas, pero que los mapas resultantes ya son útiles para la decisión clínica.

Modelos clásicos de contorno deformable. En la frontera entre “intensidad pura” y “aprendizaje” están los modelos deformables, que introducen un *prior* de forma sin requerir entrenamiento: los *snakes* o contornos activos paramétricos [?], los *level sets* [?] y sus variantes geodésica (basada en bordes) [?] y de Chan–Vese (basada en regiones) [?]. Este trabajo los incorpora explícitamente (Sec. ??) como el eslabón clásico que el bloque por intensidad echa en falta.

Hueco que llena este trabajo. El estado del arte está dominado por aprendizaje profundo y, en el escenario post-tratamiento, ningún trabajo conocido por los autores cuantifica el *techo* de los métodos puramente clásicos para el ET, incluyendo el salto de los métodos por intensidad a los de contorno deformable. Este informe no compite con NNU-NET: caracteriza su *línea de base* sin aprendizaje profundo, incluyendo post-proceso, ensambles, un *ablation* del preprocesamiento y un *prior* de forma clásico, y muestra que el límite es estructural (forma del realce) y no de umbral.

III. DESCRIPCIÓN DE LA BASE DE DATOS

Se emplea el subconjunto *BraTS 2024 GLI Post-Treatment* [?]. Es la *primera* edición del reto BraTS centrada explícitamente en el escenario post-tratamiento; su novedad principal frente a ediciones previas es la inclusión de la *cavidad de resección* (RC) como clase distinta. La cohorte completa abarca

del orden de ~ 2200 pacientes adultos provenientes de siete instituciones, con volúmenes en formato NIFTI (.nii.gz), cuatro modalidades de resonancia magnética por caso ya *co-registradas* a un espacio común y *esqueletizadas* (*skull-stripping* aplicado), y una segmentación experta consensuada por radiólogos. Las modalidades son T1n (T1 nativo), T1c (T1 con contraste de gadolinio), T2w y T2-FLAIR; las cuatro etiquetas anatómicas son 1=NETC (núcleo no realzante), 2=SNFH (edema/FLAIR hiperintenso), 3=ET (realce) y 4=RC (cavidad de resección). **El objetivo de este trabajo es la etiqueta 3 (ET).** Los volúmenes se leen directamente desde los .zip del reto, extrayendo puntualmente cada par caso/modalidad sin descomprimir el archivo completo. Se procesa un subconjunto de 100 casos del conjunto de entrenamiento (el que posee *seg*); de ellos, **78 contienen ET.**

La Tabla ?? resume la geometría, homogénea en todo el subconjunto (verificada por el EDA).

Cuadro I
GEOMETRÍA DEL SUBCONJUNTO (UNIFORME EN LOS 100 CASOS).

Propiedad	Valor
Dimensiones (vóxeles)	182 × 218 × 182
Espaciado	1,0 × 1,0 × 1,0 mm (isotrópico)
Casos procesados	100
Casos con ET (<i>seg</i> ==3)	78

III-A. Separabilidad del ET por modalidad

Para justificar la modalidad objetivo se midió la separabilidad entre los vóxeles de ET y el tejido cerebral sano por modalidad, mediante la razón discriminante de Fisher (FDR) y la distancia de Bhattacharyya (Tabla ??, Fig. ??). **T1c es claramente la modalidad más separable para el ET** (FDR mediano 1,32, casi el triple que T2-FLAIR), lo que confirma la elección de T1c como soporte de la segmentación.

Cuadro II
SEPARABILIDAD ET VS. TEJIDO SANO POR MODALIDAD (MEDIANA Y MEDIA SOBRE LOS 78 CASOS CON ET).

Modalidad	FDR mediana	FDR media	Bhatt. med.	Bhatt. media
T1c	1,317	1,461	0,375	0,403
T2-FLAIR	0,472	0,818	0,153	0,238
T2w	0,341	0,667	0,178	0,250
T1n	0,099	0,227	0,126	0,177

III-B. Umbral de Otsu y casos demostrativos

El umbral alto de Otsu ($n=3$) sobre T1c en escala cruda tiene una mediana de 3120 y un rango de 352 a 6435 entre casos (Fig. ??), lo que evidencia una fuerte variabilidad inter-caso de la intensidad y motiva la normalización del módulo siguiente. El volumen de ET tiene una mediana de 4814 mm³ (rango 66–87 993 mm³). A partir de esta distribución se seleccionaron automáticamente casos demostrativos que cubren el rango de tamaño de ET más un caso *sin* ET (Tabla ??, Fig. ??).




Figura 1. Separabilidad ET vs. tejido sano por modalidad (FDR y Bhattacharyya medianos). T1c domina, justificando su uso para ET.




Figura 2. Distribución del umbral alto de Otsu ($n=3$) en T1c por caso (escala cruda); la dispersión justifica normalizar.

Cuadro III
CASOS DEMOSTRATIVOS SELECCIONADOS POR EL EDA.

Categoría	Caso	Volumen ET (mm^3)
Pequeño	BraTS-GLI-00529-100	501
Mediano	BraTS-GLI-02063-102	4 812
Grande	BraTS-GLI-02060-100	19 975
Sin ET	BraTS-GLI-00005-100	0

IV. DESCRIPCIÓN DE LA LÍNEA DE PROCESAMIENTO

La canalización está organizada en **módulos numerados**, cada uno con sus figuras y sus archivos de salida (CSV/JSON), y reproducibles desde PYTHON 3.11 con SIMPLEITK [?]:

1. **EDA.** Caracterización de geometría, intensidades y separabilidad por modalidad sobre 100 casos; selecciona T1c como modalidad objetivo y los casos demostrativos (Sec. ??).
2. **Limpieza T1c.** Reducción de ruido con filtro de Wiener, corrección del campo de sesgo con N4 [?] y normalización por percentiles (Sec. ??).
3. **Registro rígido.** Recuperación demostrativa de una perturbación rígida conocida con información mutua de Mattes [?] sobre transformación Euler3D multi-resolución (Sec. ??).
4. **Segmentación por intensidad del ET.** Otsu multinivel, crecimiento de regiones, *watershed* por marcadores y mezcla de gaussianas multimodal (Sec. ??), incluyendo el hallazgo sobre la semilla (cavidad de resección $\rightarrow$ ET más brillante, $\alpha = 0,65$) y el ensamble por unión con post-proceso.
5. **Contornos deformables (prior de forma).** Level set geodésico, Chan–Vese variacional, B-spline y *sna-ke* paramétrico sobre una semilla híbrida automática (Sec. ??).
6. **Interpolación de contornos.** Interpolación lineal de contornos entre cortes con resolución de auto-intersecciones, para densificar la pila 3D (Sec. ??).



Figura 3. Casos demostrativos: T1c con el ET (contorno rojo) en el corte del centroide. El caso sin ET no presenta realce.

7. **Reconstrucción 3D.** Mallas por *marching cubes* [?] y reconstrucción de Poisson [?] de la predicción y el *ground truth* para validación de escala e inspección (Sec. ??).
8. **Visualización.** Mosaicos 2D (axial/coronal/sagital) y un visor 3D web autocontenido para inspección visual.

Las tres reglas transversales que se respetan a lo largo de la canalización son: (i) *el ground truth solo ubica la semilla y evalúa, nunca construye la máscara*; (ii) los hiperparámetros (umbral relativo α , radio de cierre, etc.) son *globales*, ajustados sobre el promedio de los casos y no por caso; (iii) la lectura es directa desde `.zip`, sin copiar el dataset al disco.

V. PREPROCESAMIENTO (T1C)

Sobre T1c se aplica, en este orden: (1) reducción de ruido con filtro de Wiener adaptativo (ventana 3); (2) corrección del campo de sesgo con N4 [?] (*shrink* 4); y (3) normalización por percentiles $[0,5, 99,5]$ a $[0, 1]$ dentro del cerebro. El denoise

precede a N4 para evitar que el ruido se modele como estructura, y la normalización al final fija la escala entre casos (Tabla ?? mostró que la geometría es homogénea, por lo que no se requiere remuestreo).

La Tabla ?? resume, para los nueve casos de la segmentación por intensidad, la intensidad antes (escala cruda) y después de la limpieza; todos los volúmenes quedan en $[0, 1]$, lo que homogeneiza la escala dispar de partida (medias crudas de 335 a 3096). La Fig. ?? ilustra el efecto.

Cuadro IV

ESTADÍSTICAS DE INTENSIDAD DENTRO DEL CEREBRO ANTES Y DESPUÉS DE LA LIMPIEZA (9 CASOS DE SEGMENTACIÓN).

Caso	ET	media _{orig}	p99 _{orig}	media _{limp}	std _{limp}
02063-106	sí	359,2	669,0	0,350	0,117
00529-100	sí	1973,7	3299,2	0,507	0,131
02062-100	sí	385,9	683,0	0,384	0,108
02063-102	sí	334,7	616,2	0,365	0,112
00498-100	sí	1651,9	2986,4	0,451	0,114
00463-101	sí	2133,1	4300,3	0,305	0,124
02060-100	sí	690,8	1358,0	0,340	0,128
00046-101	sí	3096,0	7022,2	0,280	0,128
00005-100	no	2081,6	4334,2	0,374	0,103




Figura 4. Limpieza de T1c (caso 02060-100): original, resultado (Wiener→N4→normalización) e histograma cerebral.

VI. REGISTRO RÍGIDO DEMOSTRATIVO

Se incluye una demostración cuantitativa de registro rígido por información mutua de Mattes [?] con transformación Euler3D y esquema multi-resolución. Tomando T1c como volumen fijo, se le aplica una perturbación rígida *conocida* (rotación $(6, 4, -5)^\circ$, traslación $(5, -4, 3)$ mm) para generar un volumen desalineado, y se registra para recuperarla. La métrica se configura con 50 *bins*, muestreo aleatorio del 10 % (semilla 42), inicialización por geometría (*CenteredTransformerInitializer*), optimizador *gradient descent line search*, factores de reducción $[4, 2]$ y sigmas $[2, 1]$.

Como la perturbación es conocida, el error de registro objetivo (TRE) mide directamente la calidad: en los cuatro

casos es *sub-vóxel* ($\approx 0,007$ mm), y el Dice del cerebro mejora de 0,906 a 0,963 (Tabla ??, Fig. ??). El registro recupera con precisión la transformación impuesta; es el único bloque del trabajo con un resultado cuantitativamente sólido, en contraste con la segmentación.




Figura 5. Arriba: fija, desalineada y recuperada (caso 02060-100). Abajo: convergencia de la información mutua de Mattes; la métrica descende y se estabiliza.

VII. SEGMENTACIÓN POR INTENSIDAD DEL ET

Sobre T1c limpio se evaluaron cuatro métodos clásicos *por intensidad*, con el ET (*seg==3*) como referencia: **Otsu** multinivel ($n=3$ [?], clase más brillante); **crecimiento de regiones**; **watershed** por marcadores [?]; y **mezcla de gaussianas** (GMM [?]) *multimodal* (T1c+T2w+T2-FLAIR), incluida como comparación. Se usaron nueve casos: ocho con ET (cubriendo el rango de volumen) y uno sin ET (robustez).

VII-A. Hallazgo: la semilla del crecimiento de regiones

El comportamiento del crecimiento de regiones reveló un problema específico del escenario post-tratamiento que merece destacarse. La semilla natural —el centroide del ET— **cae dentro de la cavidad de resección** (*label 4*), que es *oscura* en T1c, porque el ET forma típicamente un *anillo* alrededor de dicha cavidad. Sembrado ahí, el crecimiento por intensidad parte de tejido oscuro y se “fuga” hacia el resto del cerebro, produciendo máscaras degeneradas (Dice ≈ 0). La solución adoptada es sembrar en el **vóxel de ET más**

Cuadro V
REGISTRO RÍGIDO DEMOSTRATIVO (PERTURBACIÓN CONOCIDA → RECUPERACIÓN). TRE SUB-VÓXEL Y MEJORA DEL DICE DE CEREBRO EN LOS CUATRO CASOS.

Caso	TRE (mm)	Dice cerebro antes	Dice cerebro después	MSE antes	MSE después	MI final	Tiempo (s)
00529-100	0,0064	0,9076	0,9633	205 707	3 109	−1,029	8,1
02063-102	0,0095	0,9110	0,9646	5 635	188	−1,000	6,7
02060-100	0,0082	0,9196	0,9621	27 553	1 106	−0,982	7,2
00005-100	0,0054	0,8865	0,9607	242 177	3 676	−0,765	7,0
Promedio	0,0074	0,9062	0,9627	120 268	2 020	−0,944	7,25

brillante y crecer por una *ventana brillante* [$\alpha I_{\text{semilla}}$, máx] con $\alpha = 0,65$ (calibrado por barrido, Tabla ??). La etiqueta experta solo aporta la *ubicación* de la semilla (inicialización semi-automática); la máscara final surge del crecimiento sobre T1c, no de la copia del *ground truth*.

VII-B. Resultados agregados

La Tabla ?? promedia las métricas sobre los ocho casos con ET. El crecimiento de regiones obtiene el mejor Dice medio, pero **este valor (0,320) debe leerse como “el menos malo”, no como un éxito**: ningún método alcanza siquiera 0,50 de Dice. La GMM multimodal exhibe la mayor sensibilidad (0,63) pero el peor Dice (0,094), porque etiqueta como tumor un cúmulo amplio (edema, vasos) y *sobre-segmenta*; su especificidad (0,965) es la más baja de las cuatro. La Fig. ?? resume el orden y la Fig. ?? contrasta visualmente el mejor método con la sobre-segmentación de la GMM.

Cuadro VI
RESUMEN POR MÉTODO (DICE MEDIO SOBRE 8 CASOS CON ET). NINGÚN MÉTODO SUPERA 0,50.

Método	Multim.	Dice	Jaccard	Sensib.	Especif.
RegionGrowing	no	0,320	0,196	0,362	0,999
Watershed	no	0,213	0,132	0,133	0,999
Otsu	no	0,164	0,097	0,516	0,995
GMM multimodal	sí	0,094	0,052	0,630	0,965

VII-C. Resultados por caso

La Tabla ?? muestra el Dice por caso (semáforo: verde $\geq 0,80$, amarillo 0,50–0,80, rojo $< 0,50$). El predominio del rojo es, en sí mismo, el resultado: la inmensa mayoría de las combinaciones caso/método quedan por debajo de 0,50. Además, la **dispersión es alta y no hay un ganador estable**: aunque RegionGrowing gana en promedio, Watershed supera al resto en 02063-106 y 00463-101 (único valor amarillo, 0,618), y Otsu es competitivo en los casos de ET grande. El caso sin ET (00005-100) no admite Dice (N/A), pero los cuatro métodos producen máscaras no vacías (falsos positivos), lo que ilustra que ningún método clásico “se abstiene” ante la ausencia de realce.

VII-D. Calibración del crecimiento de regiones

La Tabla ?? reporta el barrido (*itertools.product*) del umbral relativo α y el radio del cierre morfológico. El óptimo medio se alcanza en ($\alpha = 0,65$, cierre = 3) con Dice 0,341; la




Figura 6. Dice medio por método. RegionGrowing es el mejor, pero todos quedan muy por debajo de un Dice útil.

Cuadro VII
DICE POR CASO Y MÉTODO. SEMÁFORO: VERDE $\geq 0,80$, AMARILLO 0,50–0,80, ROJO $< 0,50$.

Caso	Otsu	RegionGrow.	Watershed	GMM mult.
02063-106	0,007	0,257	0,344	0,003
00529-100	0,009	0,407	0,155	0,000
02062-100	0,023	0,217	0,088	0,026
02063-102	0,170	0,283	0,255	0,000
00498-100	0,136	0,157	0,096	0,094
00463-101	0,207	0,280	0,618	0,146
02060-100	0,368	0,451	0,110	0,265
00046-101	0,395	0,509	0,035	0,217
00005-100 (sin ET)	N/A	N/A	N/A	N/A

configuración por defecto usa cierre 1 (0,320). La mejora por ajuste es marginal, coherente con el límite de fondo del método.

VII-E. Estrategias de mejora y análisis de robustez

Se exploró si técnicas clásicas de post-proceso elevan el Dice del ET, manteniendo la regla anti-fuga: el GT solo ubica la semilla y evalúa, nunca construye la máscara ni ajusta parámetros por caso (el radio de cierre y α son globales, por barrido sobre el promedio). Se evaluaron cuatro variantes por método: *base*, *+morfología* (cierre + selección de componente conexo), *+sustracción* (método sobre $S = \text{clip}(T1c - T1n, 0)$,




Figura 7. Caso 02060-100. Arriba: crecimiento de regiones (predicción roja, GT cian). Abajo: GMM multimodal, que sobre-segmenta ampliamente.

Cuadro VIII
BARRIDO DEL CRECIMIENTO DE REGIONES (DICE MEDIO SOBRE LOS CASOS CON ET).

α	cierre	Dice	α	cierre	Dice
0,55	1	0,266	0,65	3	0,341
0,55	2	0,269	0,75	1	0,287
0,55	3	0,269	0,75	2	0,306
0,65	1	0,320	0,75	3	0,322
0,65	2	0,331			

con *histogram matching* de T1n a T1c) y la combinación de ambas. Tres hallazgos:

(a) **Sin apertura morfológica.** La apertura destruía el ET pequeño (lo dejaba en Dice 0,000); eliminarla y conservar solo *cierre* + *componente conexo* evita ese colapso.

(b) **Componente anclado a la semilla.** Quedarse con el componente conexo *más grande* falla cuando el método no aísla el ET: en Otsu, el blob dominante es tejido sano y el solape con el ET es nulo (Dice 0,000 en cuatro casos). Anclar el componente al vóxel de ET más brillante *rescata* esos casos (Tabla ??). El anclaje solo afecta a Otsu: el crecimiento de regiones y el *watershed* ya producen un único componente

sembrado en el ET, y la GMM produce un único blob (su semilla a veces cae fuera, con *fallback* al mayor).

(c) **La sustracción T1c–T1n no mejoró** (resultado honesto, en contra de la intuición): rebaja el Dice medio de todos los métodos respecto a su base.

La Tabla ?? resume el Dice medio por método y variante con el componente anclado, y la Fig. ?? lo ilustra.

Cuadro IX
DICE MEDIO POR MÉTODO Y VARIANTE (POST-PROCESO CON COMPONENTE ANCLADO A LA SEMILLA). NINGÚN MÉTODO ALCANZA 0,50.

Método	base	+morf.	+sust.	+sust+morf.
Otsu	0,164	0,353	0,117	0,326
RegionGrowing	0,320	0,342	0,243	0,267
Watershed	0,213	0,223	0,187	0,197
GMM multimodal	0,094	0,080	—	—

Cuadro X
RESCATE DE OTSU (+MORFOLOGÍA) AL ANCLAR EL COMPONENTE A LA SEMILLA: LOS CUATRO CASOS QUE EL COMPONENTE *mayor* DEJABA EN 0,000.

Caso	componente mayor	componente anclado
02063-106	0,000	0,181
00529-100	0,000	0,322
02062-100	0,000	0,413
02063-102	0,000	0,638

VII-E0a. *Ensamble de métodos:* Como las predicciones ancladas de Otsu, crecimiento de regiones y *watershed* fallan en casos distintos, se combinaron por unión, voto de mayoría e intersección, aplicando el mismo post-proceso anclado a la máscara fusionada (*union_post*). La unión con post-proceso es la mejor estrategia global (Tabla ??): **Dice** 0,370 (sensibilidad media 0,63, especificidad 0,997), por encima del mejor individual (0,353). El voto y la intersección sacrifican sensibilidad y bajan el Dice.

Cuadro XI
ENSAMBLE DE LOS MÉTODOS ANCLADOS (DICE MEDIO). LA UNIÓN CON POST-PROCESO ANCLADO SUPERA AL MEJOR MÉTODO INDIVIDUAL; NINGÚN ENSAMBLE ALCANZA 0,50.

Estrategia	Dice medio
Unión + post-proceso	0,370
Unión (sin post)	0,369
Otsu anclado (individual)	0,353
RegionGrowing anclado (indiv.)	0,342
Voto de mayoría	0,334
Intersección	0,204

VII-E0b. *Histéresis y Otsu de dos clases (no mejoran):* Se probó un umbral doble por histéresis (semilla alta, crecimiento hasta un nivel bajo) y un Otsu de dos clases. La histéresis eleva la sensibilidad media a 0,75 pero el Dice *cae* a 0,209 por fugas hacia tejido sano; el Otsu de dos clases se fuga masivamente en 7 de 9 casos (especificidad $\approx$ 0,80,




Figura 8. Arriba: Dice por método y variante (línea roja = 0,5). Abajo: Otsu en 02062-100 — base, componente mayor (selecciona tejido sano, Dice 0,000) y componente anclado a la semilla (verde), que recupera el realce.

>1 M de vóxeles predichos) y colapsa a 0,084. Ninguna supera al ensamble; confirman que el límite no es de *umbral* sino estructural.

VII-E0c. Análisis de robustez: ablation de la limpieza: Para descartar que el preprocesamiento (filtro de Wiener, N4, normalización) atenuara el realce fino y limitara el Dice, se repitió la segmentación variando solo la entrada: **E1** crudo, **E2** solo N4, **E3** N4 + normalización (sin Wiener) y **E4** pipeline completo. Para cada entrada se midió el Dice (estrategias Otsu anclado y unión+post) y la separabilidad ET frente a tejido sano mediante la razón discriminante de Fisher (FDR) y la distancia de Bhattacharyya (Tabla ??, Fig. ??).

El ablation arroja dos conclusiones nítidas. (i) *La limpieza ayuda, no daña*: el Dice sube +0,092 de E1 a E4 y la separabilidad crece de forma monótona (FDR 1,21 → 1,80), siendo N4 el paso de mayor salto; el filtro de Wiener no atenúa el realce (E4 > E3) y la normalización tampoco (E4 > E1). (ii) *El techo es estructural*: aun con la entrada más separable posible (E4, FDR 1,80), el Dice se estanca en 0,370 ≪ 0,50. El límite lo impone la *forma* del ET —anillo delgado, heterogéneo, post-resección— no el preprocesamiento, que queda

Cuadro XII
ABLATION DE LA LIMPIEZA. EL DICE Y LA SEPARABILIDAD (FDR, BHATTACHARYYA) DEL ET *crecen* DE LA ENTRADA CRUDA (E1) A LA LIMPIA COMPLETA (E4): LA LIMPIEZA AYUDA.

Entrada	Otsu anc.	Unión+post	FDR	Bhatt.
E1 crudo	0,264	0,278	1,21	0,328
E2 N4	0,333	0,339	1,56	0,448
E3 N4+norm (sin Wiener)	0,311	0,314	1,72	0,496
E4 completo	0,353	0,370	1,80	0,498




Figura 9. Arriba: Dice por estrategia de ensamble (línea roja = 0,5). Abajo: ablation de la limpieza — el Dice (izq.) y la separabilidad FDR/Bhattacharyya (der.) suben monótonamente de E1 (crudo) a E4 (completo).

así validado. Esta observación motiva directamente el bloque siguiente (Sec. ??): añadir un *prior* de forma.

VIII. CONTORNOS DEFORMABLES CON *prior* DE FORMA

El bloque anterior dejó una conclusión accionable: el límite del ET es de *forma*, no de umbral. La respuesta clásica natural —sin recurrir al aprendizaje profundo— es introducir un *prior* de forma mediante modelos de **contorno deformable**, en los que la segmentación deja de ser una umbralización y pasa a ser la *evolución de un contorno* que se ajusta al borde del realce minimizando una energía. Se implementaron cuatro, representando los dos grandes ejes del campo —basado en bordes frente a basado en regiones, e implícito frente a explícito—, todos sobre T1c limpio y con SimpleITK/scikit-image.

VIII-A. Semilla híbrida automática

Como ninguna señal aislada localiza el ET de forma fiable, los cuatro métodos parten de la misma **semilla automática**: un GMM de tres componentes sobre T1c (la componente

de mayor media corresponde al tejido realzante), quedándose con el componente conexo dominante. Cuando esa semilla degenera (vacía, > 250 k vóxeles o caja delimitadora $> 2,5$ M de vóxeles, indicio de que el GMM capturó tejido sano brillante) se recurre al *blob* dominante del mapa de diferencia $D = \text{clip}(T1c - T1n, 0)$. Cada modelo refina esa semilla; una salvaguarda en el post-proceso *revierte* la evolución a la semilla si el contorno colapsa ($< 0,4 \times$ el área), se fuga ($> 2,5 \times$) o se desplaza a otra región (solape $< 0,4$), de modo que un modelo degenerado nunca puntúa por debajo de la base.

VIII-B. Los cuatro modelos

Level set geodésico (basado en bordes). El contorno se representa implícitamente como el nivel cero de una función ϕ ; un frente avanza con velocidad $g(|\nabla I|)$, rápida en zonas planas y casi nula en los bordes:

$$\frac{\partial \phi}{\partial t} = g(|\nabla I|) (\alpha + \beta \kappa) |\nabla \phi| + \nabla g \cdot \nabla \phi, \quad g = \frac{1}{1 + |\nabla (G_\sigma * I)|}. \quad (1)$$

Maneja cambios de topología de forma natural (el ET puede ser un anillo o varios focos), pero se fuga donde el borde es débil; se redujo su propagación para que no infle una buena semilla.

Level set variacional de Chan–Vese (basado en regiones). No usa bordes: coloca el contorno C de modo que el interior tenga una intensidad media c_1 y el exterior otra c_2 , minimizando la energía de Mumford–Shah

$$E(c_1, c_2, C) = \mu \text{Long}(C) + \lambda_1 \int_{\text{in}} |I - c_1|^2 + \lambda_2 \int_{\text{out}} |I - c_2|^2. \quad (2)$$

El criterio de *promedio de región* es robusto justo donde fallan los métodos de borde (realce difuso y con ruido), y el término de curvatura μ aporta suavidad tipo spline. Es el mejor de los cuatro.

B-spline (regularización de la frontera). Toma el resultado de región (Chan–Vese) y reescribe su frontera corte a corte como un B-spline cúbico periódico, $C(u) = \sum_i N_{i,3}(u) P_i$, con continuidad C^2 . No cambia la energía: impone una superficie lisa que elimina el dentado de la máscara de vóxeles, clave para la posterior reconstrucción 3D.

Snake paramétrico de Kass (explícito). El contorno es una curva spline cerrada $C(s)$ que se contrae sobre la región brillante minimizando

$$E = \int_0^1 \frac{1}{2} (\alpha |C'(s)|^2 + \beta |C''(s)|^2) + E_{\text{ext}}(C(s)) ds, \quad (3)$$

donde la energía interna (tensión α , rigidez β) la mantiene suave. Es el modelo deformable más intuitivo; se inicializa ligeramente dilatado y con salvaguarda anti-colapso para evitar que la curva se contraiga a un punto.

VIII-C. Resultados

La evaluación se hizo sobre un subconjunto de **20 casos ricos en ET** (seleccionados por volumen de realce), con la misma limpieza (Wiener→N4→percentil). La Tabla ?? reporta

el Dice medio, la mediana, el máximo y el número de casos que superan 0,75; se incluyen como referencia los dos mejores métodos por intensidad sobre *ese mismo subconjunto* (Otsu y GMM, mono-modalidad sobre T1c limpio con componente anclado).

Cuadro XIII
DICE DEL ET CON CONTORNOS DEFORMABLES (20 CASOS RICOS EN ET, TOTALMENTE AUTOMÁTICO). REFERENCIA: LOS DOS MEJORES MÉTODOS POR INTENSIDAD SOBRE EL MISMO SUBCONJUNTO.

Método	Dice medio	Mediana	Máx	casos > 0,75
Chan–Vese (variacional)	0,505	0,506	0,860	5
B-spline	0,473	0,465	0,794	2
Level set (geodésico)	0,455	0,475	0,781	2
Snake (spline)	0,450	0,484	0,795	2
Otsu T1c (ref., intensidad)	0,485	0,592	0,821	6
GMM T1c (ref., intensidad)	0,481	0,513	0,866	6




Figura 10. Dice-ET medio por método sobre los 20 casos ricos en ET. El level set variacional (Chan–Vese) encabeza, seguido de cerca por las dos líneas base por intensidad sobre el mismo subconjunto.

Tres lecturas, todas honestas. (i) *El prior de forma ayuda, pero poco*: Chan–Vese es el mejor método (0,505) y supera a las líneas base por intensidad *sobre el mismo subconjunto* (0,485 Otsu, 0,481 GMM), con casos individuales hasta 0,86; su mayor virtud es la *robustez* (las salvaguardas evitan los colapsos a 0 del bloque por intensidad). (ii) *El subconjunto es favorable*: al seleccionarse por volumen de ET, estos 20 casos son más fáciles que el conjunto con dispersión de tamaños de la Sec. ??; por eso incluso Otsu/GMM rinden $\approx 0,48$ aquí frente a $\approx 0,16/0,09$ allí. La comparación válida es *intra-subconjunto*, donde el contorno deformable es el mejor. (iii) *El techo persiste*: pese al *prior* de forma, el Dice medio se **estanca en torno a 0,50**. Esto *refuerza* la tesis de la Sec. ??: el límite es estructural, y ni siquiera un modelo clásico con forma lo despeja; la mejora real exigiría aprendizaje o un modelo estadístico de forma. En total, 26 combinaciones (caso, método) superan 0,75 y se reconstruyen en 3D (Sec. ??).

IX. INTERPOLACIÓN DE CONTORNOS ENTRE CORTES

Para densificar la representación 3D del realce —paso previo a la reconstrucción de superficie— se interpolan linealmente los contornos extraídos en cortes consecutivos, generando

contornos intermedios con resolución de auto-intersecciones. Esta sección cuantifica la fidelidad geométrica del interpolado y su robustez.

IX-A. Métricas de calidad contra GT real

Para cuantificar la fidelidad geométrica del interpolado se contrastó, para cada par de cortes (A, B) , el contorno reconstruido a $t = 0,5$ contra el corte real intermedio (*ground truth*) del dataset BraTS. Se reportan cuatro métricas: *Dice* e *IoU* de solapamiento de región (mejor cuanto mayor; calculadas rasterizando ambos polígonos en una grilla 512×512), distancia de Hausdorff bidireccional entre vértices (mejor cuanto menor) y error relativo de área $\text{areaErr} = |A_{\text{interp}} - A_{\text{gt}}|/A_{\text{gt}}$.

Cuadro XIV

MÉTRICAS DEL INTERPOLADO LINEAL A $t = 0,5$ CONTRA EL CORTE GT REAL INTERMEDIO. EL SOMBREADO VERDE INDICA QUE LA CELDA CUMPLE EL UMBRAL DE CALIDAD ($\text{Dice} \geq 0,80$, $\text{IoU} \geq 0,65$, $\text{HAUSDORFF} \leq 2,0$, $\text{AREAERR} \leq 0,20$).

Caso	Par ($A \rightarrow B$)	Dice	IoU	Hausdorff	AreaErr	Auto-verda
00008-100	70 $\rightarrow$ 72	0,855	0,746	1,265	0,142	No
00008-101	70 $\rightarrow$ 72	0,854	0,746	0,896	0,056	No
Promedio	—	0,855	0,746	1,081	0,099	—

Conviene remarcar una diferencia metodológica con la evaluación de la segmentación. Una validación contra el GT *sintético* reconstruido del propio dataset (es decir, contra la misma malla que el *pipeline* produce) tiende, por construcción, a saturar en 1 ($\text{Dice} \approx 0,997$). El protocolo aquí adoptado, en cambio, *descarta* el corte intermedio del par y mide el interpolado contra el GT *real* de ese corte, lo que castiga cualquier desviación topológica o de forma. Ambos enfoques son válidos y complementarios, pero no directamente comparables: los valores $\sim 0,85$ reportados reflejan la dificultad intrínseca de *predecir un corte ausente* a partir de sus vecinos, no un fallo del método.

IX-B. Experimento de stress sobre el resolutor

Para validar el módulo `SelfIntersectionResolver` se diseñó un experimento que fuerza una correspondencia patológica entre A y B :

1. Se toma el par del caso 00008-100 (`slice_0070.obj`, `slice_0072.obj`).
2. Rotación cíclica de los vértices de B por $k = n/2$ posiciones, donde n es la cantidad de vértices de B . Esto desalinea por completo la correspondencia angular inicial y, sin compensación, forzaría que los segmentos del interpolado a $t = 0,5$ se crucen entre sí.
3. Se interpola a $t = 0,5$ y, si aparecen auto-intersecciones, se resuelven con `SelfIntersectionResolver`.

El experimento demuestra que el *pipeline* completo (rotación óptima + *resampling* + interpolación + resolutor) es robusto frente a perturbaciones del orden cíclico de los vértices de entrada, que es exactamente el tipo de inconsistencia esperable cuando los contornos provienen de cortes independientes sin un punto de inicio canónico.




Figura 11. Experimento de *stress* sobre BraTS-GLI-00008-100. Izquierda: corrida normal con B original. Derecha: B rotado en $k = n/2 = 12$ vértices. En ambos casos el contorno verde es el interpolado a $t = 0,5$. La búsqueda de rotación óptima, seguida del resolutor, recupera una topología válida incluso bajo la rotación adversarial.

IX-C. Salida para reconstrucción 3D

Escribir los vértices con $z = 0$ basta para inspeccionar el resultado en 2D pero impide apilar varios contornos interpolados en un volumen tridimensional para reconstrucción posterior (p. ej. Poisson o *marching cubes* en VTK/ParaView). Para cerrar ese hueco, el módulo `generate_multi_t.py` genera 11 capas intermedias ($t = 0,0,0,1,\dots,1,0$) con la coordenada z real interpolada linealmente entre los dos cortes originales, $z(t) = z_A + t(z_B - z_A)$:

```
# 11 contornos interpolados con z real entre los
# cortes 70 y 72
python scripts/generate_multi_t.py \
  data/contours/BraTS-GLI-00008-100/slice_0070.obj \
  data/contours/BraTS-GLI-00008-100/slice_0072.obj \
  70 72
```

Cada corrida deposita los 11 `.obj` más un `preview_3d.png` y un `index.csv` (columnas `t`, `z`, `filename`, `n_vertices`, `self_int`). Ese `index.csv` es el punto de integración con el módulo de reconstrucción (Sec. ??): se consume directamente para apilar los contornos densificados y alimentar la superficie de *marching cubes*.

X. RECONSTRUCCIÓN Y VISUALIZACIÓN 3D

La representación volumétrica del ET —ya sea la máscara segmentada o la pila de contornos densificada (Sec. ??)—se lleva a superficie por dos vías complementarias: *marching cubes* [?] (validación de escala) y reconstrucción de Poisson *screened* [?] (comparación visual suave GT vs. predicción).

X-A. Mallas por *marching cubes* y validación de escala

Se generaron mallas del ET predicho (crecimiento de regiones) y del *ground truth*, con el espaciado físico aplicado y suavizado de Taubin, exportadas en OBJ y GLB. La Tabla ?? reúne las métricas. Dos lecturas. Primero, la **validación de**

escala es correcta: el volumen de la malla GT reproduce el volumen de ET del EDA en el mismo orden de magnitud (p.ej. 02060-100, 19 266 vs. 19 975 mm³; 00046-101, 25 685 vs. 25 306 mm³). Segundo, la **distancia media superficie-superficie** (2,6 a 42,7 mm) **no valida la predicción**; al contrario, cuantifica cuánto se *aleja* la malla predicha del GT en los casos difíciles (p.ej. 00498-100, donde la predicción multiplica por seis el volumen del GT). La reconstrucción por *marching cubes* es, por tanto, una herramienta de inspección y de validación de escala, no una medida de acierto.

X-B. Reconstrucción de Poisson de los contornos deformables

Para los 26 pares (caso, método) que superan 0,75 (Sec. ??) se reconstruyó la superficie del tumor con Poisson *screened* [?] a partir de la nube de puntos orientada de la predicción y del GT, y se renderizaron lado a lado (verde = GT, rojo = predicción), exportando además las mallas .ply. La Fig. ?? muestra el mejor caso (Chan–Vese, Dice = 0,86): las superficies del GT y la predicción son casi idénticas. Un visor 3D web autocontenido (Three.js) permite rotar, acercar y superponer ambas mallas en la exposición.

BrATS-GUI-02108-100 — Superficie de Poisson | variational_spline | Dice=0.859
GT (verde, izq.) vs. predicción (rojo, der.)




Figura 12. Reconstrucción de superficie de Poisson (caso 02108, Chan–Vese, Dice = 0,86): *ground-truth* (verde) vs. predicción (rojo).

XI. DISCUSIÓN Y LIMITACIONES

Por qué fallan los métodos por intensidad en el ET.

El ET no es un objeto “brillante y compacto” separable por intensidad: es un anillo delgado, heterogéneo y, en el escenario post-tratamiento, rodea una cavidad oscura. Esto rompe las hipótesis de cada método. *Otsu* supone un histograma con un modo brillante claro, pero T1c es *unimodal* (coeficiente de bimodalidad < 5/9 en los casos analizados), de modo que el umbral de la clase alta cae en un punto arbitrario y mezcla realce con tejido sano brillante. *Crecimiento de regiones* y *watershed* dependen de una semilla/marcador fiable; aun corregida la semilla (Sec. ??), la heterogeneidad del realce limita el crecimiento. *GMM multimodal* ilustra que **añadir modalidades no ayudó**: al agrupar T1c+T2w+T2-FLAIR captura un cúmulo amplio dominado por el edema, con alta sensibilidad pero Dice ínfimo (Fig. ??).




Figura 13. Mosaico de 3 vistas (axial/coronal/sagital) del caso 02060-100: original con GT y las segmentaciones.




Figura 14. Sobre-segmentación de la GMM multimodal (caso 00529-100): predicción roja muy superior al GT cian.

Qué aporta —y qué no— el *prior* de forma. Los contornos deformables (Sec. ??) confirman que el problema es de forma: el level set variacional de Chan–Vese es el mejor método global y, por sus salvaguardas, elimina los colapsos catastróficos a 0 del bloque por intensidad. Pero el Dice medio *se estanca en* $\approx 0,50$ aun en un subconjunto favorable, lo que delimita con honestidad el alcance de lo clásico: el *prior* de forma geométrico (suavidad, curvatura) no equivale a un *prior* de forma *estadístico* (la apariencia anular y heterogénea aprendida de muchos casos), que es lo que aportaría un modelo de forma o una red.

Limitaciones del registro demostrativo. El registro es rígido y se evaluó frente a una perturbación rígida conocida; por construcción no compensa deformaciones no rígidas (efecto de masa, cambios post-quirúrgicos) y su excelente TRE no debe extrapolarse a un escenario inter-sujeto o longitudinal real.

Alcance experimental. La segmentación por intensidad se evaluó sobre nueve casos, la de contornos deformables sobre

Cuadro XV
MÉTRICAS 3D POR CASO (*marching cubes*). LA VALIDACIÓN DE ESCALA (VOL. MALLA GT VS. EDA) ES CORRECTA; LA DISTANCIA SUPERFICIE-SUPERFICIE MIDE EL *alejamiento* PRED↔GT, NO ACIERTO.

Caso	Dice	Vért. pred	Vért. GT	Vol. pred (mm ³)	Vol. GT (mm ³)	Vol. GT EDA (mm ³)	Dist. media (mm)
02063-106	0,257	724	450	254,6	192,1	254,0	4,79
00529-100	0,407	298	722	112,4	424,9	501,0	2,13
02062-100	0,217	633	1704	187,8	908,4	1062,0	3,72
02063-102	0,283	824	3898	747,9	4706,2	4812,0	10,09
00498-100	0,157	48963	5906	29113,1	4535,9	4816,0	42,74
00463-101	0,280	49983	8044	27308,6	11258,8	11312,0	37,45
02060-100	0,451	33392	18583	19489,3	19266,1	19975,0	14,13
00046-101	0,509	15095	18109	11269,1	25685,0	25306,0	2,64

veinte (subconjunto rico en ET, y por tanto favorable), el registro sobre cuatro y la reconstrucción 3D sobre ocho; las cifras son indicativas, no un *benchmark* a gran escala. La interpolación se validó sobre dos pares de cortes.

XII. REPRODUCIBILIDAD

La canalización completa (en Python 3.11 con SIMPLEITK y scikit-image) es reproducible y lee los datos directamente desde los .zip. La Tabla ?? resume los parámetros clave.

Cuadro XVI
PARÁMETROS DEL PIPELINE.

Etapas	Configuración
Objetivo	ET (seg==3) sobre T1c
Limpieza	Wiener (3) → N4 (<i>shrink</i> 4) → percentil [0,5,99,5] → [0,1]
Otsu	multinivel n=3, clase alta
Region growing	semilla en ET más brillante, ventana [αI , máx], $\alpha = 0,65$
Watershed	marcador en ET brillante, gradiente de Sobel
GMM (intensidad)	4 componentes, T1c+T2w+T2-FLAIR
Semilla deformables	GMM 3 comp. sobre T1c; <i>fallback</i> a <i>blob</i> de T1c – T1n
Level set	geodésico (propagación 0,8; curvatura 3; advección 1,5; 120 iter)
Chan–Vese	morfológico, 35 iter, suavizado 3
B-spline	cúbico periódico sobre la frontera de Chan–Vese
Snake	Kass, init dilatada, salvaguarda anti-colapso
Reconstrucción 3D	<i>marching cubes</i> + Poisson <i>screened</i> (open3d)
Registro	Mattes MI (50 bins), Euler3D, <i>shrink</i> [4,2], sigmas [2,1], 150 iter
Semilla aleatoria	42
Datos	lectura directa desde .zip (BraTS 2024 GLI)

XIII. CONCLUSIONES Y TRABAJO FUTURO

El hallazgo central es claro y honesto: **los métodos clásicos son insuficientes para segmentar el tumor realzante en T1c** en BraTS 2024 GLI post-tratamiento, y el límite es *estructural* (la forma del realce), no de umbral. En el bloque *por intensidad*, ningún método base supera un Dice medio de 0,50; el mejor —crecimiento de regiones, 0,320— es apenas “el menos malo”, la multimodalidad mediante GMM no ayudó (sobre-segmentación), y ni el post-proceso exhaustivo (morfología, anclaje, ensamble por unión 0,370, histéresis) ni un *ablation* de la limpieza —que *mejora* el Dice y la separabilidad, +0,092— cambian la conclusión. Al añadir un *prior* de forma con

modelos clásicos de **contorno deformable**, el mejor método (Chan–Vese variacional) alcanza 0,505 de Dice medio y hasta 0,86 en casos con realce claro, superando a las líneas base por intensidad sobre el mismo subconjunto y ganando en robustez; pero *se estanca en torno a 0,50*, lo que **confirma**, en lugar de refutar, el techo estructural. En contraste, el registro rígido por información mutua sí resuelve con precisión su tarea (TRE sub-vóxel), la interpolación de contornos reproduce un corte ausente con Dice 0,855, y la reconstrucción 3D (*marching cubes* y Poisson) valida la escala física de las máscaras y permite la inspección visual.

Como trabajo futuro, estos límites motivan: (i) *priors* de forma *estadísticos* (modelos de forma activos, *atlas*) que capturen la apariencia anular del ET, más allá de la suavidad geométrica de los contornos deformables; (ii) una combinación multimodal más informada que la GMM ingenua; (iii) registro deformable para escenarios longitudinales; y (iv), naturalmente, el aprendizaje profundo, cuya necesidad este estudio cuantifica por contraste.

REFERENCIAS

- [1] U. Baid *et al.*, “The RSNA-ASNR-MICCAI BraTS 2021 benchmark on brain tumor segmentation and radiogenomic classification,” *arXiv:2107.02314*, 2021.
- [2] B. C. Lowekamp, D. T. Chen, L. Ibáñez and D. Blezek, “The design of SimpleITK,” *Frontiers in Neuroinformatics*, vol. 7, p. 45, 2013.
- [3] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [4] N. J. Tustison *et al.*, “N4ITK: Improved N3 bias correction,” *IEEE Trans. Med. Imag.*, vol. 29, no. 6, pp. 1310–1320, 2010.
- [5] D. Mattes, D. R. Haynor, H. Vesselle, T. K. Lewellyn and W. Eubank, “PET-CT image registration in the chest using free-form deformations,” *IEEE Trans. Med. Imag.*, vol. 22, no. 1, pp. 120–128, 2003.
- [6] L. Vincent and P. Soille, “Watersheds in digital spaces: an efficient algorithm based on immersion simulations,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 6, pp. 583–598, 1991.
- [7] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [8] W. E. Lorensen and H. E. Cline, “Marching cubes: A high resolution 3D surface construction algorithm,” *ACM SIGGRAPH Computer Graphics*, vol. 21, no. 4, pp. 163–169, 1987.
- [9] M. Kass, A. Witkin and D. Terzopoulos, “Snakes: Active contour models,” *International Journal of Computer Vision*, vol. 1, no. 4, pp. 321–331, 1988.
- [10] S. Osher and J. A. Sethian, “Fronts propagating with curvature-dependent speed: algorithms based on Hamilton–Jacobi formulations,” *Journal of Computational Physics*, vol. 79, no. 1, pp. 12–49, 1988.
- [11] V. Caselles, R. Kimmel and G. Sapiro, “Geodesic active contours,” *International Journal of Computer Vision*, vol. 22, no. 1, pp. 61–79, 1997.

- [12] T. F. Chan and L. A. Vese, "Active contours without edges," *IEEE Trans. Image Process.*, vol. 10, no. 2, pp. 266–277, 2001.
- [13] M. Kazhdan and H. Hoppe, "Screened Poisson surface reconstruction," *ACM Trans. Graphics*, vol. 32, no. 3, art. 29, 2013.
- [14] M. Correia de Verdier *et al.*, "The 2024 Brain Tumor Segmentation (BraTS) Challenge: Glioma Segmentation on Post-treatment MRI," *arXiv:2405.18368*, 2024.
- [15] M. M. Baig *et al.*, "Adapting nnU-Net for the BraTS 2024 post-treatment glioma segmentation challenge," *Neuro-Oncology Advances*, vol. 6, no. 1, art. vdae140, 2024.
- [16] L. Luque *et al.*, "Standardized evaluation of the extent of resection in adult gliomas using semi-supervised deep learning," *Frontiers in Radiology*, vol. 4, art. 1357341, 2024.
- [17] Á. Györfi, L. Szilágyi and L. Kovács, "A fully automatic and efficient brain tumor segmentation framework based on ensemble learning and atlas-based normality deviation," *Applied Sciences*, vol. 11, no. 2, art. 564, 2021.
- [18] M. Visser *et al.*, "Inter-rater agreement in glioma segmentations on longitudinal MRI," *NeuroImage: Clinical*, vol. 22, art. 101727, 2019.
- [19] D. N. Louis *et al.*, "The 2021 WHO Classification of Tumors of the Central Nervous System: a summary," *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021.
- [20] F. B. Mesfin and M. A. Al-Dhahir, "Gliomas," in *StatPearls*, Treasure Island, FL, USA: StatPearls Publishing, 2024.
- [21] D. Bhattacharya *et al.*, "Imaging assessment of post-treatment gliomas: a review," *Clinical Radiology*, vol. 79, no. 3, pp. e376–e392, 2024.