

Segmentación clásica del tumor realzante en glioma post-tratamiento sobre BraTS 2024

Abel Albuez, Victoria Acero y Santiago Gil
Maestría en Ingeniería de Sistemas y Computación
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Procesamiento de Imágenes Médicas, 2026
<https://github.com/AbelAlbuez/medical-image-processing>

Abstract—Automatic segmentation of the enhancing tumor subregion in post-treatment glioma MRI remains an open problem for classical methods, as the resection cavity and treatment-related changes drastically alter the intensity patterns these methods rely on. This work evaluates a fully classical pipeline, implemented with SimpleITK and without any deep-learning component, on 20 randomly selected cases from the BraTS 2024 GLI Post-Treatment dataset. The pipeline applies a preprocessing stage that combines a Wiener filter, N4 bias-field correction, and percentile normalization, followed by a rigid-registration demonstration using Mattes mutual information that achieves a sub-voxel target registration error of 0.007 mm on average. For segmentation, four intensity-based methods are evaluated on contrast-enhanced T1-weighted images—multilevel Otsu thresholding, region growing, watershed by markers, and multimodal Gaussian mixture models—whose best union ensemble reaches a mean Dice of 0.370. To overcome the structural ceiling of intensity-only approaches, a gadolinium-specific subtraction map computed as T1-contrast minus T1-native is introduced, yielding mean values of 0.24 within the enhancing tumor versus 0.04 in healthy tissue. This map drives two complementary methods: a FastMarching algorithm that uses it as a propagation-speed function (Dice 0.509 with a centroid seed, 0.286 with automatic seeding), and variational active contours, among which the Chan-Vese variational spline achieves the best mean Dice of 0.505 with automatic seeding and a maximum of 0.860 on the most favorable individual case. Results show that intensity-only methods have a structural ceiling imposed by the shape of the post-surgical enhancing tumor, while the T1c–T1n subtraction map provides a discriminative signal that enables classical methods to exceed Dice 0.50 without deep learning.

Index Terms—BraTS 2024 GLI, tumor realzante, segmentación clásica, FastMarching, contornos activos, Chan-Vese, SimpleITK, mapa de sustracción T1c–T1n.

I. INTRODUCCIÓN

Los gliomas son los tumores cerebrales primarios más frecuentes en adultos y su seguimiento por resonancia magnética es indispensable para evaluar la respuesta al tratamiento y detectar recurrencia temprana [1], [2]. El tumor realzante, definido como el tejido que capta el agente de contraste gadolinio en secuencias T1 post-contraste, constituye el marcador imagenológico de actividad tumoral residual más utilizado y un sustituto habitual de la respuesta terapéutica [3]. Su delimitación manual es laboriosa y presenta una variabilidad inter-observador significativa incluso entre radiólogos especializados [4], lo que motiva la búsqueda de métodos de segmentación automática.

El escenario post-tratamiento introduce complicaciones que no existen en los estudios preoperatorios. La cirugía deja una cavidad de resección que aparece oscura en T1c, la radioterapia genera cambios inflamatorios que pueden simular realce tumoral, y el gadolinio persiste en tejidos de resección no tumorales. Como resultado, el tumor realzante ya no es un objeto brillante y compacto, sino frecuentemente un anillo delgado y heterogéneo que rodea una cavidad oscura, lo que rompe las hipótesis de separabilidad por intensidad sobre las que se apoyan los métodos clásicos.

El reto BraTS 2024 GLI Post-Treatment [5] es la primera edición del desafío BraTS centrada explícitamente en este escenario, con cuatro sub-regiones anatómicas anotadas: núcleo no realzante, hiperintensidad FLAIR sin realce, tumor realzante y cavidad de resección. Este marco provee, por primera vez de forma pública, anotaciones con estas cuatro clases en imágenes post-tratamiento, lo que lo convierte en un banco de pruebas natural para estudiar los límites de los métodos clásicos.

Este trabajo evalúa una canalización de segmentación del tumor realzante implementada íntegramente con SimpleITK [6] sobre 20 casos aleatorios de dicho conjunto, sin emplear aprendizaje profundo en ninguna etapa. El análisis se concentra en caracterizar empíricamente qué componentes de la señal multimodal son críticos para superar los métodos de intensidad pura e identificar dónde reside el cuello de botella en el desempeño clásico.

II. TRABAJOS RELACIONADOS

La segmentación automática de gliomas en BraTS ha estado dominada en los últimos años por arquitecturas de aprendizaje profundo. Györfi et al. [7] proponen una canalización híbrida que combina normalización de histogramas, un atlas de desviación de la normalidad y un ensamble de bosques aleatorios sobre características multimodales por vóxel. El sistema alcanza un coeficiente de Dice global de aproximadamente 86% sobre los conjuntos BraTS 2015 y 2019 con un tiempo de cómputo de unos 58 segundos en CPU, estableciendo los métodos basados en intensidad y atlas como una alternativa eficiente. No obstante, su evaluación corresponde al escenario preoperatorio y aborda el tumor en su totalidad, sin aislar el tumor realzante en el contexto post-quirúrgico.

Baig et al. [8] abordan explícitamente el escenario post-tratamiento mediante redes nnU-Net 3D entrenadas sobre 647 RM de gliomas difusos provenientes de siete repositorios públicos. El modelo, que recibe las cuatro modalidades estándar como entrada, reporta un Dice mediano entre 0,82 y 0,94 por sub-región, con correlaciones superiores a $R^2 = 0,94$ entre volúmenes predichos y anotados manualmente. Un hallazgo central de ese trabajo es que una red entrenada conjuntamente sobre casos pre y post-tratamiento reduce los falsos positivos sobre la cavidad de resección del 59% al 7%, evidenciando que el escenario post-quirúrgico requiere información de contexto multimodal que no puede inferirse de una sola modalidad.

Luque et al. [9] desarrollan un modelo U-Net para cuantificar el grado de resección en RM tomadas dentro de las 72 horas posteriores a la cirugía. El modelo alcanza un Dice medio de $0,52 \pm 0,03$ sobre un conjunto externo de 248 casos, comparable a la variabilidad inter-observador, y clasifica el grado de resección con una precisión de 0,90 y una sensibilidad de 0,87. Ese estudio confirmó que un Dice en torno a 0,50 ya ofrece valor pronóstico equivalente a la evaluación clínica.

El presente trabajo se enmarca en este panorama al cuantificar el desempeño de métodos puramente clásicos en el mismo escenario post-tratamiento de BraTS 2024, introduciendo el mapa de sustracción T1c–T1n como señal específica del gadolinio para guiar tanto un algoritmo de Fast-Marching como contornos activos variacionales.

III. BASE DE DATOS

El conjunto de datos utilizado es el subconjunto de entrenamiento de BraTS 2024 GLI Post-Treatment [5]. La cohorte completa comprende 1621 casos de adultos con gliomas difusos provenientes de siete instituciones internacionales, con volúmenes en formato NIfTI que incluyen cuatro modalidades co-registradas a un espacio común y con extracción del cráneo aplicada: T1 nativo (T1n), T1 con contraste de gadolinio (T1c), T2 ponderado (T2w) y T2-FLAIR. Las anotaciones definen cuatro sub-regiones: núcleo no realzante, hiperintensidad FLAIR sin realce, tumor realzante y cavidad de resección. En este trabajo el objetivo exclusivo es la segmentación del tumor realzante.

Se seleccionaron 20 casos al azar del conjunto de entrenamiento anotado. Un análisis exploratorio previo sobre 100 casos confirmó que la geometría es homogénea en todo el subconjunto (Tabla I) y que T1c es la modalidad con mayor separabilidad para el tumor realzante, con una razón discriminante de Fisher (FDR) mediana de 1,32, casi el triple de T2-FLAIR y más de diez veces superior a T1n. Esta diferencia justifica la elección de T1c como modalidad principal. El volumen del tumor realzante presenta una mediana de 4814 mm^3 con un rango amplio (desde menos de 100 mm^3 hasta casi $90\,000 \text{ mm}^3$), y aproximadamente el 22% de los casos no presentan tumor realzante visible tras la resección.

Table I
GEOMETRÍA DE LOS 20 CASOS UTILIZADOS.

Propiedad	Valor
Dimensiones (vóxeles)	$182 \times 218 \times 182$
Espaciado	$1,0 \times 1,0 \times 1,0 \text{ mm}$ (isotrópico)
Modalidades	T1n, T1c, T2w, T2-FLAIR
FDR mediana T1c (ET vs sano)	1,32
FDR mediana T2-FLAIR	0,47

IV. MÉTODOS

La canalización propuesta consta de cuatro etapas principales. En primer lugar, el preprocesamiento acondiciona las imágenes para los métodos de segmentación. A continuación, un registro rígido demostrativo valida la capacidad de alineamiento en escenarios externos. Sobre las imágenes preprocesadas se evalúan métodos clásicos de intensidad y un ensamble de sus predicciones. Finalmente, se introducen dos enfoques que explotan el mapa de sustracción T1c–T1n: el algoritmo de FastMarching y los contornos activos variacionales. A lo largo de todo el trabajo se respeta una regla fundamental: la anotación de referencia se usa únicamente para ubicar semillas de inicialización y calcular métricas de evaluación, pero nunca para construir las máscaras de salida. Conviene aclarar que los experimentos en los que la semilla se deriva de la anotación —como la semilla centroide o el vóxel de máxima intensidad dentro del tumor realzante— no representan métodos completamente automáticos, sino cotas superiores o análisis diagnósticos del comportamiento del algoritmo.

A. Preprocesamiento y registro

El preprocesamiento se aplica sobre T1c y T1n en tres pasos sucesivos. Un filtro de Wiener adaptativo con ventana de tamaño 3 reduce el ruido intrínseco a la adquisición de resonancia magnética; se aplica antes de la corrección de campo para evitar que el ruido sea interpretado como inhomogeneidad espacial. La corrección del campo de sesgo mediante el algoritmo N4ITK [10] compensa la variación del campo B_1 del escáner, que provoca que la misma estructura aparezca con distinta intensidad según su posición en el volumen. Por último, la normalización por percentiles [0,5; 99,5] mapea las intensidades al intervalo $[0, 1]$ dentro de la máscara cerebral, homogeneizando la escala entre pacientes adquiridos con diferentes equipos o protocolos.

Para confirmar que este preprocesamiento mejora la discriminabilidad del tumor realzante, se realizó un análisis de ablación del preprocesamiento en cuatro configuraciones de entrada crecientes (Tabla II). Tanto el coeficiente de Dice como la FDR y la distancia de Bhattacharyya del tumor realzante frente al tejido sano crecen monótonamente al añadir cada etapa, con N4 como el paso de mayor contribución individual. Esto confirma que el preprocesamiento ayuda sistemáticamente y que el techo de desempeño posterior es de naturaleza estructural, no instrumental.

Table II
ANÁLISIS DE ABLACIÓN DEL PREPROCESAMIENTO. LA SEPARABILIDAD DEL TUMOR REALZANTE Y EL DICE CRECEN MONÓTONAMENTE. FDR = RAZÓN DISCRIMINANTE DE FISHER; BHATT. = DISTANCIA DE BHATTACHARYYA.

Entrada	Otsu anc.	Unión+post	FDR	Bhatt.
Crudo	0,264	0,278	1,21	0,328
N4	0,333	0,339	1,56	0,448
N4 + norm.	0,311	0,314	1,72	0,496
Completo	0,353	0,370	1,80	0,498

El registro rígido se implementa con información mutua de Mattes [11] y transformación Euler3D en un esquema multi-resolución de dos niveles, con 150 iteraciones y muestreo aleatorio del 10% de los vóxeles cerebrales. Dado que BraTS 2024 provee las modalidades ya co-registradas, este módulo se incluye como validación técnica de la canalización y como preparación para escenarios externos donde las modalidades no estén alineadas previamente. Para evaluarlo de forma controlada se aplica una perturbación rígida conocida sobre T1c (rotación $(6, 4, -5)^\circ$, traslación $(5, -4, 3)$ mm) y se mide el error de registro objetivo (TRE) al recuperarla. Los cuatro casos de prueba presentan TRE sub-vóxel en todos los casos (Tabla III).

Table III
REGISTRO RÍGIDO DEMOSTRATIVO. TRE SUB-VÓXEL EN LOS CUATRO CASOS EVALUADOS.

Caso	TRE (mm)	Dice antes	Dice después	t (s)
00529-100	0,0064	0,908	0,963	8,1
02063-102	0,0095	0,911	0,965	6,7
02060-100	0,0082	0,920	0,962	7,2
00005-100	0,0054	0,887	0,961	7,0
Media	0,0074	0,906	0,963	7,25

B. Métodos clásicos de intensidad

Sobre T1c preprocesado se evalúan cuatro métodos de segmentación clásicos. El umbral de Otsu multinivel con tres clases [12] toma la clase de mayor intensidad como candidato al tumor realzante. El crecimiento de regiones parte de una semilla en el vóxel de mayor intensidad dentro del tumor realzante y expande la región hacia los vecinos cuya intensidad cae en la ventana relativa $[\alpha \cdot I_{\text{semilla}}, \text{max}]$, con $\alpha = 0,65$ calibrado por barrido sobre el promedio de los casos. La segmentación por *watershed* con marcadores [13] usa el mismo vóxel de máxima intensidad como marcador de primer plano y el gradiente de Sobel como función de energía. Por último, se evalúa una mezcla de gaussianas con cuatro componentes sobre T1c, T2w y T2-FLAIR conjuntamente [14], como referencia para verificar si incorporar más modalidades mejora la discriminación.

Un hallazgo relevante surge del comportamiento de la semilla. En el escenario post-tratamiento, el tumor realzante

forma típicamente un anillo alrededor de la cavidad de resección, que aparece oscura en T1c. Si la semilla se ubica en el centroide del tumor realzante, cae dentro de esa cavidad oscura y el crecimiento de regiones produce máscaras degeneradas con Dice cercano a cero. La solución adoptada es anclar la semilla al vóxel de mayor intensidad dentro del tumor realzante, lo que rescata cuatro casos que de otro modo obtendrían Dice nulo (Tabla IV).

Table IV
EFECTO DE ANCLAR EL COMPONENTE CONEXO A LA SEMILLA DE MÁXIMA INTENSIDAD. LOS CUATRO CASOS PASARON DE DICE 0,000 AL USAR LA SEMILLA EN EL CENTROIDE.

Caso	Comp. mayor	Comp. anclado
02063-106	0,000	0,181
00529-100	0,000	0,322
02062-100	0,000	0,413
02063-102	0,000	0,638

Dado que cada método falla en casos distintos, se evaluaron cuatro estrategias de ensamble sobre las predicciones ancladas de Otsu, crecimiento de regiones y *watershed*: unión simple, voto de mayoría, intersección, y unión con post-proceso morfológico anclado. La mejor estrategia es la unión con post-proceso, con un Dice medio de 0,370 (Tabla V). Ningún método individual ni ensamble supera el umbral de Dice 0,50, lo que sugiere que el límite es de naturaleza estructural y no de ajuste de parámetros, conclusión corroborada por el análisis de ablación del preprocesamiento.

Table V
DICE MEDIO DE LOS MÉTODOS CLÁSICOS Y ENSAMBLES (20 CASOS). NINGUNO SUPERA 0,50. LOS RESULTADOS SON INDICATIVOS DADA LA MUESTRA DE 20 CASOS.

Método	Dice	Jaccard	Sensib.	Especif.
Otsu anclado	0,353	0,221	0,521	0,995
RegionGrowing	0,342	0,210	0,398	0,999
Watershed	0,223	0,140	0,141	0,999
GMM multimodal	0,094	0,052	0,630	0,965
Unión simple	0,369	0,226	0,630	0,997
Unión + post-proceso	0,370	0,228	0,630	0,997
Voto mayoría	0,334	—	—	—
Intersección	0,204	—	—	—

La Fig. 1 ilustra el comportamiento de estos métodos en tres vistas. El crecimiento de regiones con semilla anclada captura razonablemente el anillo del tumor realzante, mientras la mezcla de gaussianas multimodal produce una sobresegmentación amplia que incluye edema y estructuras adyacentes: alta sensibilidad (0,630) pero Dice de 0,094, evidencia de que añadir modalidades sin un modelo de forma no compensa la heterogeneidad del tumor realzante post-quirúrgico.

C. Mapa de sustracción T1c–T1n y FastMarching

El gadolinio no atraviesa la barrera hematoencefálica intacta, por lo que el realce en T1c respecto a T1n es específico del tejido tumoral activo o de zonas de ruptura de




Figure 1. Comparativa de métodos clásicos en tres vistas (caso BraTS-GLI-02060-100). El contorno cian delimita la anotación y la superposición roja corresponde a la predicción de cada método. La mezcla de gaussianas (columna derecha) sobresegmenta claramente, capturando tejido periférico no tumoral.

dicha barrera. Esta propiedad se explota mediante el mapa de sustracción $S = \text{clip}(T1c_n - T1n_n, 0, 1)$, donde $T1c_n$ y $T1n_n$ se normalizan con el mismo factor máximo conjunto para preservar la relación de escala entre ambas modalidades. El mapa resultante, suavizado con $\sigma = 0,8$, presenta valores medios de 0,24 dentro del tumor realzante y de 0,04 en tejido sano (Fig. 2), con los vasos sanguíneos en el extremo superior ($S > 0,55$), excluibles por umbral. Esta discriminación no es posible con $T1c$ aislado porque el tejido sano brillante también lo era antes del contraste.




Figure 2. Mapa de sustracción $T1c - T1n$ (caso BraTS-GLI-02119-101, corte axial). De izquierda a derecha: $T1n$ sin contraste, $T1c$ con contraste y mapa de diferencia en escala de calor. El tumor realzante aparece en amarillo-blanco, con valores en torno a 0,24, mientras el tejido sano permanece oscuro.

El algoritmo de FastMarching resuelve la ecuación Eikonal $|\nabla T(x)| \cdot S(x) = 1$ desde una semilla x_0 con condición inicial $T(x_0) = 0$. En las regiones de alto realce el frente avanza rápidamente, produciendo tiempos de llegada bajos; en tejido sano avanza lento, produciendo tiempos altos; y en los bordes del tumor, donde el mapa cae abruptamente, el frente se desacelera de forma natural. La predicción final se obtiene umbralizando $T \leq t^* = 35$, valor calibrado empíricamente.

La localización de la semilla inicial es determinante para el resultado. Se evaluaron tres estrategias: una semilla automática sin acceso a la anotación, que selecciona el vóxel con mayor producto $T1c_{\text{limpio}} \times S$ excluyendo vasos, con suavizado uniforme de tamaño 5 para robustez; la semilla en el

centroide geométrico del tumor realzante según la anotación, que representa una cota superior teórica del método; y una semilla aleatoria dentro de la anotación, que evalúa la robustez del algoritmo ante variaciones en la posición inicial. Los resultados se presentan en la Tabla VI y la Fig. 3.

Table VI
RESULTADOS DEL FASTMARCHING SEGÚN LA ESTRATEGIA DE SEMILLA (20 CASOS CON TUMOR REALZANTE PRESENTE). LAS SEMILLAS BASADAS EN LA ANOTACIÓN REPRESENTAN COTAS SUPERIORES, NO MÉTODOS COMPLETAMENTE AUTOMÁTICOS.

Semilla	Dice	Máx	Mín (> 0)
Automática	0,286	0,710	0,040
Aleatoria en anotación	0,324	0,600	0,060
Centroide de anotación	0,509	0,761	0,031




Figure 3. FastMarching con tres estrategias de semilla sobre el mismo caso. La semilla centroide produce la mejor cobertura (Dice 0,761). La brecha promedio entre la semilla automática (Dice 0,286) y la semilla centroide (Dice 0,509) sugiere que el desempeño del FastMarching está fuertemente condicionado por la localización inicial de la semilla.

D. Contornos activos variacionales

Los contornos activos abordan la segmentación como un problema de minimización de energía sobre la forma y posición de un contorno deformable, lo que los hace menos sensibles a la posición exacta de la semilla que el FastMarching, pues el contorno puede corregirse iterativamente. Se implementaron cuatro variantes, todas con una inicialización automática híbrida: una mezcla de gaussianas de tres componentes sobre $T1c$ localiza la masa realzante —la componente de mayor media— y, cuando ésta degenera por captar tejido sano brillante, se recurre al *blob* dominante del mapa de sustracción. Una salvaguarda revierte a esta semilla cualquier evolución que colapse, se fugue en volumen o se desplace a otra región, de modo que un contorno degenerado nunca puntuá por debajo de la inicialización.

El spline variacional de Chan-Vese [15] minimiza la diferencia entre las medias de intensidad dentro y fuera del contorno, expresada como

$$E(C, c_1, c_2) = \mu|C| + \lambda_1 \int_{\text{int}(C)} (u_0 - c_1)^2 dx + \lambda_2 \int_{\text{ext}(C)} (u_0 - c_2)^2 dx, \quad (1)$$

sin depender del gradiente de la imagen, lo que lo hace robusto a bordes difusos característicos del tumor realzante post-quirúrgico. La variante B-spline regulariza la frontera del

resultado de Chan–Vese reescribiéndola corte a corte como un B-spline cúbico periódico con continuidad C^2 , lo que suaviza el dentado de la máscara de vóxeles sin añadir parámetros libres. El *level set* geodésico [16] evoluciona una función de distancia con signo guiada por $g(x) = 1/(1 + |\nabla G_\sigma * u_0|^2)$, que se aproxima a cero en los bordes fuertes de la imagen y desacelera la propagación del frente. El snake paramétrico clásico minimiza la energía combinada de rigidez, elasticidad y fuerza imagen sobre un contorno discretizado.

La Fig. 4 compara todos los métodos del trabajo sobre un caso representativo. Los resultados cuantitativos de los contornos activos se muestran en la Tabla VII.

Table VII
RESULTADOS DE LOS CONTORNOS ACTIVOS Y DEL FASTMARCHING (20 CASOS). LA COLUMNA “>0,75” INDICA CUÁNTOS CASOS SUPERAN ESE DICE. LOS RESULTADOS SON INDICATIVOS DADO EL TAMAÑO DE LA MUESTRA.

Método	Dice	Mediana	Máx	> 0,75
Spline var. Chan–Vese	0,505	0,506	0,860	5
B-spline	0,473	0,465	0,794	2
Level set geod.	0,455	0,475	0,781	2
Snake param.	0,450	0,484	0,795	2
FM centroide (cota sup.)	0,509	—	0,761	—
FM automática	0,286	—	0,710	—

V. VISUALIZACIÓN 3D

Para facilitar la inspección visual, se generaron mallas tridimensionales de la predicción y la anotación mediante el algoritmo *marching cubes* [17], aplicando el espaciado físico real de los vóxeles y un suavizado de Taubin. Para la comparación visual de superficies, las mallas de la predicción y la anotación se reconstruyen además mediante reconstrucción de Poisson *screened* [18] a partir de su nube de puntos orientada, obteniendo superficies suaves y cerradas. Las mallas se exportan en formato PLY y se integran en un visor web interactivo basado en Three.js que permite superponer ambas mallas con control de opacidad y alternar entre vista 2D y 3D. La validación de escala confirma que el volumen de la malla de referencia reproduce el calculado en el análisis exploratorio con un error relativo inferior al 5% en 7 de los 8 casos evaluados, lo que garantiza la consistencia geométrica del pipeline.

La Fig. 5 muestra el caso con mayor Dice del trabajo, el caso 02108-100 segmentado con el spline variacional Chan–Vese, con un Dice de 0,860. La mayor parte del volumen tumoral se captura correctamente; los falsos positivos visibles en rojo coinciden con zonas perilesionales de alta intensidad en T1c que el mapa de sustracción no discrimina completamente.

VI. RESULTADOS Y DISCUSIÓN

La Tabla VIII presenta todos los métodos ordenados por Dice medio. El análisis permite identificar tres regímenes de desempeño diferenciados.

Los métodos de intensidad pura sobre T1c quedan limitados a un rango de Dice entre 0,09 y 0,37. El análisis de ablación

confirmó que este techo es estructural: aun con la entrada más separable posible (FDR 1,80), el Dice del mejor ensamble se estanca en 0,370. La razón es geométrica: el histograma de T1c es unimodal en la mayoría de los casos post-tratamiento, de modo que el umbral alto de Otsu cae en un punto arbitrario que mezcla realce con tejido sano brillante. El crecimiento de regiones y el *watershed* pueden localizarse correctamente cuando la semilla está bien ubicada, pero la heterogeneidad del anillo post-quirúrgico limita su expansión. La mezcla de gaussianas multimodal ilustra que incorporar T2w y T2-FLAIR sin un modelo de forma empeora el resultado: captura un cúmulo amplio dominado por el edema, con alta sensibilidad pero Dice de 0,094.

El mapa de sustracción T1c–T1n cambia cualitativamente este panorama. Todos los métodos que incorporan esta señal superan o igualan el mejor método de intensidad pura. El motivo es que la diferencia T1c–T1n es específica del gadolinio: el tejido sano brillante en T1c también lo era en T1n, de modo que su diferencia es cercana a cero, mientras que el tumor realzante acumula contraste y produce una diferencia alta.

Entre los métodos avanzados, el spline variacional Chan–Vese y el FastMarching con semilla centroide son comparables en Dice medio (0,505 y 0,509 respectivamente), pero difieren en robustez. El FastMarching con semilla automática baja a 0,286 cuando la semilla cae en tejido perilesional o en un vaso sanguíneo, porque la propagación unidireccional no puede corregirse. Los contornos activos, al minimizar una energía global de forma iterativa, son más tolerantes a variaciones en la semilla: el spline variacional mantiene Dice 0,505 con semilla automática.

En términos de comparación con la literatura, los mejores métodos clásicos quedan aproximadamente 0,35 puntos de Dice por debajo de nnU-Net [8] en promedio. No obstante, algunos casos individuales alcanzan Dice altos, como 0,860 con el spline variacional, lo que muestra que el enfoque puede ser competitivo en casos con tumor realzante bien definido, aunque estos resultados son indicativos dado el tamaño de la muestra de 20 casos.

Table VIII
COMPARACIÓN GLOBAL DE TODOS LOS MÉTODOS (20 CASOS).
AMARILLO : DICE $\geq$ 0,40. ROJO : DICE $<$ 0,40. LOS MÉTODOS CON SEMILLA DE COTA SUPERIOR NO SON COMPLETAMENTE AUTOMÁTICOS.

Método	Dice	Máx
FM centroide (cota sup.)	0,509	0,761
Spline var. Chan–Vese	0,505	0,860
B-spline	0,473	0,794
Level set geod.	0,455	0,781
Snake param.	0,450	0,795
Sustracción T1c–T1n	0,447	0,792
GMM 2D	0,374	0,828
Unión+post (ensamble)	0,370	—
FM automática	0,286	0,710
Rango doble	0,238	0,589
Otsu base	0,164	—
GMM multimodal	0,094	—




Figure 4. Comparativa de todos los métodos del trabajo (caso BraTS-GLI-02169-100, corte axial $z = 69$). El contorno cian delimita la anotación de referencia y el color de relleno corresponde a la predicción de cada método. Los contornos activos variacionales (fila inferior) logran la mejor correspondencia con la anotación, seguidos del FastMarching. Los métodos de intensidad pura (filas superiores) presentan sobresegmentación o subsegmentación sistemática.

En cuanto a las limitaciones, el estudio se basa en 20 casos aleatorios y las cifras son indicativas; estudios futuros deberán validarlas sobre muestras más amplias e incluso reportar desviaciones estándar. El registro se evaluó sobre una perturbación rígida conocida y no generaliza directamente a deformaciones no rígidas en escenarios longitudinales. La semilla automática del FastMarching falla cuando el vóxel de mayor score coincide con un vaso sanguíneo o con tejido perilesional de alta intensidad en T1c.

VII. CONCLUSIONES

Este trabajo cuantifica empíricamente los alcances y límites de los métodos clásicos para la segmentación del tumor

realzante en BraTS 2024 GLI post-tratamiento. El hallazgo más importante es que los métodos de intensidad pura sobre T1c presentan un techo estructural de Dice en torno a 0,37, impuesto por la forma del tumor realzante post-quirúrgico y no por el preprocesamiento, cuyo análisis de ablación muestra que mejora la separabilidad de forma sistemática. El mapa de sustracción T1c–T1n rompe ese techo al proporcionar una señal específica del gadolinio que distingue el realce tumoral del tejido sano brillante. Tanto el algoritmo de FastMarching como los contornos activos variacionales, guiados por dicho mapa, superan Dice 0,50 con semilla centroide o con semilla automática respectivamente. El spline variacional Chan–Vese emerge como el mejor método del trabajo con un Dice medio




Figure 5. Visor 3D interactivo: anotación de referencia en verde y predicción del spline variacional Chan–Vese en rojo. Caso 02108-100, Dice 0,860. Las zonas verdes sin rojo corresponden a falsos negativos y las rojas sin verde a falsos positivos.

de 0,505 y un máximo individual de 0,860, siendo además el más robusto a la posición de la semilla gracias a su formulación variacional.

La brecha entre la semilla automática y la semilla centroide en el FastMarching (0,286 frente a 0,509) señala la localización de la semilla como la principal línea de mejora: reemplazar la heurística actual por un detector de punto liviano podría elevar el desempeño automático al nivel de la cota superior sin modificar el resto del pipeline. Adicionalmente, el pipeline de preprocesamiento y el mapa de sustracción son directamente reutilizables como etapa de entrada para modelos de aprendizaje profundo, lo que constituye una contribución modular con valor independiente.

REFERENCES

- [1] D. N. Louis *et al.*, “The 2021 WHO Classification of Tumors of the Central Nervous System: a summary,” *Neuro-Oncology*, vol. 23, no. 8, pp. 1231–1251, 2021.
- [2] F. B. Mesfin and M. A. Al-Dhahir, “Gliomas,” in *StatPearls*, StatPearls Publishing, 2024.
- [3] D. Bhattacharya *et al.*, “Imaging assessment of post-treatment gliomas: a review,” *Clinical Radiology*, vol. 79, no. 3, pp. e376–e392, 2024.
- [4] M. Visser *et al.*, “Inter-rater agreement in glioma segmentations on longitudinal MRI,” *NeuroImage: Clinical*, vol. 22, art. 101727, 2019.
- [5] M. Correia de Verdier *et al.*, “The 2024 Brain Tumor Segmentation (BraTS) Challenge: Glioma Segmentation on Post-treatment MRI,” *arXiv:2405.18368*, 2024.
- [6] B. C. Lowekamp, D. T. Chen, L. Ibáñez and D. Blezek, “The design of SimpleITK,” *Frontiers in Neuroinformatics*, vol. 7, p. 45, 2013.
- [7] Á. Györfi, L. Szilágyi and L. Kovács, “A fully automatic procedure for brain tumor segmentation from multi-spectral MRI records using ensemble learning and atlas-based data enhancement,” *Applied Sciences*, vol. 11, no. 2, art. 564, 2021.
- [8] S. Baig *et al.*, “Segmentation of pre- and posttreatment diffuse glioma tissue subregions including resection cavities,” *Neuro-Oncology Advances*, vol. 6, no. 1, art. vdae140, 2024.
- [9] A. Bjørnerud *et al.*, “Standardized evaluation of the extent of resection in glioblastoma with automated early post-operative segmentation,” *Frontiers in Radiology*, vol. 4, art. 1357341, 2024.
- [10] N. J. Tustison *et al.*, “N4ITK: Improved N3 bias correction,” *IEEE Trans. Med. Imag.*, vol. 29, no. 6, pp. 1310–1320, 2010.
- [11] D. Mattes, D. R. Haynor, H. Vesselle, T. K. Lewellyn and W. Eubank, “PET-CT image registration in the chest using free-form deformations,” *IEEE Trans. Med. Imag.*, vol. 22, no. 1, pp. 120–128, 2003.
- [12] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.

- [13] L. Vincent and P. Soille, “Watersheds in digital spaces: an efficient algorithm based on immersion simulations,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 6, pp. 583–598, 1991.
- [14] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [15] T. F. Chan and L. A. Vese, “Active contours without edges,” *IEEE Trans. Image Process.*, vol. 10, no. 2, pp. 266–277, 2001.
- [16] V. Caselles, R. Kimmel and G. Sapiro, “Geodesic active contours,” *Int. J. Computer Vision*, vol. 22, no. 1, pp. 61–79, 1997.
- [17] W. E. Lorensen and H. E. Cline, “Marching cubes: A high resolution 3D surface construction algorithm,” *ACM SIGGRAPH*, vol. 21, no. 4, pp. 163–169, 1987.
- [18] M. Kazhdan and H. Hoppe, “Screened Poisson surface reconstruction,” *ACM Trans. Graphics*, vol. 32, no. 3, art. 29, 2013.