

Pontificia Universidad Javeriana

Departamento de Ingeniería de Sistemas

Procesamiento de Imágenes Médicas

Taller 2 — Segmentación por Umbrales

Abel Albuez · Victoria Acero · Santiago Gil

aa-albuezs@javeriana.edu.co · jv.acero@javeriana.edu.co · santiago_gil@javeriana.edu.co

Bogotá D.C., Colombia — Abril 2026

Resumen

Este documento reporta la implementación y análisis experimental de tres métodos de segmentación por umbrales aplicados a imágenes de resonancia magnética (MRI) que contienen patologías oncológicas: tumor cerebral, cáncer de mama y tumor hepático. Los métodos implementados son: **Umbral Binario** (`BinaryThresholdImageFilter`), **Método de Otsu** (`OtsuMultipleThresholdsImageFilter`) y **Agrupamiento K-means** (`ScalarImageKmeansImageFilter`), todos implementados en Python con la biblioteca ITK. Los rangos de umbral se fundamentan en el análisis del histograma de intensidades obtenido mediante 3D Slicer.

1. Introducción

La segmentación de imágenes médicas es una etapa fundamental en el análisis cuantitativo de estudios de resonancia magnética. Su objetivo es delimitar automáticamente regiones de interés, separándolas del tejido sano circundante. Esta delimitación es un prerequisite para tareas clínicas y de investigación como la medición de volumen tumoral, la planificación quirúrgica y el seguimiento terapéutico.

Los métodos de segmentación por umbrales explotan la distribución de intensidades de la imagen: bajo el supuesto de que las distintas estructuras anatómicas presentan rangos de intensidad diferenciados, es posible asignar etiquetas de clase a cada vóxel en función de si su valor cae dentro o fuera de un intervalo predefinido.

Filtro ITK	Tipo	Descripción	Ref.
<code>BinaryThresholdImageFilter</code>	Manual	Umbralización binaria con rango [lower, upper] definido a partir del histograma	[1]
<code>OtsuMultipleThresholdsImageFilter</code>	Automático	Calcula n umbrales óptimos maximizando la varianza inter-clase	[2]
<code>ScalarImageKmeansImageFilter</code>	Clustering	Agrupar los vóxeles en k clases por similitud de intensidad	[3]

Tabla 1. Métodos de segmentación implementados en este taller.

2. Marco Teórico

2.1 Segmentación por umbrales en imágenes MRI

La umbralización es el método de segmentación más directo. La idea fundamental es que las distintas estructuras del tejido producen distribuciones de intensidad diferenciadas en el histograma.

Principio fundamental

Los umbrales **nunca se definen con un valor único**, sino siempre como un intervalo **$[\tau_{\text{lower}}, \tau_{\text{upper}}]$** . El punto de partida obligatorio es el **análisis del histograma** de cada imagen.

2.2 Umbral Binario

El filtro de umbral binario asigna a cada vóxel uno de dos valores: $v_{\text{inside}} = 1$ si $\tau_l \leq I(x,y,z) \leq \tau_u$, y $v_{\text{outside}} = 0$ en otro caso.

Parámetro ITK	Tipo	Descripción
<code>SetLowerThreshold(τ_l)</code>	float	Límite inferior del rango de interés
<code>SetUpperThreshold(τ_u)</code>	float	Límite superior del rango de interés
<code>SetInsideValue(v)</code>	float	Valor asignado a vóxeles dentro del rango
<code>SetOutsideValue(v)</code>	float	Valor asignado a vóxeles fuera del rango

Tabla 2. Parámetros del *BinaryThresholdImageFilter*.

2.3 Método de Otsu

El método de Otsu calcula automáticamente los umbrales que maximizan la **varianza inter-clase** de la distribución de intensidades. Para n umbrales divide el histograma en $n+1$ regiones.

Ventaja del método de Otsu

No requiere conocimiento previo de los rangos de intensidad del tumor, siendo robusto ante variaciones entre pacientes.

2.4 Agrupamiento K-means

El algoritmo K-means agrupa los vóxeles en k clases minimizando la suma de distancias cuadráticas a los centroides. Se evalúan $k \in \{2, 3, 4\}$.

Límite de clases

Para estas imágenes no tiene sentido clínico usar más de **4 clases**. Con $k > 4$ el algoritmo fragmenta regiones anatómicamente coherentes sin beneficio diagnóstico.

3. Implementación

3.1 Dataset

Archivo	Modalidad	Patología	Característica de intensidad
<code>MRBrainTumor.nii.gz</code>	MR T1c	Tumor cerebral	Hiperintenso — cola derecha del histograma
<code>MRBreastCancer.nii.gz</code>	MR	Cáncer de mama	Masa con intensidad diferenciada del tejido graso
<code>MRLiverTumor.nii.gz</code>	MR	Tumor hepático	Hipointenso respecto al parénquima hepático

Tabla 3. Imágenes MRI utilizadas en los experimentos.

3.2 Umbral binario

El pipeline implementado para la umbralización primaria contempla una secuencia de lectura, procesamiento y escritura de imágenes médicas tridimensionales, y se encuentra desarrollado en el archivo `binary.py`. En este flujo, cada imagen es cargada desde el disco mediante un lector (`ImageFileReader`) y se procesa directamente con el filtro `BinaryThresholdImageFilter`, siguiendo la lógica de encadenamiento de ITK. La imagen de entrada se maneja en formato de punto flotante para conservar la información original de intensidades, mientras que la imagen de salida se convierte a un formato más simple (8 bits), adecuado para representar una segmentación binaria. Este proceso permite clasificar cada vóxel según si su intensidad se encuentra dentro o fuera del rango definido, generando una máscara donde la región de interés queda resaltada frente al fondo.

El código está diseñado para trabajar con múltiples imágenes de forma automática, identificando todos los archivos en formato `.nii` o `.nii.gz` dentro de una carpeta específica. Para cada volumen, el usuario ingresa manualmente los valores de umbral inferior y superior, lo que permite adaptar la segmentación a las características particulares de cada imagen sin modificar el programa. Adicionalmente, se incluyen validaciones que aseguran que los valores ingresados sean correctos y coherentes, por ejemplo, evitando que el umbral superior sea menor que el inferior. Esto facilita el uso del algoritmo en un contexto práctico, reduciendo errores durante la ejecución.

Finalmente, los resultados de la segmentación se almacenan en una carpeta independiente, manteniendo el nombre original de la imagen con una modificación que indica el procesamiento realizado. Esto permite relacionar cada imagen original con su respectiva salida. El código también incorpora manejo de errores durante el procesamiento de cada archivo, lo que evita que fallos puntuales detengan toda la ejecución.

3.3 Método de Otsu

El pipeline implementado para el método de Otsu sigue una secuencia de lectura, segmentación múltiple y escritura de resultados, desarrollado en el archivo `otsu_segmentation.py`. En este flujo, cada imagen es cargada desde el disco en formato de punto flotante (`itk.F`) para preservar la precisión de las intensidades originales, garantizando que el histograma interno del filtro refleje fielmente la distribución real de valores del volumen.

A diferencia del umbral binario, el filtro `OtsuMultipleThresholdsImageFilter` no requiere que el usuario defina los rangos de intensidad manualmente: calcula de forma automática los n umbrales que maximizan la varianza inter-clase del histograma discretizado en 128 bins, parámetro fijado con `SetNumberOfHistogramBins(128)` para todas las imágenes. Para cada volumen se ejecutan tres configuraciones independientes con $n \in \{1, 2, 3\}$, generando respectivamente 2, 3 y 4 regiones etiquetadas con valores enteros consecutivos a partir de cero. Los umbrales resultantes se recuperan mediante `GetThresholds()` para su registro y análisis.

El pipeline está diseñado para trabajar con las tres imágenes de forma automática. Para cada combinación imagen $\times n$, el volumen segmentado se almacena en formato NIfTI (`.nii.gz`) bajo `results/otsu/`, y se genera una figura comparativa PNG con tres vistas ortogonales centradas en el centroide del tumor, determinado previamente mediante inspección en 3D Slicer. Esto permite comparar visualmente el efecto de incrementar n sobre la delimitación de la región tumoral sin modificar el programa entre ejecuciones.

3.4 Agrupamiento k-means

El pipeline implementado para la segmentación por agrupamiento contempla una secuencia de lectura, procesamiento y escritura análoga a los métodos anteriores, y se encuentra desarrollado en el archivo `kmeans.py`. En este flujo, cada imagen es cargada desde el disco mediante un lector (`ImageFileReader`) y se procesa con el filtro `ScalarImageKmeansImageFilter`, siguiendo la arquitectura de ITK. La imagen de entrada se procesa en formato de punto flotante para calcular las distancias métricas con precisión. A diferencia del umbral binario, este método no utiliza un rango fijo, sino que clasifica cada vóxel minimizando iterativamente la diferencia de su intensidad respecto a un conjunto de centroides. La imagen de salida se convierte a un mapa de etiquetas (label map) de 8 bits, donde el valor de cada vóxel corresponde al número entero de la clase a la que fue asignado.

Para ilustrar este proceso de manera intuitiva, podemos usar una **analogía**: imaginemos que debemos agrupar a todas las personas de un auditorio en $k = 3$ tallas de camiseta (pequeña, mediana y grande) basándonos únicamente en su estatura, pero sin conocer los rangos exactos de antemano. El algoritmo comienza eligiendo al azar a tres personas como "modelos" iniciales (los centroides). Luego, cada persona en la sala se une al modelo que tenga la estatura más parecida a la suya. Una vez formados los tres grupos, se calcula la estatura promedio de cada uno para definir a tres "nuevos modelos". Las personas vuelven a reubicarse según estos nuevos promedios, y el ciclo se repite hasta que nadie cambie de grupo. En nuestro contexto médico (el **ejemplo práctico**), las "personas" son los vóxeles de la resonancia, la "estatura" es su nivel de gris, y los tres grupos finales representan tejidos distintos: por ejemplo, el fondo oscuro (clase 1), el tejido cerebral sano (clase 2) y la masa tumoral hiperintensa (clase 3).

Finalmente, los resultados de la segmentación se almacenan en una carpeta independiente, manteniendo el nombre original de la imagen con una modificación (ej. `_kmeans_k3`) que indica el procesamiento realizado y el número de clases utilizado. Esto permite relacionar cada imagen original con su respectiva salida. El código también incorpora manejo de errores durante el procesamiento de cada archivo, lo que evita que fallos puntuales —como la falta de convergencia del algoritmo en un volumen específico— detengan toda la ejecución del lote.

3.5 Pipeline de implementación

Pipeline general

Paso 1: Histograma en 3D Slicer → definición de rangos binarios

Paso 2: `BinaryThresholdImageFilter` con rangos de la Tabla 4

Paso 3: `OtsuMultipleThresholdsImageFilter` con $n \in \{1, 2, 3\}$

Paso 4: `ScalarImageKmeansImageFilter` con $k \in \{2, 3, 4\}$

Paso 5: Visualización de 3 vistas ortogonales por volumen

4. Resultados

4.1 Umbral Binario

Mediante el uso de la herramienta 3D Slicer, se accedió al histograma de intensidades de cada imagen con el fin de analizar la distribución de los valores de gris. Como referencia inicial, en la Figura 1 se presentan los cortes de las imágenes originales para cada órgano y cada una de las vistas (axial, sagital y coronal), antes de la aplicación de cualquier método de segmentación. A partir del análisis del histograma, se realizó un ajuste manual de los umbrales inferior y superior, buscando obtener la mejor configuración visual posible para la identificación de las regiones tumorales en cada caso. Como resultado de este proceso, se definieron los siguientes rangos de umbralización: cerebro (173–360), mama (330–750) e hígado (44–85).

Posteriormente, estos valores fueron empleados en la aplicación del filtro de binarización, permitiendo segmentar de manera efectiva las estructuras de interés en cada imagen. Los resultados para cada caso pueden ser visualizados en las Figuras 2, 3 y 4. Adicionalmente, con el fin de analizar la sensibilidad del método frente a la selección de umbrales, se realizó un estudio variando los valores definidos, aumentando y disminuyendo en 5 unidades los umbrales inferior y superior. Esto permitió evaluar el efecto de utilizar rangos más restrictivos o más amplios sobre la calidad de la segmentación. Los resultados de este análisis complementario se presentan al final de la sección.




Figura 1. Imágenes originales de MRI para cada órgano en vistas axial, sagital y coronal (previo a la segmentación).

Tumor Cerebral — Umbral Binario [173–360]



Figura 2. MRBrainTumor — Umbral binario [173–360]. La región blanca corresponde a los vóxeles dentro del rango umbralizado. Izq. a der.: vista axial, coronal, sagital.

La segmentación obtenida para el tumor cerebral mediante el rango [173–360] permite aislar de manera clara la región hiperintensa asociada a la lesión. En la vista axial, se identifica una estructura compacta y bien delimitada en la zona superior del hemisferio, lo que indica que el rango seleccionado captura adecuadamente el núcleo tumoral. Esta observación se complementa con la vista coronal, donde se evidencia la continuidad de la lesión en el eje anteroposterior, confirmando que la región segmentada corresponde a una estructura tridimensional coherente y no a un artefacto aislado.

En la vista sagital, se aprecia la localización lateral del tumor y su consistencia espacial dentro del volumen. No obstante, en todas las vistas, también se observan regiones adicionales segmentadas, como bordes del cráneo y pequeños puntos dispersos que corresponden a ruido. Esto evidencia que el rango de umbral incluye intensidades presentes en otras estructuras anatómicas, lo cual es una limitación inherente del método. A pesar de ello, la segmentación logra resaltar de forma efectiva la región de interés principal, siendo adecuada como aproximación inicial para la identificación del tumor.

Mama — Umbral Binario [330–750]




Figura 3. MRBreastCancer — Umbral binario [330–750]. La región blanca corresponde a los vóxeles dentro del rango umbralizado. Izq. a der.: vista axial, coronal, sagital.

La segmentación obtenida para el cáncer de mama con el rango [330–750] permite resaltar las regiones de mayor intensidad dentro del volumen. En la vista axial, se observa que la lesión tumoral presenta una forma más compacta y aproximadamente redondeada, lo que corresponde de manera más fidedigna a la morfología esperada del tumor. Esta vista permite una mejor delimitación de la región de interés, ya que el plano de corte coincide con la orientación donde el tumor presenta mayor continuidad espacial.

Sin embargo, en las vistas sagital y coronal, la segmentación pierde esa apariencia uniforme y se observa más fragmentada o pixelada, con discontinuidades en la región tumoral. Esto ocurre porque en estos planos la representación del volumen depende de la resolución entre cortes (espaciado entre slices), lo que puede generar menor continuidad visual. Además, la heterogeneidad de intensidades en el tejido mamario y la presencia de estructuras con valores similares provocan que el umbral incluya regiones no deseadas, afectando la forma final del tumor segmentado.

Higado — Umbral Binario [44–85]

Vista axial	Vista coronal	Vista sagital
-------------	---------------	---------------



Figura 4. MRLiverTumor — Umbral binario [44–85]. La región blanca corresponde a los vóxeles dentro del rango umbralizado. Izq. a der.: vista axial, sagital, coronal.

La segmentación obtenida para el tumor hepático con el rango [44–85] permite identificar adecuadamente la región de interés dentro del hígado, a pesar de tratarse del caso con menor contraste entre la lesión y el tejido circundante. En la vista coronal, se observa una delimitación clara del contorno hepático y una región interna que corresponde al tumor, lo que indica que el rango seleccionado logra capturar la diferencia de intensidades presente en esta patología. De manera similar, en la vista coronal se distingue el borde del hígado y, dentro de este, una zona diferenciada asociada a la lesión.

En la vista sagital, la segmentación es menos evidente debido a que el tumor en la imagen original es más pequeño en esta vista. Sin embargo, en términos generales, el método resulta adecuado, ya que el tumor es menos visible en comparación con los otros casos analizados y aun así logra ser segmentado. Aunque se identifican otras regiones fuera del hígado, si se considera una región de interés restringida al órgano, la segmentación es útil, dado que dentro del hígado no se observan estructuras adicionales relevantes aparte de la lesión.

Variación de umbrales




Figura 5. MRBrainTumor — Vista axial en diferentes umbrales.




Figura 6. MRBreastCancer — Vista axial en diferentes umbrales.

<i>Ideal: [44–85]</i>	<i>Amplio: [39–90].</i>	<i>Restringido: [49–80]</i>
-----------------------	-------------------------	-----------------------------




Figura 7. MRLiverTumor — Vista axial en diferentes umbrales.

El análisis de la variación de los umbrales evidencia que la segmentación binaria es altamente sensible a pequeños cambios en los valores seleccionados. Al ampliar el rango de umbralización, se incrementa la cantidad de vóxeles clasificados como pertenecientes a la región de interés, lo que conduce a una mayor inclusión de estructuras no deseadas (falsos positivos). Por el contrario, al hacer el rango más restrictivo, se obtiene una segmentación más conservadora, pero con el riesgo de excluir partes relevantes del tumor (falsos negativos). Esto confirma que la selección del umbral representa un equilibrio crítico entre sensibilidad y especificidad.

Asimismo, se observa que el comportamiento del método depende directamente de la distribución de intensidades de cada imagen. En el caso del cerebro, donde el tumor presenta un contraste bien definido respecto al tejido circundante, la segmentación se mantiene relativamente estable frente a variaciones pequeñas del umbral. En contraste, en mama e hígado, donde existe mayor solapamiento de intensidades entre tejidos, los cambios en el rango afectan significativamente la calidad de la segmentación, generando mayor ruido o pérdida de la forma del tumor.

4.2 Método de Otsu

4.2.1 Consideraciones generales del método

El método de Otsu presenta una dificultad estructural para la segmentación de tumores en imágenes MRI: su criterio de optimización maximiza la varianza inter-clase sobre la distribución global de intensidades del volumen completo. Esto implica que los umbrales calculados son óptimos para separar las clases más pobladas del histograma, no necesariamente la región tumoral. En las tres imágenes analizadas, el tumor representa entre el 1.7 % y el 4.9 % del volumen total con $n = 3$, por lo que su contribución al histograma es marginal frente al tejido de fondo y al parénquima normal.

Un factor adicional es la relación entre la forma del histograma y la separabilidad de las clases. Cuando el histograma presenta picos bien diferenciados y valles profundos, Otsu puede situar sus umbrales con alta precisión. Cuando los picos se solapan o el tumor produce solo una pequeña distorsión en la cola de la distribución, el umbral queda desplazado respecto al tumor real. Este fenómeno se observa en diferente magnitud en las tres imágenes del taller.

4.2.2 Tumor Cerebral (MRBrainTumor)

El tumor cerebral es el caso donde Otsu obtiene el mejor desempeño. La imagen MR T1c presenta un meningioma hiperintenso cuya intensidad máxima alcanza 986 UA, considerablemente mayor que el tejido cerebral normal. Con $n = 1$ ($\tau = 84.74$ UA), el método separa fondo del tejido cerebral incluyendo el tumor (25.1 %), sin lograr aislar la lesión del parénquima. Con $n = 2$ ($\tau_1 = 69.33$, $\tau_2 = 200.30$ UA), surge una tercera región de alta intensidad (4.7 %) que agrupa principalmente el núcleo tumoral. Con $n = 3$ ($\tau_1 = 69.33$, $\tau_2 = 169.48$, $\tau_3 = 277.33$ UA), la clase de mayor intensidad [277.3–986.0] UA ocupa el 1.7 % del volumen y corresponde con precisión al núcleo del meningioma. Incrementar n refina progresivamente el aislamiento del tumor.




Figura 5. MRBrainTumor — Comparativa Otsu $n = 1, 2, 3$. Cada celda muestra imagen original (izq.) y segmentación Otsu (der.) para tres cortes axiales centrados en el tumor. La etiqueta naranja (Et.3 con $n = 3$) corresponde al núcleo del meningioma.

4.2.3 Cáncer de Mama (MRBreastCancer)

La imagen de cáncer de mama presenta un rango dinámico amplio (0–2730 UA). Con $n = 1$ ($\tau = 554.57$ UA), Otsu separa fondo del tejido hiperintenso (19.3 %), pero esta clase incluye tumor, tejido glandular e implantes. Con $n = 2$ ($\tau_1 = 341.28$, $\tau_2 = 938.51$ UA), la clase de mayor intensidad (10.5 %, [938.5–2730.0] UA) se aproxima al tumor aunque con contaminación del tejido graso. Con $n = 3$ ($\tau_3 = 1215.80$ UA), la etiqueta 3 ocupa el 4.5 % del volumen ([1215.8–2730.0] UA), logrando un aislamiento razonablemente bueno del núcleo tumoral. La heterogeneidad del tejido mamario dificulta encontrar un umbral limpio.




Figura 6. MRBreastCancer — Comparativa Otsu $n = 1, 2, 3$. Las tres vistas corresponden a cortes axiales inferior, central y superior del volumen, centrados en el tumor de la mama derecha. Con $n = 3$ la etiqueta naranja (Et.3) delimita progresivamente el núcleo tumoral.

4.2.4 Tumor Hepático (MRLiverTumor)

El hígado es el caso más problemático para Otsu. La imagen está normalizada en $[0-255]$ UA y el histograma es prácticamente unimodal con una cola suave hacia los valores altos, sin valles definidos entre el parénquima hepático y el tumor. Con $n = 1$ ($\tau_1 = 61.76$ UA), el 24.8 % del volumen queda como clase alta, incluyendo el parénquima completo junto al tumor. Con $n = 2$ ($\tau_2 = 149.43$ UA), la etiqueta 2 ocupa el 4.9 % ($[149.4-255.0]$ UA) y se acerca al tumor, pero captura también bordes y vasos. Con $n = 3$ ($\tau_3 = 161.38$ UA), la etiqueta 3 (4.4 %) muestra la región más hiperintensa que incluye el tumor, aunque sin excluir completamente otras estructuras de alta señal.

La razón fundamental del fallo es que el histograma hepático carece de bimodalidad: la distribución es unimodal con una cola larga, donde el tumor representa solo una pequeña protuberancia. En esas condiciones, el criterio de máxima varianza inter-clase no puede encontrar un corte limpio que separe el tumor del tejido hepático sano, a diferencia del umbral binario manual $[44-85]$ UA que sí logró aislar la lesión hipointensa.




Figura 7. MRLiverTumor — Comparativa Otsu $n = 1, 2, 3$. Vistas axial, coronal y sagital centradas en el tumor hepático (esquina inferior derecha en la vista axial). Aunque con $n = 3$ la etiqueta naranja (Et.3) captura la masa más hiperintensa, el histograma unimodal impide un aislamiento limpio de la lesión.


Imagen	n	Umbrales calculados (UA)	Rango tumor (UA)	Vol. tumor (%)
Tumor cerebral	1	84.74	$[84.7 - 986.0]$	25.1 %
Tumor cerebral	2	69.33 / 200.30	$[200.3 - 986.0]$	4.7 %
Tumor cerebral	3	69.33 / 169.48 / 277.33	$[277.3 - 986.0]$	1.7 %


Cáncer de mama	1	554.57	[554.6 – 2730.0]	19.3 %
Cáncer de mama	2	341.28 / 938.51	[938.5 – 2730.0]	10.5 %
Cáncer de mama	3	255.96 / 703.88 / 1215.80	[1215.8 – 2730.0]	4.5 %
Tumor hepático	1	61.76	[61.8 – 255.0]	24.8 %
Tumor hepático	2	43.83 / 149.43	[149.4 – 255.0]	4.9 %
Tumor hepático	3	29.89 / 79.69 / 161.38	[161.4 – 255.0]	4.4 %

Tabla 5. Umbrales calculados automáticamente por `OtsuMultipleThresholdsImageFilter` y porcentaje de volumen de la clase de mayor intensidad (etiqueta tumor) para las tres imágenes con $n = 1, 2, 3$.

4.3 Agrupamiento K-means

A diferencia de los métodos de umbralización basados en rangos contiguos, el filtro `ScalarImageKmeansImageFilter` agrupa los vóxeles minimizando la distancia métrica de sus intensidades hacia k centroides iterativamente. A continuación, se presenta el análisis cualitativo de las imágenes resultantes:






- Tumor Cerebral (MRBrainTumor - Vistas Axial, Coronal y Sagital):** En las primeras tres series de imágenes analizadas, se observa que el algoritmo logra agrupar de manera efectiva la región hiperintensa correspondiente al núcleo tumoral (clúster representado en color cian). Al particionar el espacio de intensidades, K-means separa de forma natural la lesión del tejido cerebral sano alrededor (clúster azul). La segmentación resultante es espacialmente compacta debido al alto contraste intrínseco de la resonancia magnética para esta patología, lo que permite que el clúster asociado al tumor contenga muy poco ruido proveniente de otras estructuras anatómicas.



- Cáncer de Mama (MRBreastCancer - Vista Axial):** La imagen evidencia una segmentación más compleja. El mapa de etiquetas refleja una alta heterogeneidad del tejido mamario (fibroglandular y adiposo). Aunque la masa tumoral es asignada a un clúster específico (color naranja), esta comparte su firma de intensidad con regiones de la piel y otros tejidos densos no adyacentes. Esto ilustra una limitación fundamental de K-means: al carecer de restricciones espaciales o topológicas, clasifica en la misma categoría a múltiples estructuras disjuntas cuyo único rasgo común es la similitud de sus niveles de gris, lo que fragmenta la segmentación de la región de interés clínica.



- Tumor Hepático (MRLiverTumor - Vistas Axial, Coronal y Sagital):** Las últimas tres imágenes muestran el desempeño del agrupamiento en la región abdominal. El algoritmo consigue diferenciar el parénquima hepático general (clústeres verdes y naranjas) de la lesión hipointensa (clúster cian). Sin embargo, al igual que en el caso mamario, estructuras anatómicas adyacentes con densidades similares al tumor (como los fluidos gástricos o la vesícula) son asignadas por el algoritmo al mismo centroide. Aunque la lesión está bien delimitada en sus bordes internos, su aislamiento requeriría aislar el órgano previamente.

5. Análisis Comparativo

5.1 Comparación de los tres métodos

Aspecto	Umbral Binario	Otsu	K-means
Definición	Manual, basada en histograma	Automática, maximiza varianza inter-clase	Automática, agrupa por similitud

Regiones	2 (dentro/fuera del rango)	$n+1$ para n umbrales	k clases (2, 3 o 4)
Ventaja	Control total del rango	No requiere rango a priori	Captura agrupamientos complejos
Limitación	Ajuste manual imagen a imagen	Sensible a la forma del histograma	Sensible a inicialización

Tabla 5. Comparación de los tres métodos de segmentación por umbrales.

5.2 Influencia de los parámetros

5.2.1 Umbral Binario: efecto del rango

Para el cerebro, el rango [173–360] permitió aislar con precisión el núcleo tumoral realzado, ya que existe un contraste marcado entre el tumor y el tejido cerebral circundante en este tipo de imagen (T1 con contraste). Esto se refleja en una segmentación relativamente estable, donde pequeñas variaciones del umbral no afectan significativamente la forma ni la continuidad de la lesión. Al ampliar el rango, se incluyen estructuras adicionales como bordes del cráneo o regiones de alta intensidad, mientras que al hacerlo más restrictivo se reduce ligeramente el volumen segmentado, pero se conserva la morfología principal del tumor, evidenciando una buena separabilidad en el histograma.

En el caso de mama, el rango [330–750] produjo una segmentación considerablemente más ruidosa, lo cual se debe a la alta heterogeneidad del tejido mamario y al solapamiento de intensidades entre la lesión y otras estructuras como tejido glandular o conectivo. Como consecuencia, al ampliar el rango se incrementa notablemente la cantidad de falsos positivos, fragmentando la imagen y dificultando la identificación clara del tumor. Por otro lado, al restringir el rango, aunque se reduce el ruido, también se pierde continuidad en la lesión, generando una representación menos uniforme y más “pixelada”, lo que afecta la interpretación de su forma real.

Para el hígado, el rango [44–85] permitió capturar la lesión hipointensa respecto al parénquima hepático, pero con una inclusión significativa de otras estructuras de baja intensidad, como vasos sanguíneos, cavidades y la vesícula biliar. Esto se debe a que, en este caso, el contraste entre el tumor y el tejido sano es menor, lo que limita la efectividad del umbral binario. Al ampliar el rango, se incrementa la inclusión de estructuras no deseadas, mientras que al restringirlo se pierde parte de la lesión, dificultando su delimitación completa.

5.2.2 Otsu: efecto del número de umbrales

Con $n=1$ Otsu divide el volumen en dos clases según el corte de mayor varianza inter-clase, separando el fondo del tejido con señal, pero sin capacidad de distinguir el tumor del parénquima normal. Con $n=2$ se generan tres regiones que en cerebro y mama permiten identificar una clase de alta intensidad que se aproxima al tumor (4.7 % y 10.5 % del volumen respectivamente), aunque con contaminación de otras estructuras. Con $n=3$ la clase de mayor intensidad queda acotada a un rango más estrecho en la cola derecha del histograma, logrando en cerebro un aislamiento del núcleo del meningioma al 1.7 % del volumen ([277–986] UA) y en mama al 4.5 % ([1216–2730] UA). Sin embargo, para el hígado ningún valor de n produce una separación adecuada, debido a que su histograma es unimodal sin valles definidos entre el parénquima y el tumor: Otsu desplaza sus umbrales hacia las clases más pobladas independientemente de n , capturando siempre entre el 4.4 % y el 24.8 % del

volumen en la clase alta sin aislar la lesión de forma específica. Esto contrasta con el umbral binario manual [44–85] UA que sí logró segmentar el tumor hepático al aprovechar el conocimiento previo de su comportamiento hipointenso.

5.2.3 K-means: efecto del número de clases

Con $k=2$ equivale a un umbral binario automático. Con $k=3$ se aproxima a Otsu con 2 umbrales, a pesar de que el ruido en el proceso de segmentación genera agrupamientos que no otorgan mucho valor. Con $k=4$ distingue potencialmente núcleo tumoral, borde activo, edema y tejido sano, manteniendo la dificultad del agrupamiento por intensidades que genera en varias ocasiones que tejido disjunto y poco relacionado termine en el mismo agrupamiento.

6. Conclusiones

1. **Umbral Binario:** El método de umbral binario demostró ser una herramienta eficaz cuando se dispone de información previa sobre el rango de intensidades de la lesión, ya que permite un control directo sobre la segmentación a partir del análisis del histograma. En este trabajo, la selección manual de los rangos cerebro [173–360], mama [330–750] e hígado [44–85], realizada en 3D Slicer, permitió identificar las regiones tumorales en los tres casos estudiados. No obstante, su desempeño varía según el nivel de contraste y la homogeneidad de las intensidades: mientras en el cerebro se logra una segmentación más precisa y estable, en mama e hígado se evidencian limitaciones asociadas al solapamiento de intensidades y la inclusión de estructuras no deseadas, lo que resalta la dependencia del método respecto a una adecuada elección de umbrales y a las características propias de cada imagen.
2. **Método de Otsu:** La determinación automática de umbrales lo hace el método más robusto ante variaciones entre pacientes. El número óptimo de umbrales depende de la estructura del histograma de cada imagen.
3. **K-means:** El agrupamiento por similitud de intensidad captura estructuras que no forman picos aislados en el histograma. La elección de $k=3$ resulta en el mejor equilibrio entre granularidad y coherencia clínica.

Efectividad del agrupamiento no supervisado: El método de K-means demuestra ser una técnica robusta para la segmentación multi-clase cuando la patología presenta una firma de intensidad significativamente ortogonal al resto de las estructuras presentes en el volumen, logrando aislar el tumor cerebral de forma equiparable a una umbralización manual refinada.

Limitaciones por heterogeneidad tisular: En regiones con alto solapamiento de intensidades y estructuras complejas (como el tejido mamario y abdominal), el algoritmo K-means evidencia que la similitud de nivel de gris no es suficiente para garantizar la coherencia anatómica. Para estos casos clínicos, la utilidad de K-means radica en generar una máscara de pre-procesamiento para inicializar algoritmos más avanzados o arquitecturas convolucionales, más que en fungir como un segmentador final.

4. **Rol del histograma:** El análisis previo del histograma es el paso metodológicamente más importante del pipeline. Identificar los rangos de intensidad permite justificar cuantitativamente los parámetros de todos los métodos.
5. **Comparación entre métodos:** Los tres métodos producen resultados complementarios. El umbral binario delimita la región definida manualmente; Otsu

identifica los cortes naturales de la distribución; K-means agrupa vóxeles de intensidad similar. Una estrategia robusta combinaría los tres enfoques.

Referencias

- [1] ITK Examples (2024). Threshold an Image Using Binary Thresholding. <https://examples.itk.org/src/filtering/thresholding/thresholdanimageusingbinary/documentation>
- [2] ITK Examples (2024). Threshold an Image Using Otsu. <https://examples.itk.org/src/filtering/thresholding/thresholdanimageusingotsu/documentation>
- [3] ITK Examples (2024). Cluster Pixels in Grayscale Image. <https://examples.itk.org/src/segmentation/classifiers/clusterpixelsingrayscaleimage/documentation>
- [4] Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66.
- [5] ITK Development Team (2024). Insight Toolkit (ITK) v5.4. <https://itk.org>
- [6] Gonzalez, R.C. & Woods, R.E. (2018). Digital Image Processing (4th ed.). Pearson.
- [7] 3D Slicer (2024). 3D Slicer Image Computing Platform. <https://www.slicer.org>